



UNIVERSIDAD ESAN
FACULTAD DE INGENIERÍA
INGENIERÍA DE TECNOLOGÍAS DE INFORMACIÓN Y SISTEMAS

Implementación de un Chatbot Médico para la Prestación de Servicios en Áreas Rurales

Trabajo de investigación para el curso de Trabajo de Tesis I

Jean Pierre Castro Acuña
Asesor: Marks Calderón

Lima, 29 de mayo de 2024

Resumen

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ac odio tempor orci dapibus ultrices in iaculis nunc sed. Vivamus arcu felis bibendum ut tristique et egestas quis ipsum. Odio morbi quis commodo odio aenean sed adipiscing diam donec. Donec ultrices tincidunt arcu non sodales neque sodales ut. Fusce ut placerat orci nulla pellentesque dignissim enim sit amet. Facilisi etiam dignissim diam quis enim lobortis. Sit amet justo donec enim diam vulputate ut pharetra. Gravida in fermentum et sollicitudin ac orci phasellus egestas. Ultricies tristique nulla aliquet enim tortor at auctor. Nullam vehicula ipsum a arcu cursus vitae congue mauris. Convallis posuere morbi leo urna molestie at elementum eu facilisis. Elit at imperdiet dui accumsan sit amet nulla. Amet consectetur adipiscing elit pellentesque habitant morbi tristique senectus et. Mauris in aliquam sem fringilla ut morbi. Ultricies integer quis auctor elit sed vulputate mi sit. Nulla pellentesque dignissim enim sit amet venenatis urna cursus eget. Ac feugiat sed lectus vestibulum mattis ullamcorper. Eu augue ut lectus arcu bibendum. Rhoncus dolor purus non enim praesent elementum.

Nulla facilisi cras fermentum odio eu feugiat pretium. Massa massa ultricies mi quis hendrerit. Id leo in vitae turpis massa sed elementum. Quis vel eros donec ac odio tempor orci. Netus et malesuada fames ac turpis egestas integer eget aliquet. Velit ut tortor pretium viverra suspendisse potenti. Ut enim blandit volutpat maecenas. Nibh tellus molestie nunc non blandit. Mus mauris vitae ultricies leo integer malesuada nunc vel. Vel elit scelerisque mauris pellentesque pulvinar pellentesque habitant. Neque viverra justo nec ultrices dui sapien eget. Vitae aliquet nec ullamcorper sit. Dui id ornare arcu odio ut sem nulla pharetra diam. Et magnis dis parturient montes. Varius morbi enim nunc faucibus.

Palabras claves: uno, dos, tres, cuatro

Abstract

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ac odio tempor orci dapibus ultrices in iaculis nunc sed. Vivamus arcu felis bibendum ut tristique et egestas quis ipsum. Odio morbi quis commodo odio aenean sed adipiscing diam donec. Donec ultrices tincidunt arcu non sodales neque sodales ut. Fusce ut placerat orci nulla pellentesque dignissim enim sit amet. Facilisi etiam dignissim diam quis enim lobortis. Sit amet justo donec enim diam vulputate ut pharetra. Gravida in fermentum et sollicitudin ac orci phasellus egestas. Ultricies tristique nulla aliquet enim tortor at auctor. Nullam vehicula ipsum a arcu cursus vitae congue mauris. Convallis posuere morbi leo urna molestie at elementum eu facilisis. Elit at imperdiet dui accumsan sit amet nulla. Amet consectetur adipiscing elit pellentesque habitant morbi tristique senectus et. Mauris in aliquam sem fringilla ut morbi. Ultricies integer quis auctor elit sed vulputate mi sit. Nulla pellentesque dignissim enim sit amet venenatis urna cursus eget. Ac feugiat sed lectus vestibulum mattis ullamcorper. Eu augue ut lectus arcu bibendum. Rhoncus dolor purus non enim praesent elementum.

Nulla facilisi cras fermentum odio eu feugiat pretium. Massa massa ultricies mi quis hendrerit. Id leo in vitae turpis massa sed elementum. Quis vel eros donec ac odio tempor orci. Netus et malesuada fames ac turpis egestas integer eget aliquet. Velit ut tortor pretium viverra suspendisse potenti. Ut enim blandit volutpat maecenas. Nibh tellus molestie nunc non blandit. Mus mauris vitae ultricies leo integer malesuada nunc vel. Vel elit scelerisque mauris pellentesque pulvinar pellentesque habitant. Neque viverra justo nec ultrices dui sapien eget. Vitae aliquet nec ullamcorper sit. Dui id ornare arcu odio ut sem nulla pharetra diam. Et magnis dis parturient montes. Varius morbi enim nunc faucibus.

Keywords: uno, dos, tres, cuatro

Para mi X, Y,X

Agradecimientos

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ac odio tempor orci dapibus ultrices in iaculis nunc sed. Vivamus arcu felis bibendum ut tristique et egestas quis ipsum. Odio morbi quis commodo odio aenean sed adipiscing diam donec. Donec ultrices tincidunt arcu non sodales neque sodales ut. Fusce ut placerat orci nulla pellentesque dignissim enim sit amet. Facilisi etiam dignissim diam quis enim lobortis. Sit amet justo donec enim diam vulputate ut pharetra. Gravida in fermentum et sollicitudin ac orci phasellus egestas. Ultricies tristique nulla aliquet enim tortor at auctor. Nullam vehicula ipsum a arcu cursus vitae congue mauris. Convallis posuere morbi leo urna molestie at elementum eu facilisis. Elit at imperdiet dui accumsan sit amet nulla. Amet consectetur adipiscing elit pellentesque habitant morbi tristique senectus et. Mauris in aliquam sem fringilla ut morbi. Ultricies integer quis auctor elit sed vulputate mi sit. Nulla pellentesque dignissim enim sit amet venenatis urna cursus eget. Ac feugiat sed lectus vestibulum mattis ullamcorper. Eu augue ut lectus arcu bibendum. Rhoncus dolor purus non enim praesent elementum.

Nulla facilisi cras fermentum odio eu feugiat pretium. Massa massa ultricies mi quis hendrerit. Id leo in vitae turpis massa sed elementum. Quis vel eros donec ac odio tempor orci. Netus et malesuada fames ac turpis egestas integer eget aliquet. Velit ut tortor pretium viverra suspendisse potenti. Ut enim blandit volutpat maecenas. Nibh tellus molestie nunc non blandit. Mus mauris vitae ultricies leo integer malesuada nunc vel. Vel elit scelerisque mauris pellentesque pulvinar pellentesque habitant. Neque viverra justo nec ultrices dui sapien eget. Vitae aliquet nec ullamcorper sit. Dui id ornare arcu odio ut sem nulla pharetra diam. Et magnis dis parturient montes. Varius morbi enim nunc faucibus.

Índice general

Índice de Figuras	9
Índice de Tablas	11
1. PLANTEAMIENTO DEL PROBLEMA	12
1.1. Descripción de la Realidad Problemática	12
1.2. Formulación del Problema	14
1.2.1. Problema General	14
1.2.2. Problemas Específicos	14
1.3. Objetivos de la Investigación	15
1.3.1. Objetivo General	15
1.3.2. Objetivos Específicos	15
1.4. Justificación de la Investigación	15
1.4.1. Teórica	15
1.4.2. Práctica	16
1.4.3. Metodológica	16
1.5. Delimitación del Estudio	17
1.5.1. Espacial	17
1.5.2. Temporal	18
1.5.3. Conceptual	18

1.6.	Hipótesis	19
1.6.1.	Hipótesis General	19
1.6.2.	Hipótesis Específicas	19
1.6.3.	Matriz de Consistencia	19
2.	MARCO TEÓRICO	20
2.1.	Antecedentes de la investigación	20
2.1.1.	The Health ChatBots in Telemedicine: Intelligent Dialog System for Remote Support	20
2.1.2.	PEFT-MedAware: Large Language Model for Medical Awareness	24
2.1.3.	Medbot: Conversational Artificial Intelligence Powered Chatbot for Delivering Tele-Health after COVID-19	28
2.1.4.	Intelligent Chatbot for Medical Assistance in Rural Areas	31
2.1.5.	HHH: An Online Medical Chatbot System based on Knowledge Graph and Hierarchical Bi-Directional Attention	34
2.1.6.	HealFavor: Dataset and A Prototype System for Healthcare ChatBot	38
2.1.7.	ChatDoctor: A Medical Chat Model Fine-Tuned on a Large Language Model Meta-AI (LLaMA) Using Medical Domain Knowledge	41
2.1.8.	Auto Response Generation in Online Medical Chat Services	44
2.1.9.	An Approach to Medical Diagnosis Using Smart Chatbot	48
2.1.10.	A Medical ChatBot	51
2.2.	Bases Teóricas	55
2.2.1.	Inteligencia Artificial y Procesamiento de Lenguaje Natural	55
2.2.2.	Modelos de Machine Learning	56
2.2.3.	Telemedicina y Salud Digital	56
2.3.	Marco Conceptual	56
2.3.1.	Concepto de Chatbot Médico Pediátrico	56

2.3.2. Componentes del Chatbot Médico Pediátrico	57
2.3.3. Funcionalidades del Chatbot	57
2.3.4. Beneficios de Implementar un Chatbot Médico Pediátrico	57
2.3.5. Desafíos y Consideraciones Éticas	58
2.4. Implementación Técnica	58
2.4.1. Selección de la Plataforma de Desarrollo	58
2.4.2. Diseño de la Arquitectura del Chatbot	58
2.4.3. Desarrollo del Chatbot	59
2.4.4. Despliegue y Mantenimiento	59
3. METODOLOGÍA DE LA INVESTIGACIÓN	60
3.1. Diseño de la investigación	60
3.1.1. Diseño no experimental	60
3.1.2. Tipo explicativo	60
3.1.3. Enfoque cuantitativo	61
3.2. Población y muestra	61
3.3. Operacionalización de Variables	61
3.4. Instrumentos de medida	62
3.5. Técnicas de recolección de datos	62
3.6. Técnicas para el procesamiento y análisis de la información	63
3.7. Cronograma de actividades y presupuesto	63
4. DESARROLLO DEL EXPERIMENTO	64
4.1. X	64
4.2. Y	64
4.3. Z	65

5. ANÁLISIS Y DISCUSIÓN DE RESULTADOS	66
5.1. X	66
5.2. Y	66
5.3. Z	67
6. CONCLUSIONES Y RECOMENDACIONES	68
6.1. Conclusiones	68
6.2. Recomendaciones	68
Anexos	69
A. Anexo I: Matriz de Consistencia	70
B. Anexo II: Arbol del Problema	73
C. Anexo III: Arbol de Objetivos	74
D. Anexo IV: Resumen de Papers investigados	75
BIBLIOGRAFÍA	77

Índice de Figuras

1.1. Total de poblacion rural y urbana. Fuente: gl'inei	13
1.2. Porcentaje de acceso a atencion medica. Fuente: gl'inei	13
2.1. Escalabilidad y Disponibilidad. Fuente: CITAR AL FINAL	22
2.2. Interfaz de Usuario y Procesamiento NLP. Fuente: CITAR AL FINAL	23
2.3. Resultado. Fuente: CITAR AL FINAL	23
2.4. Resultado. Fuente: CITAR AL FINAL	24
2.5. Resultado. Fuente: CITAR AL FINAL	24
2.6. Metodologia. Fuente: CITAR AL FINAL	26
2.7. Metodologia. Fuente: CITAR AL FINAL	30
2.8. Metodologia. Fuente: CITAR AL FINAL	34
2.9. Metodologia. Fuente: CITAR AL FINAL	36
2.10. Metodologia. Fuente: CITAR AL FINAL	38
2.11. Metodologia. Fuente: CITAR AL FINAL	38
2.12. Metodologia. Fuente: CITAR AL FINAL	42
2.13. Metodologia. Fuente: CITAR AL FINAL	44
2.14. Metodologia. Fuente: CITAR AL FINAL	47
2.15. Metodologia. Fuente: CITAR AL FINAL	49
2.16. Metodologia. Fuente: CITAR AL FINAL	51
2.17. Metodologia. Fuente: CITAR AL FINAL	52

2.18. Metodología. Fuente: CITAR AL FINAL	53
2.19. Metodología. Fuente: CITAR AL FINAL	55
3.1. Prueba de Figura	61
B.1. Árbol del problema. Fuente: Elaboración propia	73

Índice de Tablas

3.1. An example table.	63
4.1. An example table.	64
5.1. An example table.	66
A.1. Matriz de consistencia. Fuente: Elaboración propia	71
A.2. Tabla de Hipótesis Específicas, Indicadores y Fórmulas	72
D.1. Cuadro Resumen de Papers investigados. Fuente: Elaboración propia	76

Capítulo 1

PLANTEAMIENTO DEL PROBLEMA

1.1. Descripción de la Realidad Problemática

En América Latina, la situación es igualmente preocupante. Un estudio realizado por la Comisión Económica para América Latina y el Caribe (CEPAL) reveló que el 60 % de los habitantes rurales no tienen acceso a servicios de salud adecuados (**OECD·World Bank·2020**). La falta de acceso a servicios de salud tiene consecuencias graves para la población pediátrica. La UNICEF informa que las tasas de mortalidad infantil en áreas rurales son significativamente más altas que en áreas urbanas. En países en desarrollo, los niños que viven en zonas rurales tienen el doble de probabilidades de morir antes de los cinco años en comparación con sus contrapartes urbanas **UNICEF**.

La situación de atención médica en las áreas rurales de Perú es una realidad compleja y desafiante. Imagine comunidades enclavadas en paisajes montañosos y remotos, donde acceder a servicios médicos básicos es una odisea. La falta de infraestructura adecuada y la escasez de profesionales de la salud crean una brecha significativa en el acceso a la atención médica, dejando a muchas personas sin la ayuda que necesitan cuando más la necesitan. Según el Instituto Nacional de Estadística e Informática (INEI), en 2022, solo el 20 % pertenece a la población rural, en comparación con el 80 % de la población urbana. Esto significa que millones de peruanos en áreas rurales son más vulnerables a enfermedades y muertes evitables.

Ademas, los datos oficiales respaldan estas realidades duras. Según el Ministerio de Salud de Perú, en el 2021, más del 70 % de la población rural carecía de acceso regular a servicios médicos adecuados. Esto no es solo una estadística fría, sino una narrativa de vidas afectadas, enfermedades no tratadas y vidas que podrían haberse salvado con una atención médica oportuna.

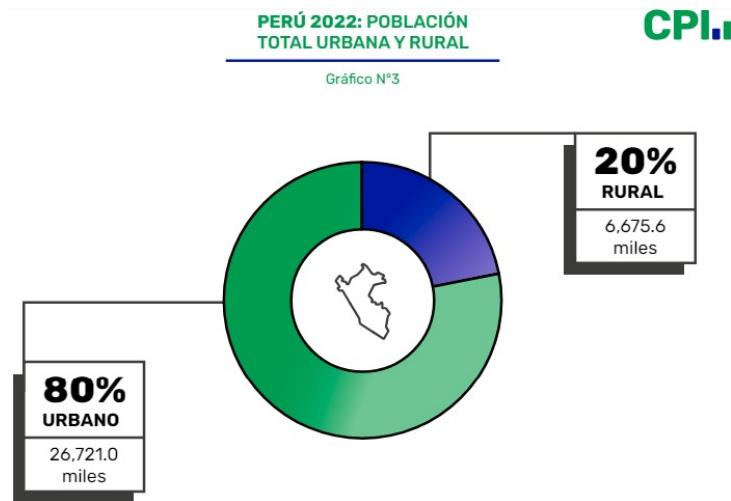


Figura 1.1: Total de población rural y urbana. Fuente: **glinei**

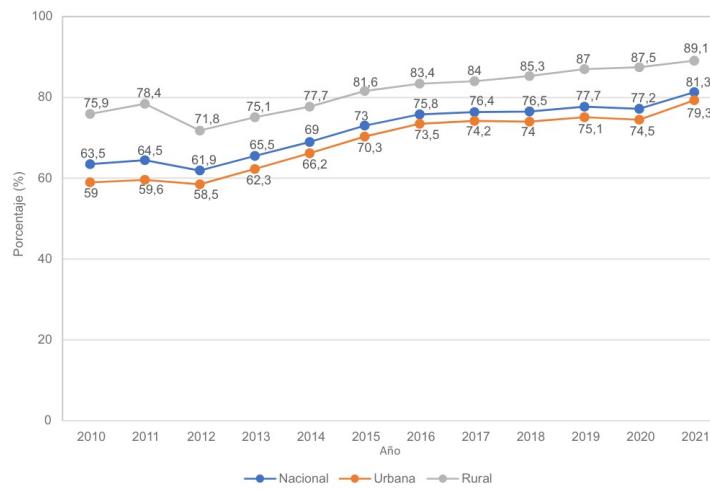


Figura 1.2: Porcentaje de acceso a atención médica. Fuente: **glinei**

Durante el período comprendido entre 2022 y 2024, la pandemia de COVID-19 solo ha intensificado estos desafíos. Los recursos y la atención se desplazaron hacia la respuesta a la pandemia, dejando otras necesidades de salud pública en segundo plano. Las comunidades rurales se encontraron aún más marginadas, enfrentando una atención médica aún más limitada y fragmentada.

Sin embargo, entre estas sombras de dificultades, hay un rayo de esperanza en la forma de la tecnología. El aumento del acceso a teléfonos móviles en áreas rurales ofrece una oportunidad única para brindar servicios médicos básicos a través de plataformas digitales, incluso en las zonas más remotas del país. Es aquí donde entra en juego la idea de un chatbot médico.

Imagínese un sistema donde las personas en las comunidades rurales pueden acceder

a información médica básica, hacer consultas sobre síntomas y recibir orientación sobre cómo buscar atención médica, todo desde la comodidad de sus teléfonos móviles. Esto no solo podría salvar vidas, sino también aliviar la carga sobre los pocos centros de salud disponibles en estas áreas.

Pero, por supuesto, hay obstáculos por superar. La adaptación cultural, la capacitación de los usuarios y la garantía de la precisión de la información son solo algunos de los desafíos que enfrenta esta iniciativa. Además, la conectividad limitada en algunas áreas rurales plantea desafíos adicionales para garantizar un acceso efectivo a la aplicación.

La implementación de Chatbots Médicos en áreas rurales del Perú tiene el potencial de mejorar significativamente el acceso a la atención médica para millones de personas. Estos sistemas pueden proporcionar información y asesoramiento médico de manera remota, sin necesidad de que un médico esté presente físicamente. Además, los Chatbots Médicos pueden ayudar a los pacientes a programar citas, recordarles que tomen sus medicamentos y monitorear su progreso.

1.2. Formulación del Problema

1.2.1. Problema General

¿De qué manera la implementación de un chatbot médico puede mejorar el acceso a servicios de salud en las zonas rurales de Perú?

1.2.2. Problemas Específicos

- ¿Qué datos disponibles se necesitarán para la implementación de chatbot?
- ¿Qué arquitectura podrían ser utilizadas para desarrollar un chatbot médico?
- ¿Qué métodos de entrenamiento y validación se pueden utilizar para un chatbot?
- ¿Qué métricas se pueden utilizar para evaluar la efectividad del chatbot médico?

1.3. Objetivos de la Investigación

1.3.1. Objetivo General

Implementar un chatbot médico efectivo y sostenible para brindar servicios de salud de calidad a las poblaciones rurales en Perú

1.3.2. Objetivos Específicos

- Identificar los datos disponibles y necesarios para la implementación del chatbot médico en áreas rurales de Perú.
- Explorar las diferentes arquitecturas disponibles para el desarrollo del chatbot médico.
- Investigar métodos de entrenamiento y validación adecuados para un chatbot médico.
- Definir métricas de evaluación para medir la efectividad y el impacto del chatbot médico en la prestación de servicios de la salud.

1.4. Justificación de la Investigación

1.4.1. Teórica

Esta investigación se enmarca en diversas teorías y modelos consolidados que brindan un respaldo sólido. En primer lugar, la Teoría de la Difusión de Innovaciones propuesta por Rogers (1962) explica cómo las innovaciones tecnológicas, como el chatbot médico, se propagan y son adoptadas en un sistema social determinado. Según Rogers, "la difusión es el proceso por el cual una innovación es comunicada a través de ciertos canales entre los miembros de un sistema social"(p. 11). Analizar factores como los canales de comunicación, las características de la innovación, el contexto social y cultural, aportará conocimientos valiosos para la implementación exitosa del chatbot en comunidades rurales.

Asimismo, los Modelos de Aceptación Tecnológica brindan un marco teórico robusto. El Modelo de Aceptación Tecnológica (TAM) propuesto por Davis (1989) sugiere que "la intención de uso de una tecnología está determinada por la utilidad percibida y la facilidad de uso percibida"(p. 320). Extensiones posteriores como el TAM2 (Venkatesh y Davis, 2000) y el UTAUT (Venkatesh et al., 2003) incorporan factores adicionales como la influencia social y

las condiciones facilitadoras, relevantes para predecir la adopción del chatbot por parte de los usuarios rurales.

Finalmente, teorías como el "Modelo de Determinantes de la Utilización de Servicios de Salud"(Andersen, 1995) y la "Teoría de Acceso a la Atención Médica"(Penchansky y Thomas, 1981) proporcionan un marco conceptual para analizar cómo el chatbot puede impactar en el acceso a servicios de salud. Andersen (1995) plantea que .el uso de los servicios de salud está determinado por factores predisponentes, facilitadores y de necesidad"(p. 3), mientras que Penchansky y Thomas (1981) definen el acceso como .el grado de ajuste entre las características de los recursos y las de la población"(p. 128), aspectos clave a considerar.

1.4.2. Práctica

Desde el punto de vista práctico, esta investigación se justifica ampliamente debido a la necesidad apremiante de mejorar el acceso a servicios de salud en áreas rurales de Perú y otros países en vías de desarrollo. Según datos de la Organización Mundial de la Salud (OMS, 2018), "más de mil millones de personas carecen de acceso a servicios de salud esenciales"(p. 1), siendo las poblaciones rurales y remotas las más afectadas.

Además, al facilitar el acceso a información y orientación básica en salud, el chatbot puede tener un impacto positivo en la calidad de vida y el bienestar de las poblaciones rurales, promoviendo prácticas preventivas y detección temprana de problemas.

Lo relevante es la optimización y descentralización de los recursos en el sistema de salud. Según Páez, F. (2024), "Los chatbots médicos pueden ayudar a reducir la carga de trabajo de médicos y hospitales al mejorar la calidad de la atención recibida por el paciente.". Esto es especialmente importante en contextos de escasez de recursos, como es el caso de las áreas rurales peruanas.

1.4.3. Metodológica

Esta investigación se justifica por la oportunidad de desarrollar un modelo integral de implementación de chatbots médicos. Es por ello que el modelo propuesto en esta investigación podría brindar una guía valiosa en este sentido.

Además, se podrán validar técnicas y herramientas innovadoras como el procesamiento de lenguaje natural (NLP), el aprendizaje automático (Machine Learning) y el diseño de in-

teracciones conversacionales naturales. Como señalan Tudor, L. et al. (2020), “el uso de NLP y ML es clave para desarrollar chatbots médicos precisos y efectivos”. Esta validación en un contexto real aportará conocimientos valiosos.

Otro aspecto metodológico importante es la generación de datos empíricos y evidencia científica sobre la aceptación, uso y efectividad del chatbot médico en comunidades rurales. Por lo que, se va a requerir más estudios de campo para evaluar el potencial de los chatbots de salud. Los datos generados en esta investigación podrían sentar las bases para futuros estudios y mejoras en la tecnología.

Finalmente, el desarrollo de métricas y herramientas de evaluación será fundamental para medir el desempeño e impacto del chatbot médico. Como sugieren Abd-Alrazaq, Alaa et al. (2020), “es necesario contar con métricas específicas para evaluar la efectividad de los chatbots de salud en cuanto a la calidad de la información, la satisfacción del usuario y los resultados clínicos”. Estas métricas y herramientas podrían ser aplicadas en futuras investigaciones y proyectos similares.

1.5. Delimitación del Estudio

1.5.1. Espacial

La presente investigación se delimita espacialmente a las áreas rurales del Perú, las cuales presentan características geográficas, demográficas y socioeconómicas particulares que obstaculizan el acceso a servicios de salud. Según el Instituto Nacional de Estadística e Informática (INEI, 2022), “en el año 2022, el 20% de la población peruana residía en el área rural”, concentrándose principalmente en la sierra y la selva. Estos territorios rurales se caracterizan por su dispersión geográfica y baja densidad poblacional, como señalan Diez-Canseco, F. et al. (2015) en su análisis del uso de tecnologías móviles en salud rural: ”Los principales desafíos son la falta de recursos, la fragmentación geográfica y las barreras culturales”(p. 2).

Asimismo, la diversidad étnica y cultural es un factor relevante, con presencia de poblaciones indígenas y comunidades nativas quechua-hablantes y aimara-hablantes, cuyas características socioculturales deben ser consideradas para asegurar la accesibilidad del chatbot médico.

1.5.2. Temporal

Esta investigación se desarrollará en un período de aproximadamente 2 años, con fases de diseño, desarrollo, implementación piloto y evaluación inicial del chatbot médico en comunidades rurales seleccionadas estratégicamente. Sin embargo, es importante considerar el contexto actual y proyecciones futuras.

Actualmente, el Ministerio de Salud de Perú (MINSA, 2022) ha implementado diversos programas y políticas orientadas a mejorar el acceso a servicios de salud en zonas rurales, como la Estrategia Sanitaria Nacional de Salud de los Pueblos Indígenas. Además, se han realizado esfuerzos por incorporar tecnologías como la telemedicina y los dispositivos móviles.

A futuro, se espera que la implementación del chatbot médico pueda escalarse a otras regiones rurales del país, integrándose con estrategias y tecnologías emergentes en el sector salud, como los sistemas de información geográfica y la inteligencia artificial aplicada a la medicina.

1.5.3. Conceptual

Según Laranjo et al. (2018), un chatbot médico es un programa de computadora basado en inteligencia artificial diseñado para simular una conversación inteligente con usuarios humanos a través de canales de texto o voz, con el objetivo de brindar información y consejos médicos. Este tipo de tecnología ha ganado relevancia en los últimos años, ya que puede ayudar a superar barreras de acceso a servicios de salud, especialmente en áreas remotas y rurales.

Tomando como referencia el marco conceptual propuesto por Levesque et al. (2013), el acceso abarca dimensiones como la accesibilidad geográfica, la disponibilidad, la aceptabilidad y la capacidad de pago. En el contexto de las áreas rurales peruanas, donde existen grandes desafíos en términos de dispersión geográfica, escasez de profesionales de la salud y barreras culturales, es esencial abordar estas dimensiones para lograr un acceso equitativo y efectivo a los servicios de salud.

Asimismo, la investigación se centrará en analizar los factores que influyen en la adopción y aceptación tecnológica del chatbot médico por parte de las poblaciones rurales. Para ello, se utilizará el Modelo Unificado de Aceptación y Uso de Tecnología (UTAUT) desarrollado por Venkatesh et al. (2003), el cual integra factores como la expectativa de desempeño, la expectativa de esfuerzo, la influencia social y las condiciones facilitadoras. Comprender estos factores será clave para diseñar e implementar el chatbot de manera efectiva y promover su adopción por parte de los usuarios.

Finalmente, la investigación también considerará los determinantes sociales de la salud, los cuales influyen en el estado de salud y el acceso a servicios médicos en las comunidades rurales.

1.6. Hipótesis

1.6.1. Hipótesis General

La implementación de un chatbot médico mejorará significativamente el acceso a servicios médicos de calidad para las poblaciones rurales.

1.6.2. Hipótesis Específicas

- La disponibilidad de datos y la integración de APIs adecuadas serán fundamentales para el desarrollo exitoso del chatbot médico.
- La arquitectura permitirá la creación de un chatbot médico eficiente y preciso.
- La aplicación de métodos de entrenamiento y validación apropiados garantizarán la funcionalidad y confiabilidad del chatbot médico
- La evaluación de métricas específicas revelará el impacto positivo del chatbot médico en la prestación de servicios de salud en áreas rurales de Perú

1.6.3. Matriz de Consistencia

A continuación se presenta la matriz de consistencia elaborada para la presente investigación (véase Anexo A.1).

Capítulo 2

MARCO TEÓRICO

2.1. Antecedentes de la investigación

En esta sección se presentarán diversos artículos de investigación o tesis las cuales abordarán diversas técnicas y enfoques que se emplearon para afrontar problemas similares al de esta tesis. Asimismo, a continuación se presenta un cuadro resumen (véase Anexo D.1) de lo que se presenta en esta sección.

2.1.1. The Health ChatBots in Telemedicine: Intelligent Dialog System for Remote Support

2.1.1.1. Planteamiento del Problema y objetivo

En la actualidad, la implementación de tecnologías avanzadas como el Internet de las Cosas (IoT), Big Data y la inteligencia artificial (IA) en el sector de la salud es esencial para mejorar los servicios de telemedicina. Sin embargo, la interacción tradicional entre pacientes y el sistema de salud carece de herramientas eficientes para la recolección y análisis de datos de salud de manera amigable y precisa. Los métodos convencionales de recopilación de síntomas y datos de pacientes son a menudo tediosos y propensos a errores, lo que puede llevar a diagnósticos imprecisos y a una experiencia de usuario deficiente.

El uso de ChatBots en telemedicina presenta una oportunidad para transformar estas interacciones, permitiendo a los pacientes comunicar sus síntomas y recibir diagnósticos preliminares de manera más interactiva y accesible. No obstante, la implementación de un sistema de ChatBot eficaz enfrenta desafíos significativos, incluyendo la necesidad de una adecuada

comprensión del lenguaje natural (NLP), la integración segura de datos de pacientes, y la creación de modelos de aprendizaje automático (ML) precisos y fiables para la predicción de enfermedades

2.1.1.2. Objetivos

1. Desarrollar una plataforma de ChatBot de salud que utilice tecnologías de NLP para mejorar la interacción entre los pacientes y el sistema de salud.
2. Implementar modelos de IA y ML para la clasificación y predicción de enfermedades basadas en los síntomas reportados por los pacientes.
3. Garantizar la seguridad y privacidad de los datos de los pacientes, cumpliendo con las normativas de protección de datos.
4. Facilitar la accesibilidad y usabilidad del sistema mediante interfaces de usuario intuitivas y compatibles con el lenguaje natural.
5. Evaluar la eficacia de la plataforma mediante la implementación y prueba de casos específicos, como enfermedades cardíacas y Covid-19.

2.1.1.3. Fundamento Teórico

La utilización de ChatBots en el ámbito de la salud se basa en tecnologías avanzadas de NLP y ML para entender y procesar el lenguaje natural de los pacientes. El NLP permite a las máquinas interpretar, analizar y responder a textos generados por humanos, facilitando la comunicación eficiente entre los pacientes y los sistemas de salud. Este proceso incluye diversas técnicas como la lematización, la segmentación morfológica y el etiquetado de partes del discurso, que ayudan a descomponer y entender el texto de entrada.

Los ChatBots de IA están diseñados para imitar la conversación humana utilizando algoritmos de NLP, permitiendo así la recolección de síntomas y la provisión de recomendaciones de autocuidado. Estos sistemas son capaces de analizar grandes volúmenes de datos generados por los usuarios, clasificarlos y extraer insights valiosos mediante algoritmos de ML. Además, la comprensión del lenguaje natural (NLU) es un componente crucial del NLP que transforma los datos no estructurados en datos clasificados, asignándolos a las intenciones adecuadas.

El desarrollo de un ChatBot de salud eficaz requiere la integración de varias capas tecnológicas, incluyendo motores de procesamiento de lenguaje natural, modelos de ML para la predicción de enfermedades y plataformas seguras para el manejo de datos de salud. La

arquitectura modular del Health Bot, por ejemplo, facilita la escalabilidad y la adaptabilidad del sistema, permitiendo su implementación en diversos escenarios de telemedicina.

2.1.1.4. Metodología empleada por los autores

- **Privacidad de Datos** Los datos del paciente son protegidos mediante algoritmos de encriptación asimétrica RSA/ECB/PKCS1PADDING. La clave privada RSA es protegida y solo accesible por la capa interna de la API hospitalaria. El Health Bot utiliza la clave pública para desencriptar las solicitudes, garantizando la seguridad de los datos .
- **Escalabilidad y Disponibilidad** Para asegurar la disponibilidad y escalabilidad de la plataforma, se ha implementado una arquitectura distribuida sin puntos únicos de falla, utilizando servicios de Google Cloud como funciones de Firebase, bases de datos y hosting, BigQuery ML y AI Cloud .

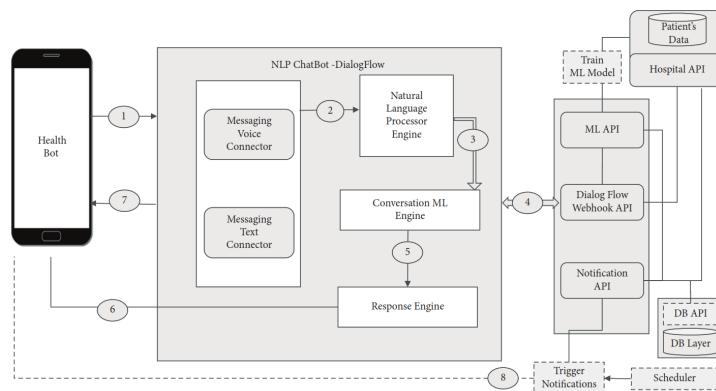


Figura 2.1: Escalabilidad y Disponibilidad. Fuente: CITAR AL FINAL

- **Interfaz de Usuario y Procesamiento NLP** El Health Bot UI soporta interfaces conversacionales basadas en texto y voz, desarrollado como una aplicación web progresiva (PWA) para proporcionar una experiencia de usuario nativa. El procesamiento NLP de DialogFlow clasifica las solicitudes de los pacientes y gestiona las respuestas utilizando un flujo de diálogo estructurado .
- **Clasificadores de Intención** Los clasificadores de intención son responsables de identificar y manejar las preguntas demográficas del paciente, los síntomas conocidos, el estado actual de salud y la programación de citas. Cada intención se gestiona a través de un flujo de contexto que asegura la recogida precisa de datos y la respuesta adecuada del sistema.

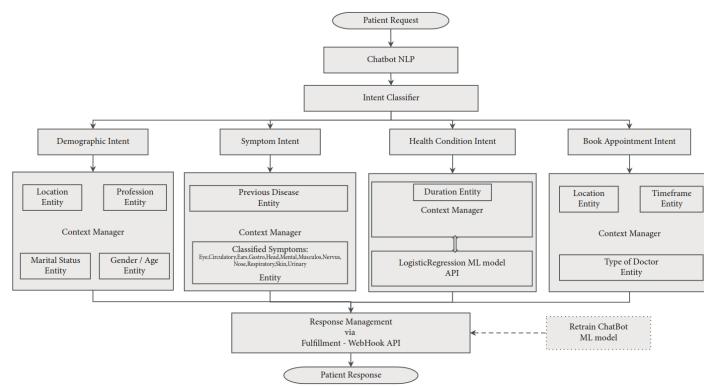


Figura 2.2: Interfaz de Usuario y Procesamiento NLP. Fuente: CITAR AL FINAL

2.1.1.5. Resultados obtenidos

Los resultados del estudio muestran que el Health Bot es capaz de predecir con alta precisión casos de Covid-19 y enfermedades cardíacas. Los modelos de ML entrenados lograron precisiones del 98.3% y 82%, respectivamente. En el caso del modelo de Covid-19, se utilizó un conjunto de datos emulado con 2100 filas, de las cuales el 80% se empleó para entrenamiento y el 20% para pruebas. El modelo de regresión logística utilizado para predecir enfermedades cardíacas fue entrenado con el conjunto de datos de Cleveland de UCI, logrando un rendimiento del 82% en precisión.

La implementación de algoritmos de ML y la integración de tecnologías de NLP permitieron una interacción más fluida y precisa entre los pacientes y el sistema de salud, mejorando así la experiencia del usuario y la eficiencia del diagnóstico.

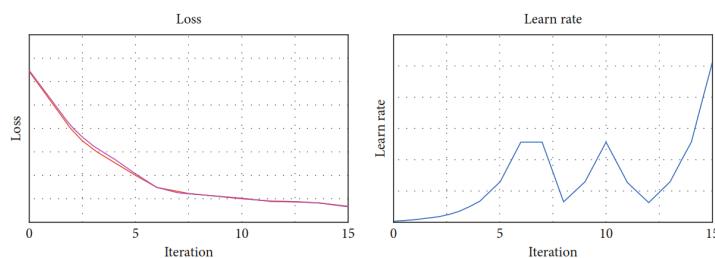
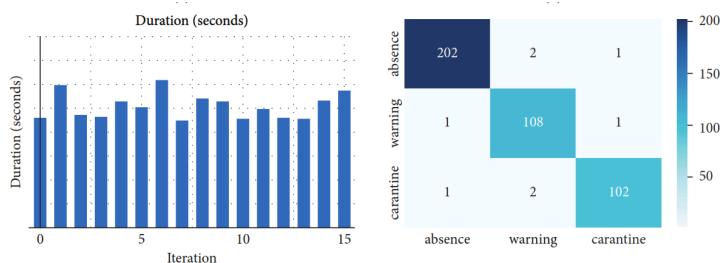
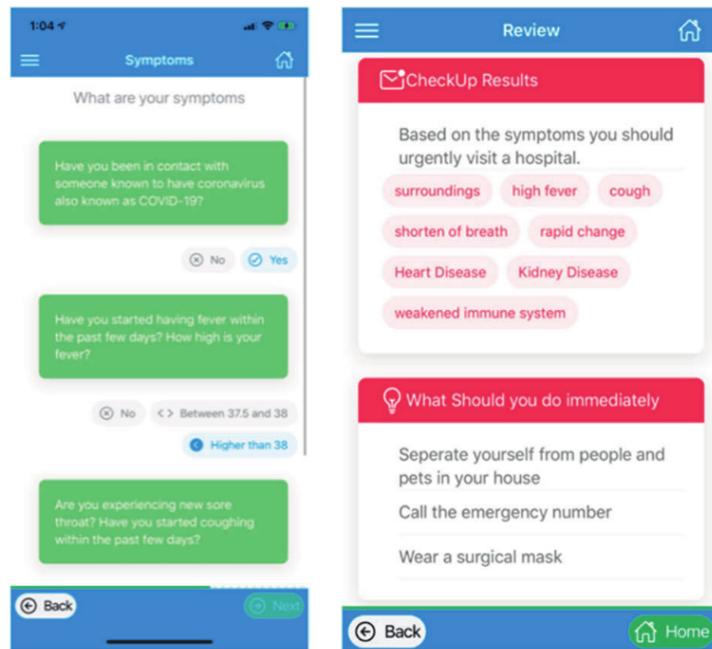


Figura 2.3: Resultado. Fuente: CITAR AL FINAL

**Figura 2.4:** Resultado. Fuente: CITAR AL FINAL**Figura 2.5:** Resultado. Fuente: CITAR AL FINAL

2.1.2. PEFT-MedAware: Large Language Model for Medical Awareness

2.1.2.1. Planteamiento del Problema y objetivo

El artículo "PEFT-MedAware: Large Language Model for Medical Awareness" de Keivalya Pandya aborda el desarrollo de un modelo de lenguaje especializado en la conciencia médica utilizando un enfoque de ajuste fino eficiente en parámetros (PEFT). El problema principal identificado es la inexactitud y la incertidumbre en las respuestas de los modelos de chat generalistas en el ámbito médico, donde la precisión y la fiabilidad son esenciales. Para abordar este problema, se propone un modelo específico, peft-MedAware, que utiliza PEFT para mejorar el modelo Falcon-1b con datos de MedQuAD, que contiene 16,407 pares de preguntas y respuestas médicas. Este enfoque optimiza el rendimiento del modelo utilizando solo el 0.44 % de sus parámetros entrenables, mejorando así la eficiencia computacional. El modelo resultante

superá a otros LLMs en tareas de preguntas y respuestas médicas específicas, utilizando recursos computacionales limitados, lo que lo hace adecuado para su implementación en entornos con restricciones de recursos.

2.1.2.2. Objetivos

1. Desarrollar y optimizar el modelo peft-MedAware utilizando técnicas de PEFT para mejorar la precisión en la respuesta a consultas médicas específicas.
2. Reducir el uso de recursos computacionales manteniendo o mejorando la precisión del modelo, haciéndolo adecuado para su implementación en entornos con recursos limitados.
3. Aumentar la eficiencia en el entrenamiento de modelos mediante la utilización de configuraciones avanzadas de quantización.
4. Proporcionar respuestas médicas contextualmente relevantes y basadas en evidencia a partir de un amplio conjunto de datos médicos.
5. Evaluar el rendimiento del modelo en comparación con otros modelos de lenguaje a gran escala en tareas de preguntas y respuestas médicas.

2.1.2.3. Fundamento Teórico

El fundamento teórico del artículo se basa en el uso de tecnologías avanzadas de procesamiento del lenguaje natural (NLP) y ajuste fino eficiente en parámetros (PEFT) para mejorar la precisión y eficiencia de los modelos de lenguaje en el ámbito médico.

- **Procesamiento del Lenguaje Natural (NLP)** El NLP es una rama de la inteligencia artificial que se centra en la interacción entre las computadoras y el lenguaje humano. Este campo permite a las máquinas interpretar, comprender y responder a textos generados por humanos. En el contexto del artículo, el NLP se utiliza para analizar y clasificar datos médicos en texto, permitiendo al modelo peft-MedAware proporcionar respuestas precisas y contextualmente relevantes a consultas médicas.
- **Ajuste Fino Eficiente en Parámetros (PEFT)** El PEFT es una técnica de optimización que ajusta solo los parámetros más influyentes de un modelo, lo que reduce significativamente la sobrecarga computacional y el tiempo de entrenamiento. Esta técnica es crucial cuando se trabaja con grandes modelos de lenguaje, ya que permite un uso más eficiente

de los recursos computacionales. En el caso del modelo peft-MedAware, solo se ajustaron 3 millones de parámetros de un total de 700 millones, lo que representa el 0.44 % del total, logrando así una optimización significativa sin comprometer el rendimiento del modelo.

- **Modelos de Lenguaje Grande (LLMs)** Los LLMs son modelos de inteligencia artificial que contienen miles de millones de parámetros y están diseñados para comprender y generar texto. Estos modelos tienen el potencial de revolucionar la búsqueda de información en el ámbito médico al proporcionar información precisa y actualizada. Sin embargo, su eficacia depende de su capacidad para ofrecer respuestas detalladas y específicas a consultas médicas.
- **Quantización** La configuración de BitsAndBytes se utiliza para procesar datos y actualizar pesos de manera eficiente durante el entrenamiento de transformadores. La quantización reduce la precisión de los datos procesados, lo que disminuye el consumo de memoria y permite manejar modelos más grandes o múltiples modelos simultáneamente sin sobrecargar los recursos del sistema.
- **Datasets Especializados** MedQuAD es un conjunto de datos de preguntas y respuestas médicas utilizado para entrenar el modelo peft-MedAware. Este dataset incluye pares de preguntas y respuestas sobre una amplia variedad de enfermedades, medicamentos y otras entidades médicas, proporcionando una base sólida para el entrenamiento y la evaluación del modelo en tareas específicas de QA médico.

2.1.2.4. Metodología empleada por los autores

La metodología utilizada en el desarrollo del modelo peft-MedAware incluye varias etapas críticas, desde la preprocesamiento de datos hasta la implementación de técnicas de ajuste fino y cuantificación para optimizar el rendimiento del modelo.

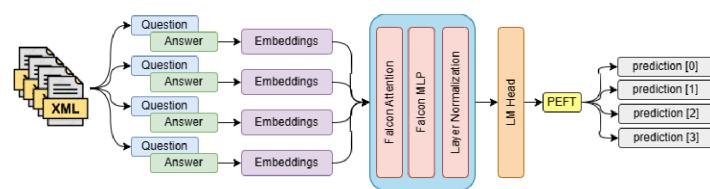


Figura 2.6: Metodología. Fuente: CITAR AL FINAL

1. Selección y Preprocesamiento de Datos:

Dataset MedQuAD: Se utilizó el conjunto de datos MedQuAD, que contiene 16,407 pares de preguntas y respuestas médicas, para entrenar el modelo. Este dataset está bien anotado y cubre una amplia variedad de tipos de preguntas relacionadas con enfermedades, tratamientos, diagnósticos y efectos secundarios.

Preprocesamiento: Se llevó a cabo un preprocesamiento exhaustivo de los datos para transformar las preguntas y respuestas en un formato adecuado para el entrenamiento del modelo. Esto incluye la limpieza de datos, normalización y etiquetado de entidades.

2. Entrenamiento del Modelo:

Ajuste Fino Eficiente en Parámetros (PEFT): Se aplicó PEFT para ajustar finamente el modelo Falcon-1b utilizando solo el 0.44 % de sus parámetros entrenables (aproximadamente 3 millones de 700 millones). Esto permitió reducir significativamente la sobrecarga computacional mientras se mantenía una alta precisión en las respuestas del modelo.

Quantización: Se utilizó la configuración de BitsAndBytes para procesar los datos con precisión de 4 bits, lo que redujo el consumo de memoria y permitió un entrenamiento más eficiente en hardware diverso. Además, se empleó la técnica de doble quantización para capturar características intrincadas de los datos sin comprometer la precisión numérica.

3. Configuración del Modelo:

Carga del Modelo: El modelo se cargó utilizando precisión de 4 bits, lo que permitió manejar grandes volúmenes de datos y entrenar el modelo de manera eficiente en Google Colab T4 Runtime.

Optimización de Recursos: La reducción de la complejidad computacional permitió entrenar el modelo más rápidamente y conservar recursos, facilitando la experimentación con varios hiperparámetros y configuraciones sin sobrecargar el sistema.

4. Evaluación y Comparación:

Comparación con Otros Modelos: Se comparó el rendimiento del modelo peft-MedAware con otros modelos de lenguaje a gran escala, como ChatGPT y Baize-healthcare, en tareas de preguntas y respuestas médicas. Se demostró que peft-MedAware proporciona respuestas más precisas y contextualmente relevantes, superando a los modelos estándar en términos de precisión sin requerir una gran cantidad de recursos computacionales.

2.1.2.5. Resultados obtenidos

Los resultados del estudio muestran que el modelo peft-MedAware supera a otros modelos de lenguaje en tareas de preguntas y respuestas médicas específicas, utilizando recursos computacionales limitados. El modelo fue capaz de proporcionar respuestas precisas y contextualmente relevantes a una amplia gama de consultas médicas, demostrando una alta eficiencia y especialización. Además, la reducción en los requisitos computacionales permitió tiempos de entrenamiento más rápidos y una mejor eficiencia general del modelo. La implementación de técnicas de PEFT y cuantificación optimizada resultó en un modelo que es tanto preciso como eficiente, adecuado para su despliegue en entornos con restricciones de recursos.

2.1.3. Medbot: Conversational Artificial Intelligence Powered Chatbot for Delivering Tele-Health after COVID-19

2.1.3.1. Planteamiento del Problema y objetivo

La pandemia de COVID-19 ha exacerbado los desafíos existentes en la atención médica, particularmente en áreas rurales de India, donde el acceso a servicios de salud es limitado. El artículo aborda la necesidad de una solución innovadora para superar estas barreras mediante el uso de inteligencia artificial (IA) y tecnologías de telemedicina. Específicamente, propone el desarrollo de un chatbot conversacional multilingüe llamado “Apka Chikitsak”, diseñado para proporcionar educación sanitaria primaria, asesoramiento y medidas preventivas a los pacientes sin necesidad de visitar físicamente un hospital. Este enfoque no solo busca reducir la transmisión del virus, sino también mejorar la accesibilidad y la calidad de la atención médica en un contexto de recursos limitados.

2.1.3.2. Objetivos

1. Mejorar el acceso a la atención médica: Facilitar el acceso a información y consultas médicas para poblaciones rurales y marginadas.
2. Reducir la carga en los sistemas de salud: Aliviar la presión sobre los servicios de salud presenciales mediante la provisión de consultas virtuales.
3. Proveer educación sanitaria: Ofrecer información sanitaria básica, medidas preventivas y remedios caseros para enfermedades prevalentes.

4. Implementar tecnología avanzada: Utilizar procesamiento de lenguaje natural y arquitectura sin servidor para crear un sistema eficiente y escalable.
5. Promover la salud pública: Ayudar en la prevención de enfermedades infecciosas y mejorar el bienestar general de la población.

2.1.3.3. Fundamento Teórico

El fundamento teórico del artículo se basa en varios pilares de la inteligencia artificial y la telemedicina:

- **Inteligencia Artificial en Salud:** La IA, a través de chatbots y asistentes virtuales, ha demostrado ser eficaz en la simulación de interacciones humanas para proporcionar atención médica. Ejemplos previos incluyen sistemas como ELIZA y PARRY, que imitan interacciones humanas para fines terapéuticos y de diagnóstico .
- **Procesamiento de Lenguaje Natural (NLP):** El uso de NLP permite que los chatbots comprendan y respondan a las consultas de los usuarios en lenguaje natural, facilitando interacciones más humanas y efectivas. Esto incluye la conversión de voz a texto y viceversa, esencial para la funcionalidad del chatbot en múltiples idiomas.
- **Telemedicina:** La telemedicina permite la distribución de servicios de salud a distancia, reduciendo la necesidad de visitas físicas a los centros de salud. Esto es particularmente relevante en el contexto de la pandemia de COVID-19, donde el distanciamiento social es crucial.
- **Arquitectura sin Servidor:** El uso de arquitecturas sin servidor (serverless) permite implementar servicios de backend sin necesidad de infraestructura dedicada, lo que facilita la escalabilidad y la eficiencia del sistema.

2.1.3.4. Metodología empleada por los autores

La metodología empleada en el desarrollo del chatbot .^apka Chikitsak inkluye varios componentes clave:

1. **Análisis de Requisitos:** Se identificaron las necesidades de los usuarios, particularmente en áreas rurales, para diseñar un sistema que sea accesible y fácil de usar.

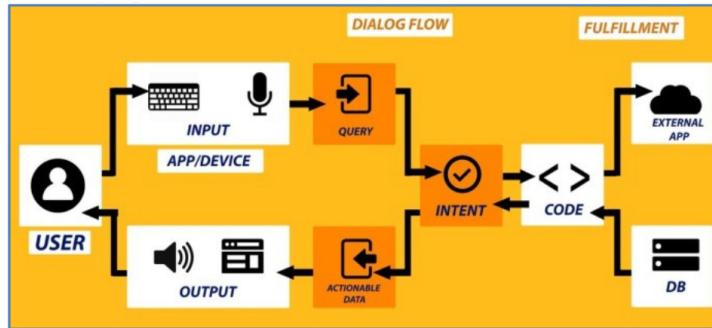


Figura 2.7: Metodología. Fuente: CITAR AL FINAL

2. **Diseño de la Arquitectura:** La aplicación se construyó sobre una arquitectura sin servidor utilizando Google Cloud Platform (GCP) y Firebase Cloud Functions. Esta elección permite una fácil escalabilidad y reduce la necesidad de infraestructura física.
3. **Desarrollo del Chatbot:** Se desarrolló un chatbot multilingüe utilizando el API de Dialogflow para la creación de una interfaz conversacional automatizada. El chatbot puede manejar entradas de voz y texto, procesarlas usando NLP y generar respuestas adecuadas.
4. **Entrenamiento del Modelo:** Se entrenaron modelos de NLP para reconocer y entender diversas consultas de salud. Los modelos se alimentaron con datos relevantes para mejorar su precisión en la identificación de síntomas y la provisión de consejos médicos.
5. **Integración y Pruebas:** La aplicación se integró con diversas bases de datos de salud y se sometió a pruebas exhaustivas para asegurar su funcionalidad y precisión. Se realizaron pruebas de usuario para ajustar la interfaz y mejorar la experiencia del usuario.
6. **Despliegue y Mantenimiento:** El sistema se desplegó en la infraestructura de GCP, asegurando su disponibilidad y accesibilidad. Se implementó un sistema de monitoreo continuo para mantener la calidad del servicio y realizar mejoras basadas en el feedback de los usuarios.

2.1.3.5. Resultados obtenidos

Los resultados del estudio muestran que el chatbot "apka Chikitsak" ha logrado reducir significativamente las barreras de acceso a los servicios de salud en las áreas rurales de India. El bot proporciona información sobre las enfermedades más prevalentes, medidas preventivas, remedios caseros y recomendaciones dietéticas basadas en la ubicación del usuario. Además, ofrece sesiones de asesoramiento interactivo para el apoyo emocional y la atención prenatal. La

implementación del chatbot ha demostrado ser eficaz en la detección de enfermedades comunes y la provisión de soluciones inmediatas y eficientes a los pacientes.

2.1.4. Intelligent Chatbot for Medical Assistance in Rural Areas

2.1.4.1. Planteamiento del Problema y objetivo

El artículo 'Intelligent Chatbot for Medical Assistance in Rural Areas.'^aborda la problemática de la falta de acceso a servicios médicos en las áreas rurales de la India, donde la mayoría de los doctores y facilidades hospitalarias están concentrados en zonas urbanas. Esto deja a millones de personas sin acceso adecuado a atención médica. Para abordar esta disparidad, los autores han desarrollado una aplicación de chatbot que actúa como un asistente médico virtual, diseñado para conectar a los pacientes rurales con médicos y proporcionar asistencia médica básica. La aplicación utiliza inteligencia artificial para responder consultas médicas, recomendar prácticas de tratamiento y derivar a los pacientes a médicos en casos de problemas más graves. El objetivo es ofrecer una herramienta accesible que pueda brindar información médica esencial, mejorar la autogestión de la salud y reducir la carga sobre los servicios de salud urbanos.

2.1.4.2. Objetivos

1. Mejorar el acceso a servicios médicos.
2. Proporcionar asistencia médica básica.
3. Incrementar la eficiencia del sistema de salud.
4. Fomentar la educación en salud.
5. Implementar tecnología avanzada.

2.1.4.3. Fundamento Teórico

- **Procesamiento de Lenguaje Natural (NLP):** El NLP permite que los chatbots entiendan y procesen el lenguaje humano. Utilizando algoritmos de NLP, el chatbot puede interpretar las consultas de los usuarios y proporcionar respuestas adecuadas. Esto incluye la identificación de síntomas y la recomendación de tratamientos básicos.

- **Arquitectura Sin Servidor:** La aplicación se basa en una arquitectura sin servidor utilizando servicios como Heroku y Firebase. Esto permite una fácil escalabilidad y una gestión eficiente de los recursos, reduciendo la necesidad de infraestructura física.
- **Dialogflow:** Esta herramienta se utiliza para desarrollar interfaces conversacionales que soportan la interacción en lenguaje natural. Dialogflow permite la creación de agentes que pueden comprender y responder a las consultas de los usuarios, facilitando una interacción fluida y eficiente.
- **Flask y Flutter:** Flask se utiliza como marco web para el desarrollo del backend, mientras que Flutter se emplea para la creación de la interfaz de usuario de la aplicación móvil. Estas herramientas permiten una integración efectiva y una experiencia de usuario intuitiva.
- **Algoritmos de Aprendizaje Automático:** Se utilizan algoritmos como Naive Bayes y árboles de decisión para clasificar las consultas de los usuarios y proporcionar respuestas precisas. Estos algoritmos permiten al chatbot aprender y mejorar continuamente a medida que interactúa con más usuarios

2.1.4.4. Metodología empleada por los autores

1. Análisis de Requisitos:

Se realizó un análisis detallado de las necesidades de los usuarios, especialmente en áreas rurales, para diseñar un sistema que sea accesible y fácil de usar.

2. Diseño de la Arquitectura:

La aplicación se construyó sobre una arquitectura sin servidor utilizando Heroku y Firebase, lo que permite una fácil escalabilidad y reduce la necesidad de infraestructura física.

3. Desarrollo del Chatbot:

Se utilizó Dialogflow para crear un agente conversacional que puede manejar entradas de voz y texto. El chatbot utiliza NLP para interpretar las consultas de los usuarios y proporcionar respuestas adecuadas.

4. Entrenamiento del Modelo:

Se entrenaron modelos de NLP para reconocer y entender diversas consultas de salud. Estos modelos se alimentaron con datos relevantes para mejorar su precisión en la identificación de síntomas y la provisión de consejos médicos.

5. Integración de APIs:

Se integraron varias APIs, como la API de DrugBank para información sobre medicamentos y la API de Practo para datos de médicos. Esto permite al chatbot proporcionar información precisa y relevante sobre tratamientos y profesionales de la salud.

6. Desarrollo de la Aplicación Móvil:

Se utilizó Flutter para desarrollar la aplicación móvil, lo que permite una interfaz de usuario intuitiva y una experiencia de usuario fluida. La aplicación está diseñada para ser utilizada en dispositivos Android.

7. Implementación de Funcionalidades de Desconexión:

Dado que muchas áreas rurales tienen acceso limitado a Internet, se implementaron funcionalidades de comunicación fuera de línea utilizando Twilio. Esto permite a los usuarios interactuar con el chatbot a través de mensajes de texto y llamadas telefónicas, incluso sin una conexión a Internet.

8. Pruebas y Evaluación:

La aplicación se sometió a pruebas exhaustivas para asegurar su funcionalidad y precisión. Se realizaron pruebas de usuario para ajustar la interfaz y mejorar la experiencia del usuario. Además, se evaluó la precisión de las respuestas del chatbot mediante la comparación con respuestas proporcionadas por profesionales de la salud.

9. Despliegue y Mantenimiento:

El sistema se desplegó en la infraestructura de Heroku y Firebase, asegurando su disponibilidad y accesibilidad. Se implementó un sistema de monitoreo continuo para mantener la calidad del servicio y realizar mejoras basadas en el feedback de los usuarios.

2.1.4.5. Resultados obtenidos

Los resultados presentados en el estudio muestran que el chatbot es capaz de proporcionar información médica precisa y útil a los usuarios rurales, mejorando significativamente el acceso a servicios médicos básicos. La aplicación ha sido bien recibida por los usuarios, con una alta tasa de interacción y satisfacción. El análisis de las sesiones de usuario indica que el chatbot maneja eficazmente una variedad de consultas médicas, proporcionando respuestas rápidas y relevantes. Los usuarios han utilizado principalmente el chatbot para consultas sobre síntomas comunes, medicación y recomendaciones de primeros auxilios. Además, la capacidad del chatbot para operar sin conexión constante a internet ha sido un factor crucial en su aceptación y uso en áreas rurales con infraestructura limitada de internet.

INTENT	SESSIONS	COUNT	EXIT%
FIND DOCTOR	10	52	1.92
FIND DOCTOR-CUSTOM	8	48	18.75
SMALLTALK.GREETINGS.HELLO	6	22	18.18
WEATHER	5	16	12.50
FEVER	4	12	8.33
FIND HOSPITAL	5	11	2.5
FIND HOSPITAL-CUSTOM	4	9	22.22
WEATHER-CUSTOM	2	9	8.9
DIABETES	3	7	2.1

Figura 2.8: Metodología. Fuente: CITAR AL FINAL

2.1.5. HHH: An Online Medical Chatbot System based on Knowledge Graph and Hierarchical Bi-Directional Attention

2.1.5.1. Planteamiento del Problema y objetivo

El artículo "HHH: An Online Medical Chatbot System based on Knowledge Graph and Hierarchical Bi-Directional Attention.^aborda los problemas que enfrentan los pacientes para acceder a servicios de atención primaria, como la dificultad para ver a un médico, largos tiempos de espera y la inconveniencia de hacer citas. Para abordar estos desafíos, los autores proponen un sistema de chatbot médico que combina un grafo de conocimiento con un modelo de atención bidireccional jerárquico (HBAM). El chatbot, denominado HHH (Healthcare Helper System), está diseñado para responder preguntas médicas complejas utilizando un grafo de conocimiento construido a partir de datos médicos recopilados de Internet y un modelo de similitud de texto basado en aprendizaje profundo. Este enfoque híbrido permite al chatbot comprender y responder preguntas en lenguaje natural, proporcionando respuestas precisas y relevantes a los usuarios con poco conocimiento médico. El objetivo principal es mejorar la eficiencia y calidad del servicio médico, facilitando el acceso a información médica y reduciendo el desperdicio de recursos.

2.1.5.2. Objetivos

- Reducir el desperdicio de recursos y tiempo.
- Proveer respuestas precisas a usuarios sin conocimientos especializados.

- Facilitar la gestión y extensión del sistema.

2.1.5.3. Fundamento Teórico

El fundamento teórico del trabajo se basa en la combinación de dos enfoques: el uso de un grafo de conocimiento y un modelo de atención jerárquico bidireccional (HBAM) para procesar y responder preguntas en el contexto médico.

- **Grafo de Conocimiento:** Un grafo de conocimiento es una estructura de datos que representa información en forma de entidades y las relaciones entre ellas. En este sistema, el grafo de conocimiento almacena información médica, incluyendo enfermedades, síntomas, tratamientos y relaciones entre estos conceptos. Este enfoque es útil para proporcionar respuestas rápidas y precisas a preguntas bien definidas, aprovechando la estructura organizada y fácilmente consultable del grafo.
- **Modelo de Atención Jerárquico Bidireccional (HBAM):** Este modelo es una extensión de los modelos LSTM (Long Short-Term Memory), que son una clase de redes neuronales recurrentes (RNN) diseñadas para procesar secuencias de datos. El HBAM incluye una capa de BiLSTM que captura información de contexto en ambas direcciones (hacia adelante y hacia atrás) y una capa de atención que resalta las palabras clave en una oración. Esto permite al modelo comprender mejor el significado semántico de las preguntas y encontrar respuestas relevantes en una gran base de datos de preguntas y respuestas médicas. La combinación de la capa de BiLSTM y la capa de atención mejora la precisión del modelo al identificar la similitud entre preguntas.
- **Siamese Framework y Distancia Manhattan:** El modelo utiliza un enfoque de redes siamés, donde dos redes idénticas comparten los mismos pesos para procesar dos entradas diferentes y comparar sus representaciones. La distancia Manhattan se utiliza para medir la similitud semántica entre las representaciones de las oraciones, lo que permite identificar preguntas similares en la base de datos y proporcionar respuestas precisas.

El uso combinado de estos enfoques permite al sistema HHH manejar una amplia variedad de preguntas médicas, proporcionando respuestas tanto desde un grafo de conocimiento como utilizando modelos de aprendizaje profundo para comparar y entender la semántica de las consultas en lenguaje natural.

2.1.5.4. Metodología empleada por los autores

La metodología adoptada para el desarrollo del sistema HHH incluye varios componentes y pasos clave para garantizar su efectividad y precisión:

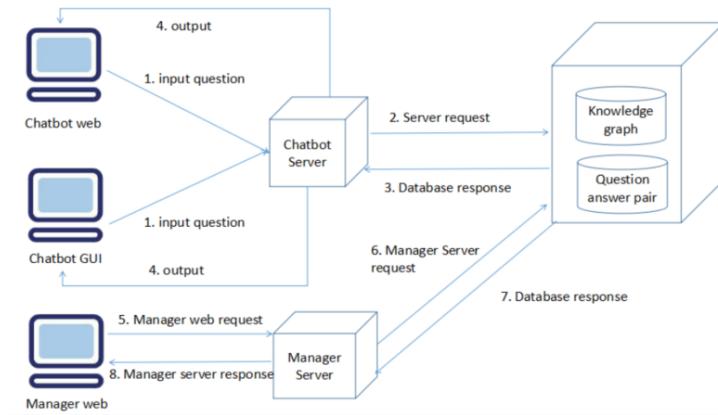


Figura 2.9: Metodología. Fuente: CITAR AL FINAL

1. Diseño de la Arquitectura del Sistema:

Arquitectura del Gráfico de Conocimiento: Se desarrolló utilizando Neo4j, que almacena datos sobre enfermedades, síntomas y tratamientos. El gráfico contiene 3,500 entidades y 4,500 relaciones.

Modelo HBAM: Incluye una capa de LSTM bidireccional y una capa de atención de palabras, diseñada para comparar la similitud semántica entre preguntas y respuestas en el dataset.

2. Implementación del Gráfico de Conocimiento:

Almacenamiento y Recuperación de Datos: El gráfico de conocimiento se construyó a partir de datos médicos recopilados de diversas fuentes en línea. El proceso de selección de respuestas implica la extracción de entidades relevantes y la identificación de la intención del usuario.

Extracción de Entidades y Reconocimiento de Intenciones: Utiliza el algoritmo Aho-Corasick para identificar entidades médicas en las preguntas de los usuarios y un módulo de reconocimiento de intenciones para predecir la intención del usuario basada en bibliotecas de predicados predefinidos.

3. Desarrollo del Modelo HBAM:

Entrenamiento y Pruebas: El modelo se entrenó utilizando un subconjunto del dataset de preguntas duplicadas de Quora, que contiene pares de preguntas y respuestas

médicas. Se utilizó una capa de LSTM bidireccional para capturar la información contextual y una capa de atención para resaltar las palabras clave en las preguntas.

Evaluación del Modelo: Se comparó el rendimiento del HBAM con otros modelos de vanguardia como BERT y MaLSTM. Los resultados mostraron que HBAM tiene un mejor rendimiento en términos de precisión en la similitud semántica.

4. Integración de la Interfaz de Usuario:

Interfaz Web y GUI Local: Se desarrollaron para permitir la interacción del usuario con el chatbot. La interfaz web facilita el acceso remoto, mientras que la GUI local proporciona una experiencia de usuario enriquecida.

5. Pruebas y Evaluación del Sistema:

Pruebas de Usuario: Se realizaron pruebas exhaustivas para asegurar la funcionalidad y precisión del sistema. Los usuarios interactuaron con el chatbot para evaluar la calidad de las respuestas y la facilidad de uso de la interfaz.

6. Despliegue y Mantenimiento:

Implementación en Entornos Reales: El sistema se desplegó en entornos de producción para evaluar su rendimiento en situaciones reales. Se implementó un sistema de monitoreo continuo para mantener la calidad del servicio y realizar mejoras basadas en el feedback de los usuarios.

2.1.5.5. Resultados obtenidos

Los resultados obtenidos muestran que el modelo HBAM supera a otros modelos de última generación en términos de precisión en la predicción de la similitud de oraciones médicas. En los experimentos realizados, el HBAM logró una precisión promedio del 81.2 %, comparado con el 78.2 % de BERT y el 78.4 % de MaLSTM. Estos resultados indican que el HBAM es más efectivo en la comprensión de consultas médicas y la provisión de respuestas precisas.

Además, el sistema HHH demostró ser capaz de manejar una variedad de preguntas médicas, proporcionando respuestas precisas y relevantes tanto desde el grafo de conocimiento como mediante la comparación de similitud de texto. Los experimentos adicionales realizados con conjuntos de datos médicos adicionales confirmaron la robustez y flexibilidad del modelo HBAM, mostrando un rendimiento consistente en diferentes escenarios de prueba.

Methods	Average Evaluation Accuracy	Range of change by 30 times experiments
BERT [7]	78.2%	(-1.8%,+1.3%)
MaLSTM [9]	78.4%	(-2.9%,+2.0%)
HBAM	81.2%	(-2.4%,+2.2%)

Figura 2.10: Metodología. Fuente: CITAR AL FINAL

Medical website name	Method name	Average predict accuracy	Range of change by 10 times experiments
ehealthforumQAs	BERT	78.5%	(-1.8%,+1.1%)
	HBAM	81.3%	(-1.2%,+1.1%)
	MaLSTM	78.4%	(-2.9%,+1.5%)
questionDoctorQAs	BERT	78.2%	(-1.4%,+0.9%)
	HBAM	80.9%	(-2.1%,+2.5%)
	MaLSTM	78.1%	(-1.7%,+1.9%)
webmdQAs	BERT	78.1%	(-1.6%,+0.9%)
	HBAM	81.2%	(-1.2%,+1.3%)
	MaLSTM	78.5%	(-1.5%,+1.9%)

Figura 2.11: Metodología. Fuente: CITAR AL FINAL

2.1.6. HealFavor: Dataset and A Prototype System for Healthcare Chat-Bot

2.1.6.1. Planteamiento del Problema y objetivo

El acceso a servicios médicos puede ser difícil debido a varios factores, como la escasez de médicos, largos tiempos de espera y la inconveniencia de hacer citas. Estas barreras afectan tanto a pacientes como a proveedores de servicios de salud, resultando en un uso ineficiente de los recursos disponibles. En respuesta a estos desafíos, se han desarrollado sistemas innovadores como los chatbots médicos basados en inteligencia artificial. Estos sistemas tienen el potencial de simular conversaciones en tiempo real, proporcionando asistencia médica interactiva y personalizada. El trabajo presentado propone el desarrollo de un chatbot médico llamado HealFavor, que utiliza un conjunto de datos autogenerado y una arquitectura prototípica para mejorar la accesibilidad médica y proporcionar respuestas precisas a consultas médicas comunes.

2.1.6.2. Objetivos

- Mejorar el acceso a servicios médicos.
- Proveer asistencia médica básica.
- Incrementar la eficiencia del sistema de salud.

- Fomentar la educación en salud.
- Implementar tecnología avanzada.

2.1.6.3. Fundamento Teórico

El fundamento teórico del sistema de chatbot HealFavor se basa en la integración de técnicas avanzadas de inteligencia artificial y procesamiento de lenguaje natural (NLP). Estos enfoques permiten al sistema comprender y responder a consultas médicas en lenguaje natural, proporcionando respuestas precisas y relevantes.

- **Sistemas de Chatbot Históricos y Contemporáneos** El desarrollo de chatbots se remonta a sistemas pioneros como ELIZA, desarrollado en la década de 1960, que utilizaba patrones de scripts codificados para simular conversaciones. ALICE, que utilizaba patrones basados en el lenguaje de marcado de inteligencia artificial (AIML), mejoró esta capacidad al almacenar respuestas en archivos AIML. Sistemas más recientes como Jabberwacky y Cleverbot no solo utilizan respuestas preprogramadas, sino que también aprenden de las interacciones pasadas para mejorar sus respuestas
- **Arquitectura del Sistema:** La aplicación HealFavor se basa en el marco de RASA, utilizando políticas de diálogo embebidas recurrentes para la generación de respuestas. La integración con MongoDB permite el almacenamiento en tiempo real de historiales de chat y análisis de informes médicos, facilitando un sistema escalable y eficiente.

2.1.6.4. Metodología empleada por los autores

La metodología adoptada para el desarrollo del sistema HHH incluye varios componentes y pasos clave para garantizar su efectividad y precisión:

1. Preparación de Datos:

Fuentes y Observaciones: Los datos se recopilaron de fuentes confiables como WebMD y Drugs.com, y se consultó con expertos médicos para obtener información sobre síntomas comunes.

Calidad y Filtrado: Los datos preparados se verificaron para asegurar su consistencia y relevancia. Se realizaron grandes clasificaciones iniciales para abarcar un amplio conjunto de enfermedades y luego se refinaron según síntomas específicos.

2. Preprocesamiento de Datos:

Técnicas Utilizadas: Incluyen conversión a minúsculas, eliminación de palabras vacías, tokenización y lematización para mejorar la clasificación y precisión de los datos.

3. Representación de Datos:

Clasificación de Intenciones: Se desarrollaron módulos para clasificar las intenciones de los pacientes como un problema de clasificación múltiple. Las secuencias de intenciones se utilizaron para predecir las respuestas y continuar la conversación.

Predicción de Secuencias: Se prepararon conjuntos exhaustivos de secuencias para diferentes casos de uso de pacientes, incluyendo preguntas relacionadas con la salud y la reserva de citas.

4. Arquitectura del Sistema Prototipo:

Marco RASA: Utiliza políticas de diálogo embebidas recurrentes inspiradas en el algoritmo StarSpace de Facebook AI Research. Se crean vectores de características utilizando la representación de Bag of Words (BoW) y se generan incrustaciones a través de capas densas para la entrada del paciente y las acciones del sistema.

Mecanismo de Atención: El input del usuario y el output previo de la red se alimentan en un modelo recurrente para calcular la atención, utilizando la suma total del output de la capa de incrustación y del mecanismo de atención para generar la respuesta final.

5. Evaluación del Sistema:

Pruebas de Usuario: Se realizaron pruebas exhaustivas con evaluadores que hicieron un total de 162 preguntas al sistema. Las respuestas se calificaron en una escala de 1 a 3, obteniendo una precisión total del 46.50 %.

6. Despliegue y Mantenimiento:

Implementación en Entornos Reales: El sistema se desplegó utilizando el marco de RASA y MongoDB, asegurando su disponibilidad y accesibilidad en tiempo real. Se implementó un sistema de monitoreo continuo para mantener la calidad del servicio y realizar mejoras basadas en el feedback de los usuarios.

2.1.6.5. Resultados obtenidos

El sistema de chatbot HealFavor ha demostrado ser efectivo en la provisión de respuestas precisas y relevantes a preguntas médicas comunes. Los resultados de las pruebas de usuario

mostraron una alta satisfacción con la precisión de las respuestas y la facilidad de uso de la interfaz. El sistema alcanzó una precisión del 46.50 % en la clasificación de respuestas correctas, lo que indica una mejora significativa en la accesibilidad médica y la eficiencia del sistema de salud. La integración con MongoDB permitió el almacenamiento en tiempo real de historiales de chat y análisis de informes médicos, facilitando un sistema escalable y eficiente.

2.1.7. ChatDoctor: A Medical Chat Model Fine-Tuned on a Large Language Model Meta-AI (LLaMA) Using Medical Domain Knowledge

2.1.7.1. Planteamiento del Problema y objetivo

El acceso a consultas médicas precisas y oportunas sigue siendo un desafío significativo, especialmente en regiones con recursos médicos limitados. Los modelos de lenguaje grandes (LLMs) como ChatGPT han demostrado capacidades impresionantes en tareas generales de procesamiento del lenguaje natural (NLP), pero su rendimiento en el dominio médico es limitado debido a la falta de entrenamiento específico en conocimientos médicos. Esto puede resultar en respuestas incorrectas que pueden ser perjudiciales en un contexto médico. Para abordar esta limitación, se desarrolló el modelo ChatDoctor, afinado específicamente en el conocimiento del dominio médico utilizando el modelo LLaMA. Este modelo busca mejorar la precisión y relevancia de las respuestas médicas, proporcionando así un apoyo más fiable y accesible para los pacientes y profesionales de la salud.

2.1.7.2. Objetivos

- Mejorar la precisión en las respuestas médicas.
- Desarrollar una base de conocimiento externa.
- Proporcionar acceso a información médica actualizada.
- Evaluar el rendimiento del modelo.

2.1.7.3. Fundamento Teórico

El desarrollo de ChatDoctor se basa en varios principios teóricos y tecnológicos clave:

- **Modelo de Lenguaje Grande (LLM):** Los LLMs como LLaMA se entrena inicialmente en grandes cantidades de datos textuales para predecir la siguiente palabra en una secuencia, desarrollando así habilidades generales de lenguaje. Estos modelos luego se afinan utilizando conjuntos de datos específicos del dominio para mejorar su rendimiento en tareas especializadas.
- **Afine del Modelo con Datos Específicos del Dominio:** ChatDoctor se afina utilizando un conjunto de datos de 100,000 conversaciones médico-paciente reales recopiladas de una plataforma de consulta médica en línea. Este enfoque asegura que el modelo desarrolle una comprensión profunda de las consultas y respuestas médicas auténticas.
- **Recuperación Autónoma de Información:** Para mitigar las limitaciones inherentes a los LLMs, como las respuestas erróneas, se incorpora una base de conocimientos externos que el modelo puede consultar en tiempo real. Esta base de conocimientos incluye bases de datos médicas confiables y recursos en línea como Wikipedia. La recuperación de información se realiza a través de prompts configurados que extraen términos clave de las consultas del paciente y buscan la información relevante en la base de conocimientos.
- **Evaluación de Rendimiento:** El rendimiento de ChatDoctor se evalúa utilizando métricas estándar como precisión, recuerdo y puntuación F1, comparándolo con otros modelos como ChatGPT. Estas evaluaciones se realizan utilizando respuestas de médicos humanos como referencia para garantizar la relevancia y exactitud de las respuestas generadas por el modelo.

2.1.7.4. Metodología empleada por los autores

La metodología adoptada para el desarrollo del sistema HHH incluye varios componentes y pasos clave para garantizar su efectividad y precisión:

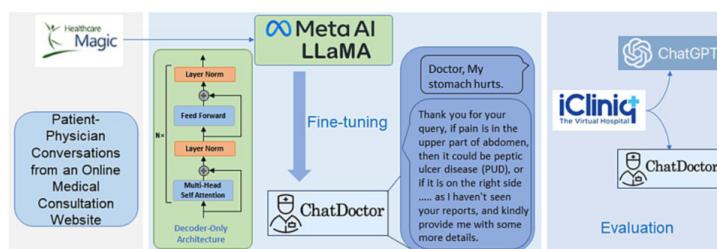


Figura 2.12: Metodología. Fuente: CITAR AL FINAL

1. Recolección y Preparación de Datos:

Dataset de Conversaciones Médico-Paciente: Se recopilaron alrededor de 100,000 interacciones médico-paciente de la plataforma HealthCareMagic. Estas conversaciones se limpiaron y anonimizaron para respetar la privacidad de los participantes.

Filtrado de Conversaciones: Se eliminaron automáticamente las conversaciones demasiado cortas y se filtraron manualmente las respuestas con errores. Se utilizó LanguageTool para corregir errores gramaticales y asegurar la calidad de los datos.

Dataset de Pruebas: Se recopilaron alrededor de 10,000 conversaciones adicionales de iCliniq para probar el rendimiento del modelo.

2. Desarrollo de la Base de Conocimientos Externa:

Curación de la Base de Datos: Se creó una base de datos que incluye enfermedades, síntomas, pruebas médicas y tratamientos utilizando fuentes confiables como Medline-Plus. Esta base de datos es actualizable continuamente sin necesidad de reentrenamiento del modelo.

Recuperación de Información: Se diseñaron prompts específicos para extraer términos clave de las consultas del paciente y buscar información relevante en la base de conocimientos. Este proceso asegura respuestas precisas y respaldadas por fuentes confiables.

3. Entrenamiento del Modelo:

Modelo LLaMA: Se utilizó el modelo LLaMA de Meta, entrenado en 1.0 billón de tokens de fuentes de datos públicas. Este modelo fue afinado primero con datos del proyecto Alpaca de Stanford y luego con el dataset HealthCareMagic-100k utilizando 6 GPUs A100 durante tres horas.

Parámetros de Entrenamiento: Los parámetros incluyeron un tamaño de batch total de 192, una tasa de aprendizaje, 3 épocas, una longitud máxima de secuencia de 512 tokens y una proporción de calentamiento de 0.03, sin decaimiento de peso.

4. Evaluación del Modelo:

Pruebas de Rendimiento: Se utilizaron preguntas del dataset iCliniq como entradas y las respuestas de médicos humanos como referencia. Se empleó BERTScore para evaluar la precisión, el recuerdo y la puntuación F1 de las respuestas generadas por ChatDoctor en comparación con ChatGPT.

Comparaciones Cualitativas: Se realizaron comparaciones detalladas entre las respuestas de ChatDoctor y ChatGPT en términos de precisión y relevancia para diversas consultas médicas contemporáneas.

2.1.7.5. Resultados obtenidos

El modelo ChatDoctor mostró un rendimiento superior en la provisión de respuestas médicas precisas y relevantes en comparación con ChatGPT. En pruebas cualitativas, ChatDoctor fue capaz de responder correctamente a preguntas sobre términos médicos recientes como Monkeypox y medicamentos aprobados recientemente como Daybue, gracias a su capacidad de recuperación autónoma de información. En evaluaciones cuantitativas utilizando BERTS-core, ChatDoctor superó a ChatGPT en precisión, recuerdo y puntuación F1, demostrando su efectividad en proporcionar respuestas médicas fiables. Estas mejoras subrayan el potencial de ChatDoctor para asistir en consultas médicas preliminares y mejorar la accesibilidad a la información médica precisa.

	ChatGPT	ChatDoctor	P-value
Precision	0.837±0.0188	0.8444±0.0185	6.66×10^{-96}
Recall	0.8445±0.0164	0.8451±0.0157	4.71×10^{-4}
F1 Score	0.8406±0.0143	0.8446±0.0138	2.14×10^{-111}

Figura 2.13: Metodología. Fuente: CITAR AL FINAL

2.1.8. Auto Response Generation in Online Medical Chat Services

2.1.8.1. Planteamiento del Problema y objetivo

El acceso a servicios médicos de calidad y la eficiencia en la comunicación entre médicos y pacientes son desafíos significativos en el campo de la telemedicina. Con el aumento de la demanda de consultas médicas en línea debido a la pandemia de COVID-19 y otros factores, los profesionales de la salud enfrentan una carga de trabajo elevada que puede afectar la calidad de la atención médica. En respuesta a este problema, el estudio propone un mecanismo de generación de respuestas automáticas inteligentes para servicios de chat médico en línea, con el objetivo de mejorar la eficiencia de las interacciones entre médicos y pacientes y reducir los tiempos de espera. Este mecanismo se basa en algoritmos de aprendizaje automático y procesamiento de lenguaje natural para identificar y generar respuestas adecuadas a las consultas de los pacientes, mejorando así la experiencia general del usuario y la efectividad del servicio de telemedicina.

2.1.8.2. Objetivos

- Mejorar la eficiencia de las interacciones médicas en línea.

- Aumentar la precisión de las respuestas médicas.
- Facilitar el acceso a la atención médica.
- Optimizar el uso de recursos médicos.
- Evaluar la efectividad del sistema.

2.1.8.3. Fundamento Teórico

El desarrollo del sistema de generación de respuestas automáticas inteligentes se basa en varias tecnologías y teorías clave:

- **Procesamiento de Lenguaje Natural (NLP):** El NLP permite que las máquinas comprendan e interpreten el lenguaje humano de manera efectiva. En este estudio, se utilizan técnicas de NLP para analizar y procesar las consultas de los pacientes, permitiendo la generación de respuestas adecuadas basadas en la comprensión del contexto y la semántica del texto.
- **Modelos de Aprendizaje Automático:** Se emplean varios algoritmos de aprendizaje automático, incluyendo BERT, BiLSTM, y XGBoost, para entrenar el sistema con un gran conjunto de datos de conversaciones médicas. Estos modelos aprenden a identificar patrones y generar respuestas basadas en el historial de interacciones médicas.
- **Clustering y Filtrado de Datos:** Se utilizan algoritmos de clustering para agrupar respuestas médicas similares y etiquetar manualmente los datos, creando un conjunto de respuestas prediseñadas que el sistema puede utilizar. Este enfoque asegura que las respuestas generadas sean coherentes y relevantes para las consultas de los pacientes.
- **Evaluación y Mejora Continua:** El rendimiento del sistema se evalúa mediante métricas estándar como precisión, recuerdo y puntuación F1, comparando las respuestas generadas con las respuestas proporcionadas por médicos humanos. Este proceso de evaluación permite identificar áreas de mejora y ajustar los modelos para mejorar la precisión y relevancia de las respuestas.

2.1.8.4. Metodología empleada por los autores

La metodología empleada para desarrollar el sistema de generación de respuestas automáticas inteligentes incluye varias etapas clave:

1. Recolección y Preparación de Datos:

Dataset de Conversaciones Médico-Paciente: Se recopilaron más de 900,000 mensajes históricos entre médicos y pacientes a lo largo de 9 meses. Estos datos se anonimizaron y se prepararon para el análisis.

Filtrado de Datos: Se aplicaron técnicas de limpieza de datos para corregir errores ortográficos, mal uso de puntuación y errores gramaticales, asegurando la calidad del dataset.

2. Creación de un Conjunto de Respuestas Prediseñadas:

Clustering de Respuestas Médicas: Se implementaron algoritmos de clustering para identificar las respuestas más frecuentes de los médicos y etiquetar los datos manualmente. Se crearon clusters semánticos para agrupar respuestas similares y se seleccionaron los clusters más densos para su uso en el sistema.

3. Desarrollo del Modelo de Filtrado (Triggering Model):

Modelo de Clasificación Binaria: Se desarrolló un modelo de clasificación binaria para filtrar los mensajes de los pacientes y determinar si requieren una respuesta automática. Este modelo se entrenó utilizando técnicas de embedding ponderado y algoritmos como BERT y BiLSTM.

4. Generación de Respuestas:

Modelo de Generación de Respuestas: Se desarrollaron varios modelos de generación de respuestas, incluyendo BERT y Seq2Seq, para sugerir las respuestas más adecuadas a las consultas de los pacientes que pasaron el filtro de triggering. Estos modelos se entrenaron utilizando el conjunto de datos preprocesado y se ajustaron para maximizar la precisión y relevancia de las respuestas generadas.

5. Evaluación del Sistema:

Pruebas de Rendimiento: Se realizaron pruebas exhaustivas para evaluar la precisión, el recuerdo y la puntuación F1 de las respuestas generadas. Se utilizó un enfoque de validación cruzada de 5 pliegues para asegurar la robustez del modelo y evitar el sobreajuste.

Comparación con Baselines: Se comparó el rendimiento de los modelos desarrollados con enfoques basados en reglas y otros algoritmos de aprendizaje automático, demostrando la efectividad del enfoque propuesto.

2.1.8.5. Resultados obtenidos

El sistema de generación de respuestas automáticas inteligentes demostró ser altamente efectivo en la provisión de respuestas precisas y relevantes a consultas médicas en línea. Los modelos basados en BERT superaron significativamente a otros algoritmos en términos de precisión y recuerdo, con una precisión@3 de 85.41 %. La integración de técnicas de NLP y aprendizaje automático permitió generar respuestas coherentes y útiles en tiempo real, mejorando la eficiencia de las interacciones médico-paciente. Los resultados indican que el sistema puede manejar eficazmente una gran cantidad de consultas simultáneas, reduciendo la carga de trabajo de los médicos y mejorando la satisfacción de los pacientes.

370

Journal of Healthcare Informatics Research (2022) 6:344–374

Table 4 Summary performance values for the triggering and response generation model combinations to create an end-to-end pipeline

Triggering Model	Response Generation Model	Precision@3	Triggering Model	Precision@3	Response Generation Model	Precision@3
BERT	BERT	85.42 ± 0.82	LSTM	85.58 ± 0.42	BERT	85.58 ± 0.42
BERT	LSTM	82.79 ± 0.81	LSTM	83.28 ± 0.75	LSTM	83.28 ± 0.75
BERT	Seq2seq	60.22 ± 1.80	LSTM	61.56 ± 0.08	Seq2seq	61.56 ± 0.08
BERT	XGBoost	80.89 ± 1.07	LSTM	81.92 ± 0.57	XGBoost	81.92 ± 0.57
BERT	SVM	81.11 ± 1.23	LSTM	82.03 ± 0.66	SVM	82.03 ± 0.66
BERT	Weighted-TFIDF	49.73 ± 4.03	LSTM	51.63 ± 2.27	Weighted-TFIDF	51.63 ± 2.27
BERT	TFIDF	50.33 ± 2.22	LSTM	52.13 ± 2.90	TFIDF	52.13 ± 2.90
BERT	Frequency	46.32 ± 1.82	LSTM	48.18 ± 1.24	Frequency	48.18 ± 1.24
BERT	BERT	83.61 ± 0.41	SVM	83.00 ± 0.39	BERT	83.00 ± 0.39
XGBoost	XGBoost	81.37 ± 0.66	SVM	80.68 ± 1.62	LSTM	80.68 ± 1.62
XGBoost	Seq2seq	59.32 ± 1.27	SVM	58.59 ± 4.19	Seq2seq	58.59 ± 4.19
XGBoost	XGBoost	79.60 ± 0.52	SVM	78.83 ± 0.48	XGBoost	78.83 ± 0.48
XGBoost	SVM	79.81 ± 0.57	SVM	78.98 ± 0.49	Weighted-TFIDF	78.98 ± 0.49
XGBoost	Weighted-TFIDF	48.85 ± 3.42	SVM	47.79 ± 3.30	Weighted-TFIDF	47.79 ± 3.30
XGBoost	TFIDF	49.45 ± 2.48	SVM	48.41 ± 2.41	TFIDF	48.41 ± 2.41
XGBoost	Frequency	49.61 ± 0.63	SVM	44.51 ± 0.46	Frequency	44.51 ± 0.46
Weighted-TFIDF	BERT	73.31 ± 0.96	TFIDF	73.2 ± 1.66	BERT	73.2 ± 1.66
Weighted-TFIDF	LSTM	74.45 ± 0.91	TFIDF	71.28 ± 1.72	LSTM	71.28 ± 1.72
Weighted-TFIDF	Seq2seq	52.34 ± 3.12	TFIDF	52.09 ± 3.31	Seq2seq	52.09 ± 3.31
Weighted-TFIDF	XGBoost	69.96 ± 0.87	TFIDF	69.75 ± 1.68	XGBoost	69.75 ± 1.68
Weighted-TFIDF	SVM	70.14 ± 0.78	TFIDF	69.90 ± 0.56	SVM	69.90 ± 0.56
Weighted-TFIDF	Weighted-TFIDF	46.46 ± 2.97	TFIDF	45.38 ± 2.90	Weighted-TFIDF	45.38 ± 2.90
Weighted-TFIDF	TFIDF	44.44 ± 2.20	TFIDF	44.35 ± 2.28	TFIDF	44.35 ± 2.28
Weighted-TFIDF	Frequency	42.24 ± 0.74	TFIDF	40.93 ± 0.70	Frequency	40.93 ± 0.70

Springer

Figura 2.14: Metodología. Fuente: CITAR AL FINAL

2.1.9. An Approach to Medical Diagnosis Using Smart Chatbot

2.1.9.1. Planteamiento del Problema y objetivo

El acceso a diagnósticos médicos precisos y accesibles es un desafío significativo, especialmente en áreas con recursos médicos limitados. Las visitas hospitalarias para asuntos menores a menudo se evitan, lo que puede llevar a problemas de salud más graves en el futuro. Para abordar esta situación, se propone el desarrollo de un chatbot médico llamado DiagZone, diseñado para proporcionar diagnósticos rápidos y fiables de manera remota y accesible desde cualquier lugar. Utilizando tecnologías como AWS Lex, AWS Lambda y Twilio, DiagZone integra procesamiento de lenguaje natural (NLP) para analizar las consultas de los usuarios, identificar posibles enfermedades y sugerir medidas correctivas o remitir al usuario a un médico si es necesario. Este enfoque pretende mejorar la eficiencia del diagnóstico médico, reducir la carga de trabajo de los especialistas y ofrecer una solución accesible y gratuita para el monitoreo de la salud.

2.1.9.2. Objetivos

- Proporcionar diagnósticos médicos accesibles y precisos.
- Mejorar la eficiencia de la atención médica.
- Fomentar el uso de tecnología en la salud.
- Aumentar la accesibilidad a servicios médicos.

2.1.9.3. Fundamento Teórico

El desarrollo de DiagZone se basa en varios principios teóricos y tecnológicos clave:

- **Procesamiento de Lenguaje Natural (NLP):** Utiliza técnicas de NLP para analizar y comprender las consultas de los usuarios, permitiendo una interacción más humana y precisa. Herramientas como Python NLTK son empleadas para analizar el habla y generar respuestas inteligentes.
- **Modelos de Aprendizaje Automático:** Se entrena modelo como AWS Lex con datos médicos para mejorar su capacidad de diagnóstico. Estos modelos son capaces de reconocer patrones en las consultas de los usuarios y generar respuestas basadas en un conjunto de datos predefinido.

- **Integración de Servicios en la Nube:** AWS Lambda y Twilio se utilizan para integrar el chatbot con plataformas de mensajería como WhatsApp, permitiendo una comunicación segura y eficiente. Estas tecnologías aseguran que el chatbot pueda manejar grandes volúmenes de consultas de manera rápida y segura.
- **Enfoque en la Seguridad de los Datos:** Se implementan estrictas medidas de seguridad para proteger la información sensible de los usuarios. Twilio proporciona un sistema de prevención de pérdida de datos y Amazon Lex implementa controles técnicos y físicos para prevenir el acceso no autorizado a la información.
- **Accesibilidad y Usabilidad:** El chatbot está diseñado para ser accesible desde cualquier dispositivo con conexión a internet, lo que facilita su uso en diversas situaciones y por diferentes tipos de usuarios. La interfaz intuitiva y la capacidad de interactuar en lenguaje natural mejoran la experiencia del usuario.

2.1.9.4. Metodología empleada por los autores

La metodología para desarrollar DiagZone incluye varias etapas clave:

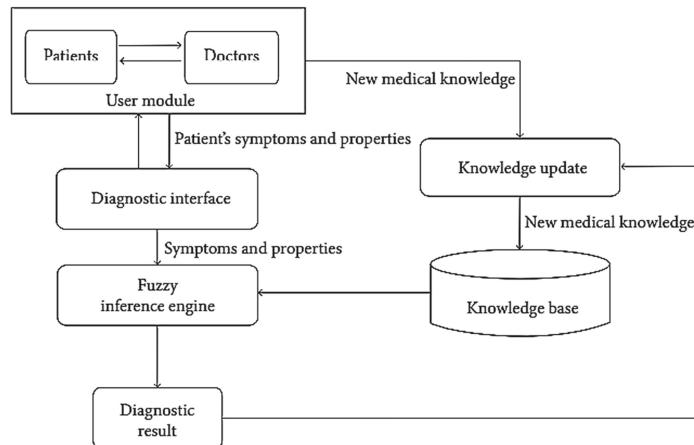


Figura 2.15: Metodología. Fuente: CITAR AL FINAL

1. Recolección y Preparación de Datos:

Dataset de Síntomas: Se recopiló un conjunto de datos de síntomas y enfermedades de diversas fuentes médicas confiables. Este dataset se utiliza para entrenar el modelo de aprendizaje automático.

Limpieza y Preprocesamiento de Datos: Se eliminaron errores ortográficos y gramaticales de los datos recopilados para asegurar su calidad. Se utilizaron técnicas de tokenización y extracción de características para preparar los datos para el análisis.

2. Desarrollo del Modelo de Diagnóstico:

Entrenamiento del Modelo: Utilizando AWS Lex, se entrenó un modelo de lenguaje que puede analizar las consultas de los usuarios y generar diagnósticos basados en los síntomas proporcionados.

Integración con Servicios en la Nube: AWS Lambda y Twilio se integraron para permitir la comunicación segura entre el chatbot y los usuarios a través de WhatsApp. Este sistema permite que el chatbot acceda a una base de datos de conocimiento médico y genere respuestas en tiempo real.

3. Implementación de Medidas de Seguridad:

Protección de Datos: Se implementaron sistemas de prevención de pérdida de datos y encriptación para proteger la información sensible de los usuarios. Twilio asegura que los datos solo sean accesibles por dispositivos autorizados y se sigue el principio de menor privilegio para el acceso a la información.

Auditorías y Cumplimiento: AWS certifica que las medidas de seguridad cumplen con los requisitos legislativos, contractuales y regulatorios necesarios para manejar datos médicos sensibles.

4. Evaluación:

Pruebas de Rendimiento: Se realizaron pruebas exhaustivas para evaluar la precisión y relevancia de los diagnósticos generados por el chatbot. Se utilizó un enfoque de validación cruzada para asegurar la robustez del modelo.

2.1.9.5. Resultados obtenidos

DiagZone demostró ser efectivo en la provisión de diagnósticos médicos precisos y relevantes. En pruebas de rendimiento, el chatbot fue capaz de analizar los síntomas proporcionados por los usuarios y sugerir posibles enfermedades junto con medidas correctivas adecuadas. El sistema también pudo referir a los usuarios a médicos en caso de que los síntomas indicaran una condición más grave. La integración con WhatsApp a través de Twilio permitió una comunicación rápida y segura, mientras que el uso de AWS Lex garantizó respuestas precisas basadas en el análisis de datos de síntomas. Los usuarios reportaron una alta satisfacción con la facilidad de uso y la rapidez de las respuestas proporcionadas por el chatbot.



Figura 2.16: Metodología. Fuente: CITAR AL FINAL

2.1.10. A Medical ChatBot

2.1.10.1. Planteamiento del Problema y objetivo

El acceso a información médica precisa y oportuna es esencial para el bienestar de las personas, pero muchas veces los usuarios no tienen el conocimiento necesario sobre tratamientos o síntomas de enfermedades específicas. Además, las visitas al hospital para problemas menores pueden ser costosas y consumir mucho tiempo, y las consultas telefónicas pueden ser complicadas y no siempre efectivas. Este documento presenta un chatbot médico que utiliza procesamiento de lenguaje natural (NLP) para proporcionar orientación sobre temas de salud de manera inmediata y accesible, sin la necesidad de visitas físicas al hospital. Este sistema no solo pretende ahorrar tiempo y reducir la carga sobre los servicios médicos, sino también ofrecer un recurso educativo para aquellos interesados en mejorar su conocimiento sobre salud y bienestar.

2.1.10.2. Objetivos

- Proporcionar acceso inmediato a información médica confiable.
- Reducir la carga sobre los servicios médicos.
- Mejorar la educación en salud de los usuarios.
- Implementar tecnología avanzada de NLP.
- Fomentar la adopción de tecnologías de salud digitales.

2.1.10.3. Fundamento Teórico

El desarrollo del chatbot médico se fundamenta en varias teorías y tecnologías clave:

- **Procesamiento de Lenguaje Natural (NLP):** El NLP permite a las máquinas comprender e interpretar el lenguaje humano, facilitando la interacción entre el usuario y el chatbot. Técnicas como el etiquetado de partes del discurso y el análisis semántico se utilizan para interpretar correctamente las consultas de los usuarios y generar respuestas adecuadas.
- **Algoritmo de Máquina de Vectores de Soporte (SVM):** El SVM es un potente clasificador que se utiliza para diferenciar entre diferentes clases basándose en los datos de entrenamiento. En el contexto del chatbot médico, el SVM se utiliza para predecir enfermedades basándose en los síntomas proporcionados por los usuarios.

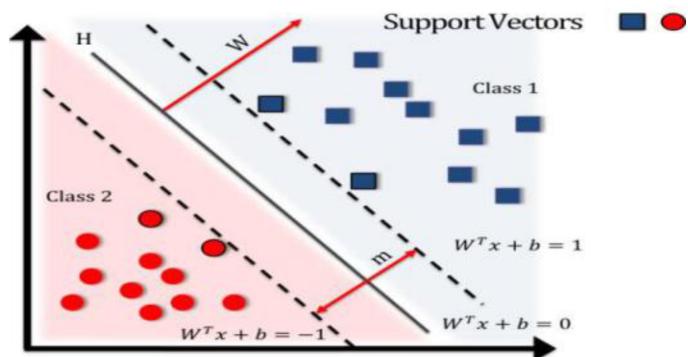


Figura 2.17: Metodología. Fuente: CITAR AL FINAL

- **Similitud de Orden de Palabras:** La similitud de orden de palabras es importante para asegurar que el significado de las oraciones se mantenga coherente. Diferentes órdenes de palabras pueden alterar significativamente el significado de una oración, por lo que este enfoque ayuda a preservar la precisión semántica.
- **Algoritmo de Stemming de Porter:** Este algoritmo se utiliza para reducir las palabras a su raíz o forma base, eliminando sufijos comunes. Esto ayuda a normalizar los datos textuales y mejora la precisión del análisis de NLP.
- **Interfaz de Usuario Gráfica (GUI):** Una GUI eficiente es crucial para facilitar la interacción entre el usuario y el chatbot. La interfaz debe ser intuitiva y proporcionar respuestas en un formato fácil de entender, simulando una conversación humana.

- **APIs de Google:** Las APIs de Google para la conversión de voz a texto y de texto a voz se utilizan para facilitar la comunicación verbal con el chatbot. Esto permite a los usuarios interactuar con el sistema utilizando comandos de voz, mejorando la accesibilidad para personas con discapacidades visuales o dificultades para escribir.

2.1.10.4. Metodología empleada por los autores

La metodología empleada para desarrollar el chatbot médico incluye varias etapas clave:

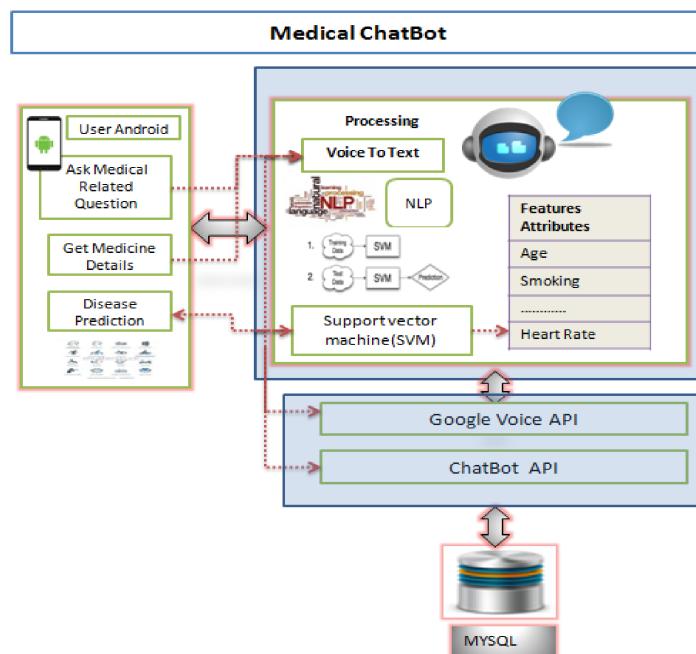


Figura 2.18: Metodología. Fuente: CITAR AL FINAL

1. Recolección y Preparación de Datos:

Dataset de Síntomas y Enfermedades: Se recopiló un conjunto de datos de síntomas y enfermedades de diversas fuentes médicas confiables. Estos datos fueron limpiados y preprocesados para asegurar su calidad y relevancia.

Filtrado de Datos: Se aplicaron técnicas de limpieza de datos para corregir errores ortográficos y gramaticales, así como para eliminar cualquier ruido o datos irrelevantes.

2. Desarrollo del Modelo de Diagnóstico:

Entrenamiento del Modelo SVM: Utilizando los datos preprocesados, se entrenó un modelo de SVM para clasificar y predecir enfermedades basándose en los síntomas

proporcionados por los usuarios. Este modelo fue ajustado para maximizar la precisión y minimizar los errores de clasificación.

Implementación de NLP: Se integraron técnicas de NLP para analizar y comprender las consultas de los usuarios. Esto incluye el uso de algoritmos de stemming, etiquetado de partes del discurso y análisis semántico para interpretar correctamente las entradas de texto.

3. Desarrollo de la Interfaz de Usuario:

Diseño de la GUI: Se diseñó una interfaz gráfica intuitiva y fácil de usar para facilitar la interacción entre los usuarios y el chatbot. La GUI incluye funciones para la entrada de texto y voz, así como para la visualización de respuestas.

Integración con APIs de Google: Las APIs de Google para la conversión de voz a texto y de texto a voz se integraron en el sistema para permitir la comunicación verbal con el chatbot. Esto mejora la accesibilidad y facilita el uso del chatbot por una mayor variedad de usuarios.

4. Implementación de la Similitud de Orden de Palabras:

Cálculo de la Similitud: Se implementaron técnicas para calcular la similitud de orden de palabras entre las consultas de los usuarios y las respuestas almacenadas en la base de datos. Esto ayuda a mantener la coherencia semántica y a generar respuestas precisas.

Optimización del Umbral: Se ajustó el umbral de similitud para equilibrar la precisión y la relevancia de las respuestas generadas. Esto asegura que el chatbot proporcione respuestas útiles y coherentes en una variedad de contextos.

5. Evaluación:

Pruebas de Rendimiento: Se realizaron pruebas exhaustivas para evaluar la precisión y relevancia de los diagnósticos generados por el chatbot. Se utilizó un enfoque de validación cruzada para asegurar la robustez del modelo y evitar el sobreajuste.

Comparación con Métodos Existentes: Se comparó el rendimiento del chatbot con otros métodos de diagnóstico existentes, como el clasificador K-nearest neighbors y el clasificador Naive Bayes. Los resultados mostraron que el SVM superó a estos métodos en términos de precisión y eficiencia.

2.1.10.5. Resultados obtenidos

El chatbot médico demostró ser efectivo en la provisión de diagnósticos médicos precisos y relevantes. En las pruebas de rendimiento, el modelo de SVM logró una precisión del 94 %, superando significativamente a los métodos K-nearest neighbors y Naïve Bayse. El uso de técnicas de NLP permitió al chatbot interpretar correctamente las consultas de los usuarios y generar respuestas útiles basadas en los datos de síntomas y enfermedades. La integración con APIs de Google facilitó la comunicación verbal con el chatbot, mejorando la accesibilidad para una mayor variedad de usuarios. Los usuarios reportaron una alta satisfacción con la facilidad de uso y la precisión de los diagnósticos proporcionados por el chatbot.

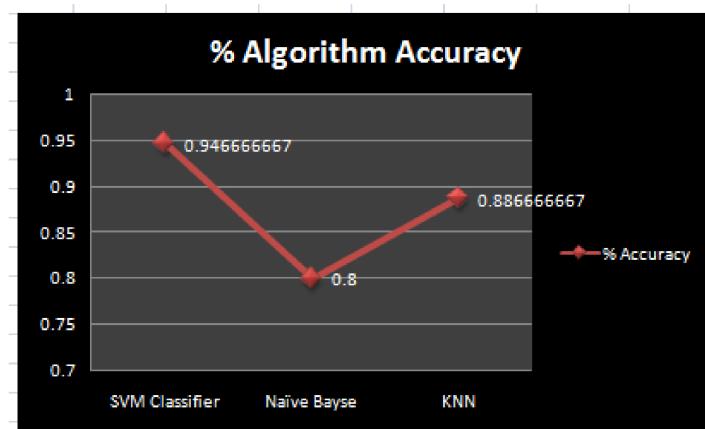


Figura 2.19: Metodología. Fuente: CITAR AL FINAL

2.2. Bases Teóricas

2.2.1. Inteligencia Artificial y Procesamiento de Lenguaje Natural

Inteligencia Artificial (IA): La IA se refiere a la simulación de procesos de inteligencia humana por parte de sistemas informáticos. En el contexto de un chatbot médico, la IA se utiliza para analizar las consultas de los usuarios y proporcionar respuestas precisas y relevantes.

Procesamiento de Lenguaje Natural (NLP): El NLP es una rama de la IA que se centra en la interacción entre computadoras y humanos mediante el lenguaje natural. Los modelos de NLP permiten a los chatbots entender y responder a las consultas en lenguaje humano, facilitando la comunicación natural y efectiva.

2.2.2. Modelos de Machine Learning

Machine Learning (ML): Es una subdisciplina de la IA que permite a los sistemas aprender y mejorar a partir de la experiencia sin ser explícitamente programados para cada tarea. Los algoritmos de ML son fundamentales para el funcionamiento de los chatbots, ya que permiten mejorar la precisión y relevancia de las respuestas basadas en datos históricos.

Redes Neuronales y Deep Learning: Las redes neuronales, especialmente las redes neuronales profundas (deep learning), han revolucionado el campo del NLP. Modelos como Transformers y BERT (Bidirectional Encoder Representations from Transformers) son capaces de comprender el contexto y matices del lenguaje humano con gran precisión.

2.2.3. Telemedicina y Salud Digital

Telemedicina: La telemedicina se refiere al uso de tecnologías de la información para proporcionar servicios médicos a distancia. Los chatbots médicos son una extensión de la telemedicina, proporcionando asesoramiento y orientación médica sin la necesidad de una interacción cara a cara.

Salud Digital: La salud digital engloba todas las aplicaciones de las tecnologías digitales en el ámbito sanitario. Esto incluye desde aplicaciones móviles hasta sistemas complejos de gestión de datos de pacientes. Los chatbots médicos se sitúan en la intersección de la salud digital y la telemedicina, facilitando el acceso a información médica de calidad.

2.3. Marco Conceptual

2.3.1. Concepto de Chatbot Médico Pediátrico

Un **chatbot médico pediátrico** es una aplicación de software diseñada para interactuar con los usuarios mediante una interfaz de chat, ofreciendo asesoramiento y orientación médica específica para pediatría. Este chatbot puede responder preguntas sobre síntomas comunes, proporcionar consejos de salud preventiva y orientar sobre cuándo buscar atención médica.

2.3.2. Componentes del Chatbot Médico Pediátrico

- **Interfaz de Usuario:** La interfaz debe ser intuitiva y fácil de usar, especialmente diseñada para personas con acceso limitado a la tecnología.
- **Motor de IA y NLP:** El corazón del chatbot, responsable de entender las consultas y generar respuestas adecuadas.
- **Base de Conocimientos Médicos:** Una base de datos extensa y actualizada con información validada por expertos en pediatría.
- **Módulo de Seguridad y Privacidad:** Implementaciones para garantizar la seguridad de los datos de los usuarios y el cumplimiento de las regulaciones de privacidad.

2.3.3. Funcionalidades del Chatbot

- **Consulta de Síntomas:** Permite a los usuarios ingresar síntomas y recibir orientación sobre posibles condiciones y recomendaciones.
- **Información Preventiva:** Proporciona consejos sobre vacunaciones, nutrición y desarrollo infantil.
- **Orientación en Emergencias:** Informa a los usuarios sobre cuándo es crucial buscar atención médica inmediata.
- **Soporte Multilingüe:** Para ser accesible a comunidades rurales diversas, el chatbot debe soportar múltiples idiomas y dialectos.

2.3.4. Beneficios de Implementar un Chatbot Médico Pediátrico

- **Accesibilidad:** Proporciona acceso a información médica en áreas rurales con pocos recursos médicos.
- **Eficiencia:** Reduce la carga en los centros de salud al manejar consultas básicas de forma automatizada.
- **Costos Reducidos:** Minimiza los costos asociados con desplazamientos y consultas médicas innecesarias.
- **Educación Sanitaria:** Aumenta el conocimiento y la concienciación sobre temas de salud entre las comunidades rurales.

2.3.5. Desafíos y Consideraciones Éticas

- **Precisión de las Respuestas:** Garantizar que la información proporcionada sea precisa y actualizada.
- **Privacidad de los Datos:** Proteger la confidencialidad de la información de los usuarios.
- **Accesibilidad Tecnológica:** Asegurar que el chatbot sea accesible en áreas con conectividad limitada.
- **Aprobación Reguladora:** Cumplir con las regulaciones locales e internacionales sobre salud y tecnología.

2.4. Implementación Técnica

2.4.1. Selección de la Plataforma de Desarrollo

Plataformas recomendadas para el desarrollo de chatbots médicos incluyen:

- **Dialogflow:** Ofrecido por Google, soporta NLP avanzado y es fácil de integrar con otras aplicaciones.
- **Microsoft Bot Framework:** Una plataforma robusta para desarrollar y desplegar chatbots en múltiples canales.
- **Rasa:** Una opción open-source que proporciona flexibilidad y control total sobre el diseño del chatbot.

2.4.2. Diseño de la Arquitectura del Chatbot

- **Frontend:** La interfaz de usuario, que puede ser una aplicación web, móvil o incluso integrarse en plataformas de mensajería existentes como WhatsApp.
- **Backend:** El servidor que alberga el motor de IA y la base de conocimientos, procesando las consultas y generando respuestas.
- **Integraciones:** Con sistemas de información médica, bases de datos de salud y plataformas de telemedicina.

2.4.3. Desarrollo del Chatbot

- **Entrenamiento del Modelo de NLP:** Utilizar datos médicos pediátricos para entrenar el modelo, asegurando que pueda comprender y responder a consultas específicas.
- **Desarrollo de la Base de Conocimientos:** Compilar y estructurar la información médica relevante en una base de datos accesible por el chatbot.
- **Pruebas y Validación:** Realizar pruebas exhaustivas para asegurar la precisión y fiabilidad del chatbot, incluyendo pruebas de usabilidad con usuarios de áreas rurales.

2.4.4. Despliegue y Mantenimiento

- **Despliegue:** Implementar el chatbot en los canales seleccionados y asegurarse de que esté accesible para la comunidad objetivo.
- **Monitoreo y Actualización:** Monitorear el rendimiento del chatbot y actualizar la base de conocimientos regularmente para mantener la relevancia y precisión de la información.
- **Soporte y Feedback:** Establecer un sistema de soporte para los usuarios y recopilar feedback para mejorar continuamente el chatbot.

Capítulo 3

METODOLOGÍA DE LA INVESTIGACIÓN

3.1. Diseño de la investigación

En esta sección del documento se explicará cual es el diseño, el tipo y el enfoque del trabajo de investigación, así como también la población y la muestra.

3.1.1. Diseño no experimental

El diseño es no experimental longitudinal, ya que las variables no serán manipuladas y serán analizadas tal como se encuentran. Es decir, tanto los datos textuales (noticias) y el precio del cobre serán analizados sin ningún cambio aplicando técnicas de procesamiento de lenguaje natural y algoritmos de aprendizaje automático con la finalidad de crear un modelo productivo robusto y facilitar la predicción del cobre. Asimismo, la recolección de datos que se realizará será en un determinado periodo de tiempo.

3.1.2. Tipo explicativo

El alcance de la presente investigación es explicativo debido a que se busca explicar el comportamiento volátil del precio del cobre en base a noticias de periódicos digitales y además predecirlo.

3.1.3. Enfoque cuantitativo

El enfoque de esta investigación es cuantitativo dado que se empleará técnicas del procesamiento de lenguaje natural (NLP), las cuales conllevan a procesar los datos de tipo textual a numéricos (vectores de características) y con ello posteriormente usar técnicas estadísticas como la regresión lineal para la predicción del precio del cobre.

3.2. Población y muestra

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdible sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdible dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit. La Figura 3.1 y el Cuadro 3.1

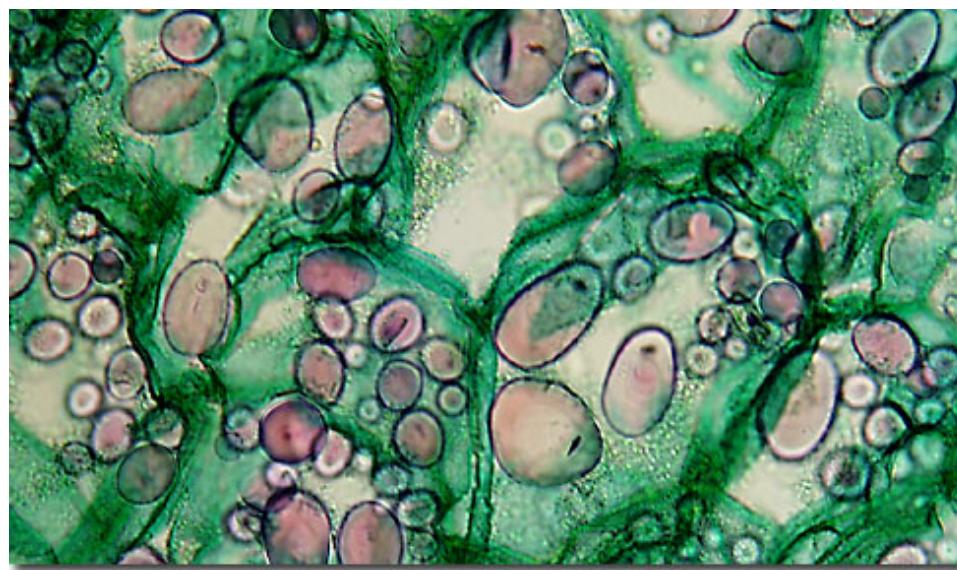


Figura 3.1: Prueba de Figura

3.3. Operacionalización de Variables

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdible sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus

mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdiet dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit.

3.4. Instrumentos de medida

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat

- muscle and fat cells remove glucose from the blood,
- cells breakdown glucose via glycolysis and the citrate cycle, storing its energy in the form of ATP,
- liver and muscle store glucose as glycogen as a short-term energy reserve,
- adipose tissue stores glucose as fat for long-term energy reserve, and
- cells use glucose for protein synthesis.

3.5. Técnicas de recolección de datos

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdiet sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdiet dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit.

\LaTeX is great at typesetting mathematics. Let X_1, X_2, \dots, X_n be a sequence of independent and identically distributed random variables with

$$S_n = \frac{X_1 + X_2 + \dots + X_n}{n} = \frac{1}{n} \sum_i^n X_i \quad (\text{Ecuación 3.1})$$

La Ecuación [Ecuación 3.1](#) denote their mean. Then as n approaches infinity, the random variables

$$\sqrt{n}(S_n - \mu)$$

converge in distribution to a normal $\mathcal{N}(0, \sigma^2)$.

3.6. Técnicas para el procesamiento y análisis de la información

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdiet sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdiet dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit.

You can make lists with automatic numbering ...

1. Like this,
2. and like this.

... or bullet points ...

- Like this,
- and like this.

3.7. Cronograma de actividades y presupuesto

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdiet sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdiet dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit.

Item	Quantity
Widgets	42
Gadgets	13

Tabla 3.1: An example table.

Capítulo 4

DESARROLLO DEL EXPERIMENTO

4.1. X

Hello, here is some text without a meaning. This text should show what a printed text will look like at this place. If you read this text, you will get no information. Really? Is there no information? Is there a difference between this text and some nonsense like “Huardest gefburn? Kjift ”not at all!...

4.2. Y

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdiet sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdiet dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit.

Item	Quantity
Widgets	42
Gadgets	13

Tabla 4.1: An example table.

4.3. Z

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdiet sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdiet dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit.

El paper es citado y el otro paper .

Capítulo 5

ANÁLISIS Y DISCUSIÓN DE RESULTADOS

5.1. X

Hello, here is some text without a meaning. This text should show what a printed text will look like at this place. If you read this text, you will get no information. Really? Is there no information? Is there a difference between this text and some nonsense like “Huardest gefburn? Kjift ”not at all!...

5.2. Y

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdiet sed euismod. Velit euismod in pellentesque massa placerat. Nam praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdiet dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit.

Item	Quantity
Widgets	42
Gadgets	13

Tabla 5.1: An example table.

5.3. Z

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdiet sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdiet dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit.

Capítulo 6

CONCLUSIONES Y RECOMENDACIONES

6.1. Conclusiones

Hello, here is some text without a meaning. This text should show what a printed text will look like at this place. If you read this text, you will get no information. Really? Is there no information? Is there a difference between this text and some nonsense like “Huardest gefburn? Kjift ”not at all!...

6.2. Recomendaciones

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdiet sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdiet dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit.

Anexos

Anexos A

Anexo I: Matriz de Consistencia

PROBLEMAS	OBJETIVOS	HIPÓTESIS
Problema General	Objetivo General	Hipótesis General
Problemas Específicos	Objetivos Específicos	Hipótesis Específicas
¿De qué manera la implementación de un chatbot médico puede mejorar el acceso a servicios de salud en las zonas rurales de Perú?	Implementar un chatbot médico efectivo y sostenible para brindar servicios de salud de calidad a las poblaciones rurales en Perú	La implementación de un chatbot médico mejorará significativamente el acceso a servicios médicos de calidad para las poblaciones rurales.
¿Que datos disponibles se necesitaran para la implementacion de chatbot?	Identificar los datos disponibles y necesarios para la implementación del chatbot médico en áreas rurales de Perú.	La disponibilidad de datos y la integración de APIs adecuadas serán fundamentales para el desarrollo exitoso del chatbot médico.
¿Que arquitectura podrían ser utilizadas para desarrollar un chatbot médico?	Explorar las diferentes arquitecturas disponibles para el desarrollo del chatbot médico.	La arquitectura permitirá la creación de un chatbot médico eficiente y preciso.
¿Qué métodos de entrenamiento y validación se pueden utilizar para un chatbot?	Investigar métodos de entrenamiento y validación adecuados para un chatbot médico.	La aplicación de métodos de entrenamiento y validación apropiados garantizarán la funcionalidad y confiabilidad del chatbot médico
¿Qué métricas se pueden utilizar para evaluar la efectividad del chatbot médico?	Definir métricas de evaluación para medir la efectividad y el impacto del chatbot médico en la prestación de servicios de la salud.	La evaluación de métricas específicas revelará el impacto positivo del chatbot médico en la prestación de servicios de salud en áreas rurales de Perú

Tabla A.1: Matriz de consistencia. Fuente: Elaboración propia

Hipótesis Específica	Indicadores	Fórmulas
La disponibilidad de datos y la integración de APIs adecuadas serán fundamentales para el desarrollo exitoso del chatbot médico.	*Porcentaje de integración de APIs *Calidad de datos *Tiempo de respuesta de la API *Porcentaje de consultas resueltas	$\frac{\text{Número de APIs integradas}}{\text{Total de APIs disponibles}} \times 100$ $\frac{\text{Cantidad de datos precisos y actualizados}}{\text{Total de datos utilizados}} \times 100$ $\frac{\text{Tiempo total de respuesta de la API}}{\text{Número total de consultas}}$ $\frac{\text{Consultas resueltas}}{\text{Total de consultas realizadas}} \times 100$
La arquitectura permitirá la creación de un chatbot médico eficiente y preciso.	*Precisión del modelo de lenguaje natural *Eficiencia del chatbot *Tasa de reconocimiento de entidades médicas *Cobertura de conocimiento médico	$\frac{\text{Número de respuestas correctas}}{\text{Total de respuestas generadas}} \times 100$ $\frac{\text{Número de consultas manejadas}}{\text{Tiempo total de prueba}}$ $\frac{\text{Número de entidades médicas correctamente identificadas}}{\text{Total de entidades médicas identificadas}} \times 100$ $\frac{\text{Número de temas médicos cubiertos correctamente}}{\text{Total de temas médicos probados}} \times 100$
La aplicación de métodos de entrenamiento y validación apropiados garantizarán la funcionalidad y confiabilidad del chatbot médico	*Exactitud del conjunto de datos de entrenamiento *Tasa de generalización del modelo *Precisión de la validación cruzada *Estabilidad del modelo	$\frac{\text{Número de pares de consulta-respuesta correctos}}{\text{Total de pares de consulta-respuesta}} \times 100$ $\frac{\text{Número de consultas generales respondidas correctamente}}{\text{Total de consultas generales}} \times 100$ $\frac{\text{Número de consultas validadas correctamente}}{\text{Total de consultas validadas}} \times 100$ $\frac{\text{Desviación estándar del rendimiento del modelo}}{\text{Media del rendimiento del modelo}} \times 100$
La evaluación de métricas específicas revelará el impacto positivo del chatbot médico en la prestación de servicios de salud en áreas rurales de Perú	*Reducción en tiempos de espera *Aumento en la accesibilidad de servicios médicos *Mejora en la precisión del diagnóstico *Satisfacción del usuario	Antes= Tiempo promedio de espera antes de la implementación Después= Tiempo promedio de espera después de la implementación $\frac{\text{Antes} - \text{Después}}{\text{Antes}} \times 100$ $\frac{\text{Número de consultas médicas atendidas por el chatbot}}{\text{Total de consultas médicas realizadas}} \times 100$ dChat=Precisión del diagnóstico del chatbot. dHumano=Precisión del diagnóstico humano $\frac{\text{dChat} - \text{dHumano}}{\text{dHumano}} \times 100$ $\frac{\text{Número de usuarios satisfechos}}{\text{Total de usuarios encuestados}} \times 100$

Tabla A.2: Tabla de Hipótesis Específicas, Indicadores y Fórmulas

Anexos B

Anexo II: Árbol del Problema

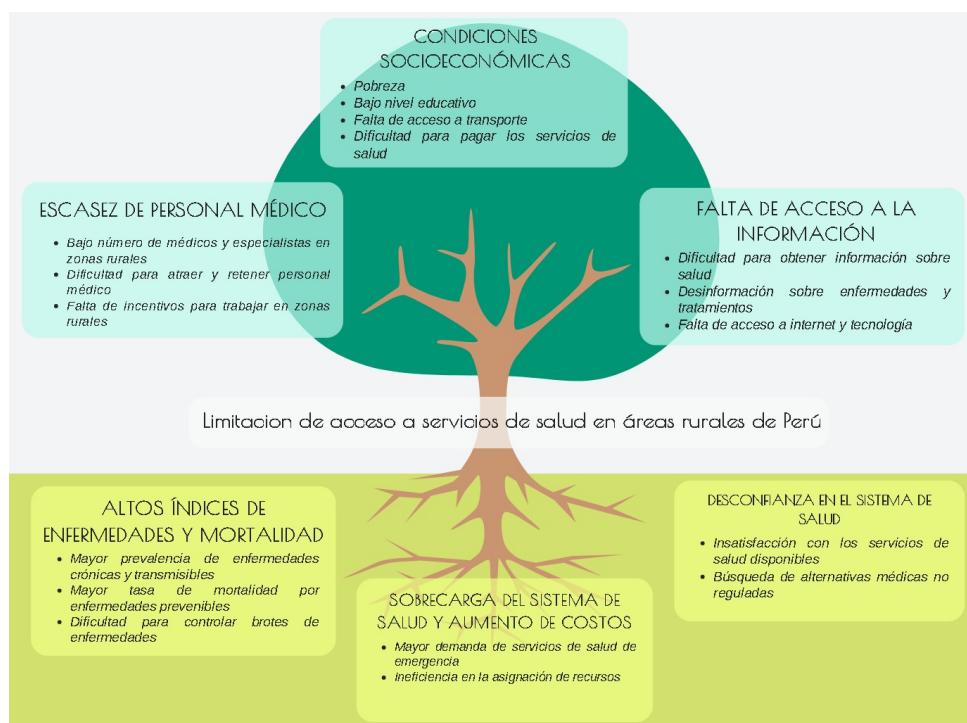


Figura B.1: Árbol del problema. Fuente: Elaboración propia

Anexos C

Anexo III: Arbol de Objetivos

Anexos D

Anexo IV: Resumen de Papers investigados

Tipo	Nº	Título	Autor	Año	País	Fuente
Problema	1	Copper price estimation using bat algorithm	Dehghani Bogdanovic	2018	United Kingdom	Resources Policy
	2	Alternative techniques for forecasting mineral commodity prices	Cortez, Saydam, Coulton, Sammut	2018	Netherlands	International Journal of Mining Science and Technology
Propuesta	3	Prediction of the crude oil price thanks to natural language processing applied to newspapers	Trastour, Gennin, Morlot	2016	USA	Standfort University ML repository
	4	Stock Price Prediction Using Deep Learning	Tipirisetty	2018	USA	Master's Theses San Jose State University
Técnica	5	Deep Learning for Stock Prediction Using Numerical and Textual Information	Akita, R., Yoshihara, A., Matsubara, T., Uehara, K.	2016	USA	2016 IEEE/ACIS 15th International Conference on Computer and Information Science (ICIS)
	6	Stock Prices Prediction using the Title of Newspaper Articles with Korean Natural Language Processing	Yun, Sim, Seok	2019	Japan	2019 International Conference on Artificial Intelligence in Information and Communication (ICAIIC)
Técnica	7	A Method of Optimizing LDA Result Purity Based on Semantic Similarity	Jingrui, Z., Qinglin, W., Yu, L., Yuan, L.	2017	China	2017 32nd Youth Academic Annual Conference of Chinese Association of Automation (YAC)
	8	Qualitative Stock Market Predicting with Common Knowledge Based Nature Language Processing: A Unified View and Procedure	Rao, D., Deng, F., Jiang, Z., Zhao, G.	2015	USA	2015 7th International Conference on Intelligent Human-Machine Systems and Cybernetics
Técnica	9	Fuzzy Bag-of-Words Model for Document Representation	Zhao, R., Mao, K.	2018	USA	IEEE Transactions on Fuzzy Systems (Volume: 26 , Issue: 2 , April 2018)

Tabla D.1: Cuadro Resumen de Papers investigados. Fuente: Elaboración propia

BIBLIOGRAFÍA

- Akita, R., Yoshihara, A., Matsubara, T., & Uehara, K. Deep learning for stock prediction using numerical and textual information. En: En *2016 IEEE/ACIS 15th International Conference on Computer and Information Science (ICIS)*. IEEE. 2016, 1-6.
- Cortez, C. T., Saydam, S., Coulton, J., & Sammut, C. (2018). Alternative techniques for forecasting mineral commodity prices. *International Journal of Mining Science and Technology*, 28(2), 309-322.
- Dehghani, H., & Bogdanovic, D. (2018). Copper price estimation using bat algorithm. *Resources Policy*, 55, 55-61.
- Gartner. (2019). Gartner IT Glossary. <https://www.gartner.com/it-glossary/>
- Gollapudi, S. (2016). *Practical machine learning*. Packt Publishing Ltd.
- Goyal, P., Pandey, S., & Jain, K. (2018). Deep learning for natural language processing. *Deep Learning for Natural Language Processing: Creating Neural Networks with Python [Berkeley, CA]: Apress*, 138-143.
- IBM. (2019). IBM AI glossary. <https://www.ibm.com/cloud/garage/architectures/cognitiveArchitecture/glossary>
- Jingrui, Z., Qinglin, W., Yu, L., & Yuan, L. A method of optimizing LDA result purity based on semantic similarity. En: En *2017 32nd Youth Academic Annual Conference of Chinese Association of Automation (YAC)*. IEEE. 2017, 361-365.
- Kulkarni, A., & Shivananda, A. (2019). Exploring and Processing Text Data. En *Natural Language Processing Recipes* (pp. 37-65). Springer.
- Lagos, G. (2017). ¿Cómo lo han hecho los especialistas?: aciertos y desaciertos al proyectar el precio del cobre. <https://gyn.claseejecutiva.uc.cl/como-lo-han-hecho-los-especialistas-aciertos-y-desaciertos-al-proyectar-el-precio-del-cobre/#>
- Martínez, R., & Cohen, E. (2018). Manual formulación, evaluación y monitoreo de proyectos sociales. <https://dds.cepal.org/redesoc/publicacion?id=242>
- Ministerio de Energía y Minas (ESTAMIN). (2019). *Perú: país líder de los metales del futuro* (Boletín Estadístico Minero).

- Rao, D., Deng, F., Jiang, Z., & Zhao, G. Qualitative Stock Market Predicting with Common Knowledge Based Nature Language Processing: A Unified View and Procedure. En: En *2015 7th International Conference on Intelligent Human-Machine Systems and Cybernetics*. 2. IEEE. 2015, 381-384.
- Real Academia Española. (2014). Diccionario de la lengua española (Twenty-third). <https://dle.rae.es/?w=diccionario>
- Royal Society Working Group. (2017). *Machine learning: the power and promise of computers that learn by example* (inf. téc.). Technical report.
- Study Group International Copper. (2018). The World Copper Factbook 2018. www.icsg.org
- TensorFlow. (2019). Vector Representations of Words. <https://www.tensorflow.org/tutorials/representation/word2vec>
- Tipirisetty, A. (2018). *Stock Price Prediction using Deep Learning* [Tesis de maestría, San José State University] [Master's Projects]. <https://doi.org/https://doi.org/10.31979/etd-bzmm-36m7>
- Trastour, S., Genin, M., & Morlot, A. (2016). Prediction of the crude oil price thanks to natural language processing applied to newspapers. <http://cs229.stanford.edu/proj2016/report/>
- U.S. Geological Survey. (2019). Mineral commodity summaries 2019: U.S. Geological Survey. <https://doi.org/https://doi.org/10.3133/70202434>
- Yun, H., Sim, G., & Seok, J. Stock Prices Prediction using the Title of Newspaper Articles with Korean Natural Language Processing. En: En *2019 International Conference on Artificial Intelligence in Information and Communication (ICAIIC)*. IEEE. 2019, 019-021.
- Zhao, R., & Mao, K. (2017). Fuzzy bag-of-words model for document representation. *IEEE Transactions on Fuzzy Systems*, 26(2), 794-804.