



UNIVERSIDAD ESAN
FACULTAD DE INGENIERÍA
INGENIERÍA DE TECNOLOGÍAS DE INFORMACIÓN Y SISTEMAS

**Implementación de un Chatbot Médico Pediatrico para la Prestación de Servicios en
Áreas Rurales**

Trabajo de investigación para el curso de Trabajo de Tesis I

Jean Pierre Castro Acuña
Asesor: Marks Calderón

Lima, 10 de junio de 2024

Resumen

Abstract

Para mi X, Y,X

Agradecimientos

Índice general

Índice de Figuras	8
Índice de Tablas	10
1. PLANTEAMIENTO DEL PROBLEMA	11
1.1. Descripción de la Realidad Problemática	11
1.2. Formulación del Problema	13
1.2.1. Problema General	13
1.2.2. Problemas Específicos	13
1.3. Objetivos de la Investigación	14
1.3.1. Objetivo General	14
1.3.2. Objetivos Específicos	14
1.4. Justificación de la Investigación	14
1.4.1. Teórica	14
1.4.2. Práctica	15
1.4.3. Metodológica	16
1.5. Delimitación del Estudio	16
1.5.1. Espacial	16
1.5.2. Temporal	17
1.5.3. Conceptual	17
1.6. Hipótesis	18
1.6.1. Hipótesis General	18
1.6.2. Hipótesis Específicas	18

1.6.3. Matriz de Consistencia	18
2. MARCO TEÓRICO	19
2.1. Antecedentes de la investigación	19
2.1.1. The Health ChatBots in Telemedicine: Intelligent Dialog System for Remote Support (Vasileiou & Maglogiannis, 2022)	19
2.1.2. PEFT-MedAware: Large Language Model for Medical Awareness (Pandya, 2023)	23
2.1.3. Medbot: Conversational Artificial Intelligence Powered Chatbot for Delivering Tele-Health after COVID-19 (Bharti, Bajaj, Batra, Lalit, Lalit & Gangwani, 2020)	26
2.1.4. Intelligent Chatbot for Medical Assistance in Rural Areas (Arulmangainayaki, Harini, Keerthiga & Priya*, 2020)	29
2.1.5. HHH: An Online Medical Chatbot System based on Knowledge Graph and Hierarchical Bi-Directional Attention (Bao, Ni & Liu, 2020)	32
2.1.6. HealFavor: Dataset and A Prototype System for Healthcare ChatBot (Ur Rahman Khilji, Laskar, Pakray, Kadir, Lydia & Bandyopadhyay, 2020)	36
2.1.7. ChatDoctor: A Medical Chat Model Fine-Tuned on a Large Language Model Meta-AI (LLaMA) Using Medical Domain Knowledge (Li, Li, Zhang, Dan, Jiang & Zhang, 2023)	38
2.1.8. Auto Response Generation in Online Medical Chat Services (Jahanshahi, Kazmi & Cevik, 2022)	41
2.1.9. An Approach to Medical Diagnosis Using Smart Chatbot (Verma, Singh, Tiwari & Tripathy, 2022)	46
2.1.10. A Medical ChatBot (Dharwadkar & Deshpande, 2018)	49
2.2. Bases Teóricas	52
2.2.1. Inteligencia Artificial y Procesamiento de Lenguaje Natural	52
2.2.2. Modelos de Machine Learning	53
2.2.3. Telemedicina y Salud Digital	53
2.3. Marco Conceptual	53
2.3.1. Concepto de Chatbot Médico Pediátrico	53

2.3.2. Componentes del Chatbot Médico Pediátrico	53
2.3.3. Funcionalidades del Chatbot	54
2.3.4. Beneficios de Implementar un Chatbot Médico Pediátrico	54
2.3.5. Desafíos	54
2.4. Implementación Técnica	55
2.4.1. Selección de la Plataforma de Desarrollo	55
2.4.2. Diseño de la Arquitectura del Chatbot	55
2.4.3. Desarrollo del Chatbot	55
Anexos	57
A. Anexo I: Matriz de Consistencia	58
B. Anexo II: Arbol del Problema	60
C. Anexo IV: Resumen de Papers investigados	61
BIBLIOGRAFÍA	64

Índice de Figuras

1.1. Total de poblacion rural y urbana. Fuente: INEI, 2022	12
1.2. Porcentaje de acceso a atencion medica. Fuente: INEI, 2022	12
2.1. Metodologia. Fuente: Bharti et al., 2020	20
2.2. Escalabilidad y Disponibilidad. Fuente: Vasileiou y Maglogiannis, 2022	21
2.3. Interfaz de Usuario y Procesamiento NLP. Fuente: Vasileiou y Maglogiannis, 2022	21
2.4. Resultado. Fuente: Vasileiou y Maglogiannis, 2022	22
2.5. Resultado. Fuente: Vasileiou y Maglogiannis, 2022	22
2.6. Resultado. Fuente: Vasileiou y Maglogiannis, 2022	23
2.7. Metodologia. Fuente: Pandya, 2023	25
2.8. Metodologia. Fuente: Bharti et al., 2020	28
2.9. Resultado. Fuente: Arulmangainayaki et al., 2020	29
2.10. Metodologia. Fuente: Bharti et al., 2020	30
2.11. Metodologia. Fuente: Bao et al., 2020	33
2.12. Metodologia. Fuente: Bharti et al., 2020	37
2.13. Metodología del proceso del modelo del ChatDoctor. Fuente: Li et al., 2023 . .	40
2.14. Metodologia. Fuente: Bharti et al., 2020	43
2.15. Valores de rendimiento para la combinación de modelos de activación y generación de respuesta. Fuente: Jahanshahi et al., 2022	45
2.16. Metodologia. Fuente: Verma et al., 2022	47
2.17. Chat Between User and Bot Salli. Fuente: Verma et al., 2022	48
2.18. Separando hiperplano por ecuación. Fuente: Dharwadkar y Deshpande, 2018 . .	49

2.19. Metodología del Medical Chatbot. Fuente: Dharwadkar y Deshpande, 2018	50
2.20. Algoritmo de Exactitud despues de la comparación de diferentes métodos. Fuente: Dharwadkar y Deshpande, 2018	52
B.1. Árbol del problema. Fuente: Elaboración propia	60

Índice de Tablas

2.1. Resultado. Fuente: Arulmangainayaki et al., 2020	32
2.2. Metodos de comparacion. Fuente: Bao et al., 2020	35
2.3. Resultado de exactitud. Fuente: Bao et al., 2020	35
2.4. Comparacion entre el BERTScore entre ChatDoctor y Chatgpt. Fuente: Li et al., 2023	41
A.1. Matriz de consistencia. Fuente: Elaboración propia	58
A.2. Tabla de Hipótesis Específicas, Indicadores y Fórmulas	59
C.1. Cuadro Resumen de Papers investigados. Fuente: Elaboración propia	62

Capítulo 1

PLANTEAMIENTO DEL PROBLEMA

1.1. Descripción de la Realidad Problemática

En América Latina, la situación es igualmente preocupante. Un estudio realizado por la Comisión Económica para América Latina y el Caribe (CEPAL) demostró que el 60 % de los habitantes rurales no tienen acceso a servicios de salud adecuados ([OECD & Bank, 2020](#)). La falta de acceso a servicios de salud tiene consecuencias graves para la población pediátrica. La UNICEF informa que las tasas de mortalidad infantil en áreas rurales son significativamente más altas que en áreas urbanas. En países en desarrollo, los niños que viven en zonas rurales tienen el doble de probabilidades de morir antes de los cinco años en comparación con sus contrapartes urbanas [UNICEF, 2022](#).

La situación de atención médica en las áreas rurales de Perú es una realidad compleja y desafiante. Imagine comunidades enclavadas en paisajes montañosos y remotos, donde acceder a servicios médicos básicos es una odisea. La falta de infraestructura adecuada y la escasez de profesionales de la salud crean una brecha significativa en el acceso a la atención médica, dejando a muchas personas sin atención. Según el Instituto Nacional de Estadística e Informática (INEI), en 2022, solo el 20 % pertenece a la población rural, en comparación con el 80 % de la población urbana. Esto significa que millones de peruanos en áreas rurales son más vulnerables a enfermedades y muertes evitables.

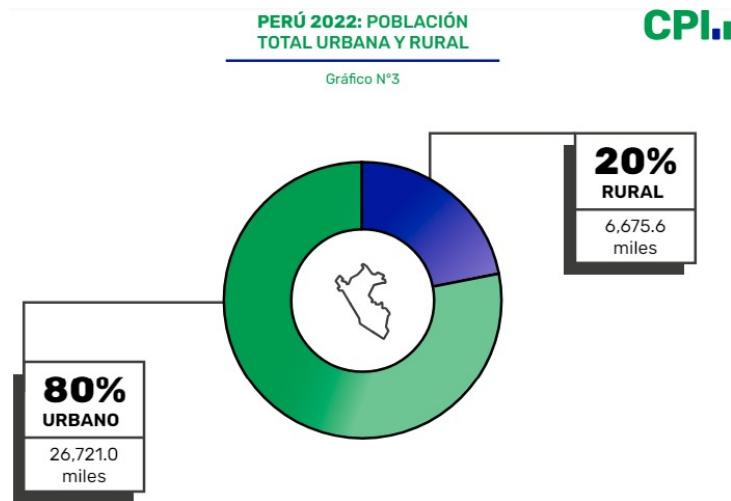
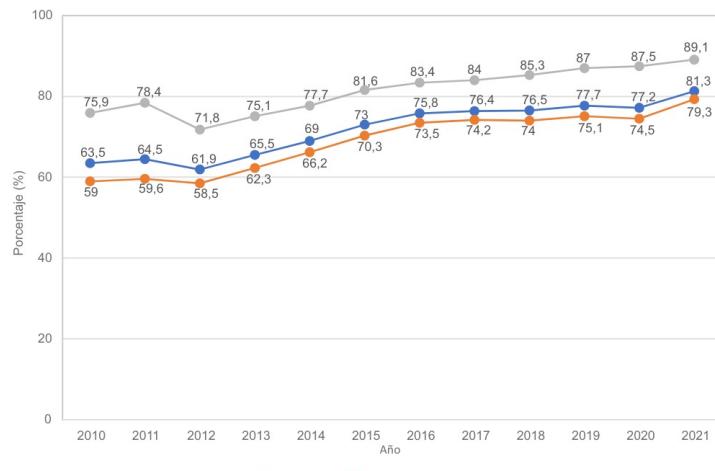


Figura 1.1: Total de población rural y urbana. Fuente: [INEI, 2022](#)

Ademas, los datos oficiales respaldan estas realidades duras. Según el Ministerio de Salud de Perú, en el 2021, más del 70 % de la población rural carecía de acceso regular a servicios médicos adecuados. Esto no es solo una estadística fría, sino una narrativa de vidas afectadas, enfermedades no tratadas y vidas que podrían haberse salvado con una atención médica oportuna.



Fuente: INEI.
Elaboración: Unidad de Análisis de Situación de Salud del CDC - MINSA.

Figura 1.2: Porcentaje de acceso a atención médica. Fuente: [INEI, 2022](#)

Durante el período comprendido entre 2022 y 2024, la pandemia de COVID-19 solo ha intensificado estos desafíos. Los recursos y la atención se desplazaron hacia la respuesta a la pandemia, dejando otras necesidades de salud pública en segundo plano. Las comunidades rurales se encontraron aún más marginadas, enfrentando una atención médica aún más limitada y fragmentada.

Sin embargo, entre estas sombras de dificultades, hay un rayo de esperanza en la forma de la tecnología. El aumento del acceso a teléfonos móviles en áreas rurales ofrece una oportunidad única para brindar servicios médicos básicos a través de plataformas digitales, incluso en las zonas más remotas del país. Aquí es donde cobra importancia la noción de un chatbot médico.

Imagínese un sistema donde las personas en las comunidades rurales pueden acceder a información médica básica, hacer consultas sobre síntomas y recibir orientación sobre cómo buscar atención médica, todo desde la comodidad de sus teléfonos móviles. Esto no solo podría salvar vidas, sino también aliviar la carga sobre los pocos centros de salud disponibles en estas áreas.

Pero, por supuesto, hay obstáculos por superar. La adaptación cultural, la capacitación de los usuarios y la garantía de la precisión de la información son solo algunos de los desafíos que enfrenta esta iniciativa. Además, la conectividad limitada en algunas áreas rurales plantea desafíos adicionales para garantizar un acceso efectivo a la aplicación.

La implementación de Chatbots Médicos en áreas rurales del Perú tiene el potencial de mejorar el acceso a la atención médica significativamente para millones de personas. Estos sistemas pueden proporcionar información y asesoramiento médico de manera remota, sin necesidad de que un médico esté presente físicamente. Además, los Chatbots Médicos pueden ayudar a los pacientes a programar citas, recordarles que tomen sus medicamentos y monitorear su progreso.

1.2. Formulación del Problema

1.2.1. Problema General

¿De qué manera la implementación de un chatbot médico Pediatrico puede mejorar el acceso a servicios de salud en las zonas rurales de Perú?

1.2.2. Problemas Específicos

- ¿Que datos disponibles se necesitaran para la implementacion de chatbot médico Pediatrico?
- ¿Que arquitectura podrían ser utilizadas para desarrollar un chatbot médico Pediatrico?
- ¿Qué métodos de entrenamiento y validación se pueden utilizar para un chatbot médico Pediatrico?

- ¿Qué métricas se pueden utilizar para evaluar la efectividad del chatbot médico Pediatrico?

1.3. Objetivos de la Investigación

1.3.1. Objetivo General

Implementar un chatbot médico Pediatrico efectivo y sostenible para brindar servicios de salud de calidad a las poblaciones rurales en Perú

1.3.2. Objetivos Específicos

- Identificar los datos disponibles y necesarios para la implementación del chatbot médico Pediatrico en áreas rurales de Perú.
- Explorar las diferentes arquitecturas disponibles para el desarrollo del chatbot médico Pediatrico.
- Investigar métodos de entrenamiento y validación adecuados para un chatbot médico Pediatrico.
- Definir métricas de evaluación para medir la efectividad y el impacto del chatbot médico Pediatrico en la prestación de servicios de la salud.

1.4. Justificación de la Investigación

1.4.1. Teórica

La teoría de la difusión de innovaciones de [Rogers, 2003](#) es fundamental para entender cómo las nuevas tecnologías se adoptan dentro de una sociedad. Rogers argumenta que la adopción de innovaciones depende de la ventaja comparativa, compatibilidad, complejidad, capacidad de prueba y visibilidad. Para un chatbot médico, la ventaja comparativa se manifiesta en la capacidad para proporcionar atención médica inmediata y accesible. La compatibilidad se refiere a cómo esta tecnología se integra en la vida cotidiana y entorno cultural, mientras que la complejidad debe ser mínima para garantizar la facilidad de uso. La capacidad de prueba permite a usuarios experimentar con el chatbot, y la visibilidad se relaciona con los beneficios visibles que otros pueden percibir al usar la tecnología.

Además, la teoría del cuidado centrado en el paciente, promovida por [Epstein y Street, 2011](#), subraya la importancia de una atención personalizada y accesible. La atención médica debe adaptarse a las necesidades individuales de los pacientes, considerando sus valores y preferencias. En áreas rurales, un chatbot puede proporcionar un nivel de personalización y atención sorprendente, mejorando significativamente la calidad de atención y satisfacción del paciente.

La teoría del acceso equitativo a la salud descrita por [Braveman y Gruskin, 2003](#), menciona que todas las personas, independientemente de su ubicación geográfica o condición socioeconómica, deben tener acceso a los servicios de salud de calidad. En Perú, las disparidades para el acceso a la atención médica entre áreas urbanas y rurales son marcadas. Un chatbot médico puede actuar como un nivelador, proporcionando información y asistencia médica, reduciendo así las inequidades en salud.

1.4.2. Práctica

Los chatbots pueden proporcionar información médica confiable y oportuna a los pacientes. En áreas rurales, donde el acceso a profesionales de la salud es limitado y las instalaciones médicas a menudo están lejos, un chatbot puede actuar como una primera línea de consulta médica. Esto puede ayudar a los pacientes a recibir orientación inmediata sobre sus síntomas, lo cual es crucial para la detección temprana y el manejo apropiado de enfermedades.

Además, la implementación de un chatbot médico puede mejorar la eficiencia del sistema de salud. Los chatbots pueden automatizar la respuesta a preguntas frecuentes y proporcionar diagnósticos preliminares, lo que puede reducir la carga de trabajo de los profesionales y permitirles centrarse en casos más complejos. Esto es especialmente relevante en situaciones de emergencia y en el manejo de enfermedades crónicas, donde el monitoreo constante y el acceso rápido a la información son vitales.

Un estudio realizado por [\(PwC\), 2017](#) destacó que los chatbots pueden ayudar a reducir los costos en el sector de la salud al mejorar la eficiencia y la gestión de los recursos. En áreas rurales de Perú, donde los recursos son escasos y el acceso a la atención médica es limitado, esta tecnología puede ser un cambio transformador. Los pacientes pueden obtener la ayuda que necesitan de manera rápida y eficiente, lo que puede mejorar los resultados y reducir tasas de complicaciones y hospitalizaciones.

Además, la implementación de un chatbot médico puede empoderar a los pacientes rurales al proporcionarles acceso a información médica confiable. Esto puede aumentar su conocimiento sobre su propia salud y fomentar prácticas de autocuidado, lo cual es crucial en comunidades donde la educación en salud puede ser limitada. Al tener acceso a información

precisa y recomendaciones médicas, los pacientes pueden tomar decisiones más informadas sobre su salud y bienestar.

1.4.3. Metodológica

Esta investigación se justifica por la oportunidad de desarrollar un modelo integral de implementación de chatbots médicos. El desarrollo del chatbot seguirá un enfoque de diseño centrado en el usuario **Norman1986**, con iteraciones constantes y pruebas de usabilidad para asegurar una interfaz intuitiva. Una vez desarrollado, se realizará un estudio piloto que combinará análisis cuantitativos (como tiempos de respuesta y satisfacción del paciente) con análisis cualitativos de la experiencia del usuario.

Además, se podrán validar técnicas y herramientas innovadoras como el NLP, Machine Learning y el diseño de interacciones conversacionales naturales. Como señalan [Tudor Car et al., 2020](#), "El uso de NLP y ML es clave para desarrollar chatbots médicos precisos y efectivos".

Otro aspecto metodológico importante es la generación de datos empíricos y evidencia científica sobre la aceptación, uso y efectividad del chatbot médico en comunidades rurales. Por lo que, se va a requerir más estudios de campo para evaluar el potencial de los chatbots de salud. Los datos generados en esta investigación podrían sentar las bases para futuros estudios y mejoras en la tecnología.

Finalmente, el desarrollo de métricas y herramientas de evaluación será fundamental para medir el desempeño e impacto del chatbot médico. Como sugieren [Abd-Alrazaq et al., 2020](#), "Es necesario contar con métricas específicas para evaluar la efectividad de los chatbots de salud en cuanto a la calidad de la información, la satisfacción del usuario y los resultados clínicos". Estas métricas y herramientas podrían ser aplicadas en futuras investigaciones y proyectos similares.

1.5. Delimitación del Estudio

1.5.1. Espacial

La presente investigación se delimita espacialmente a las áreas rurales del Perú, las cuales presentan características geográficas, demográficas y socioeconómicas particulares que obstaculizan el acceso a servicios de salud. Según el Instituto Nacional de Estadística e Informática [INEI, 2022](#), "En el año 2022, el 20 % de la población peruana residía en el área rural", concentrándose principalmente en la sierra y la selva. Estos territorios rurales se caracterizan por

su dispersión geográfica y baja densidad poblacional, como señalan [Diez-Canseco et al., 2015](#) en su análisis del uso de tecnologías móviles en salud rural: "Los principales desafíos son la falta de recursos, la fragmentación geográfica y las barreras culturales"(p. 2).

Asimismo, la diversidad étnica y cultural es un factor relevante, con presencia de poblaciones indígenas y comunidades nativas quechua-hablantes y aimara-hablantes, cuyas características socioculturales deben ser consideradas para asegurar la accesibilidad del chatbot médico.

1.5.2. Temporal

Esta investigación se desarrollará en un período de aproximadamente 2 años, con fases de diseño, desarrollo, implementación piloto y evaluación inicial del chatbot médico en comunidades rurales seleccionadas estratégicamente. Sin embargo, es importante considerar el contexto actual y proyecciones futuras.

Actualmente, el Ministerio de Salud de Perú (MINSA, 2022) ha implementado diversos programas y políticas orientadas a mejorar el acceso a servicios de salud en zonas rurales, como la Estrategia Sanitaria Nacional de Salud de los Pueblos Indígenas. Además, se han realizado esfuerzos por incorporar tecnologías como la telemedicina y los dispositivos móviles.

A futuro, se espera que la implementación del chatbot médico pueda escalarse a otras regiones rurales del país, integrándose con estrategias y tecnologías emergentes en el sector salud, como los sistemas de información geográfica y la inteligencia artificial aplicada a la medicina.

1.5.3. Conceptual

Según [Laranjo et al., 2018](#), un chatbot médico es un programa de computadora basado en inteligencia artificial diseñado para simular una conversación inteligente con usuarios humanos a través de canales de texto o voz, con el objetivo de brindar información y consejos médicos. Este tipo de tecnología ha ganado relevancia en los últimos años, ya que puede ayudar a superar barreras de acceso a servicios de salud, especialmente en áreas remotas y rurales.

Tomando como referencia el marco conceptual propuesto por [pr'Levesque2013-vb](#), el acceso abarca dimensiones como la accesibilidad geográfica, la disponibilidad, la aceptabilidad y la capacidad de pago. En el contexto de las áreas rurales peruanas, donde existen grandes desafíos en términos de dispersión geográfica, escasez de profesionales de la salud y barreras culturales, es esencial abordar estas dimensiones para lograr un acceso equitativo y efectivo a los servicios de salud.

Asimismo, la investigación se centrará en analizar los factores que influyen en la adopción y aceptación tecnológica del chatbot médico por parte de las poblaciones rurales. Para ello, se utilizará el Modelo Unificado de Aceptación y Uso de Tecnología (UTAUT) desarrollado por **pr Venkatesh2003-po**, el cual integra factores como la expectativa de desempeño, de esfuerzo, la influencia social y las condiciones facilitadoras. Comprender estos factores será clave para diseñar e implementar el chatbot de manera efectiva y promover su adopción por parte de los usuarios.

Finalmente, la investigación también considerará los determinantes sociales de la salud, los cuales influyen en el estado de salud y el acceso a servicios médicos en las comunidades rurales

1.6. Hipótesis

1.6.1. Hipótesis General

La implementación de un chatbot médico Pediatrico mejorará significativamente el acceso a servicios médicos de calidad para las poblaciones rurales.

1.6.2. Hipótesis Específicas

- La disponibilidad de datos y la integración de APIs adecuadas serán fundamentales para el desarrollo exitoso del chatbot médico Pediatrico.
- La arquitectura permitirá la creación de un chatbot médico Pediatrico eficiente y preciso.
- La aplicación de métodos de entrenamiento y validación apropiados garantizarán la funcionalidad y confiabilidad del chatbot médico Pediatrico.
- La evaluación de métricas específicas revelará el impacto positivo del chatbot médico Pediatrico en la prestación de servicios de salud en áreas rurales de Perú.

1.6.3. Matriz de Consistencia

A continuación se presenta la matriz de consistencia elaborada para la presente investigación (véase Anexo [A.1](#)).

Capítulo 2

MARCO TEÓRICO

2.1. Antecedentes de la investigación

En esta sección se presentarán diversos artículos de investigación o tesis las cuales abordarán diversas técnicas y enfoques que se emplearon para afrontar problemas similares al de esta tesis. Asimismo, a continuación se presenta un cuadro resumen (véase Anexo C.1) de lo que se presenta en esta sección.

2.1.1. The Health ChatBots in Telemedicine: Intelligent Dialog System for Remote Support ([Vasileiou & Maglogiannis, 2022](#))

2.1.1.1. Planteamiento del Problema

En la actualidad, la implementación de tecnologías avanzadas como Internet de las Cosas (IoT), Big Data y inteligencia artificial (IA) en el sector de la salud es esencial para mejorar los servicios de telemedicina. Sin embargo, la interacción tradicional entre pacientes y el sistema de salud carece de herramientas eficientes para la recolección y análisis de datos de salud de manera amigable y precisa. Los métodos convencionales de recopilación de síntomas y datos de pacientes son a menudo tediosos y propensos a errores, lo que puede llevar a diagnósticos imprecisos y a una experiencia de usuario deficiente.

El uso de ChatBots en telemedicina presenta una oportunidad para transformar estas interacciones, permitiendo a los pacientes comunicar sus síntomas y recibir diagnósticos preliminares de manera más interactiva y accesible. No obstante, la implementación de un sistema de ChatBot eficaz enfrenta desafíos significativos, incluyendo la necesidad de una adecuada comprensión del lenguaje natural (NLP), la integración segura de datos de pacientes, y la crea-

ción de modelos de aprendizaje automático (ML) precisos y fiables para la predicción de enfermedades

2.1.1.2. Objetivos

1. Desarrollar una plataforma de ChatBot de salud que utilice tecnologías de NLP para mejorar la interacción entre los pacientes y el sistema de salud.
2. Implementar modelos de IA y ML para la clasificación y predicción de enfermedades basadas en los síntomas reportados por los pacientes.
3. Facilitar la accesibilidad y usabilidad del sistema mediante interfaces de usuario intuitivas y compatibles con el lenguaje natural.

2.1.1.3. Fundamento Teórico

La utilización de ChatBots en el ámbito de la salud se basa en tecnologías avanzadas de NLP y ML para entender y procesar el lenguaje natural de los pacientes. El NLP permite a las máquinas interpretar, analizar y responder a textos generados por humanos. Este proceso incluye diversas técnicas como la lematización, la segmentación morfológica y el etiquetado de partes del discurso, que ayudan a descomponer y entender el texto de entrada.

Los ChatBots de IA están diseñados para imitar la conversación humana utilizando algoritmos de NLP, permitiendo así la recolección de síntomas y la provisión de recomendaciones de autocuidado. Estos sistemas son capaces de analizar grandes volúmenes de datos generados por los usuarios, clasificarlos y extraer insights valiosos mediante algoritmos de ML.

La arquitectura modular del Health Bot, por ejemplo, facilita la escalabilidad y la adaptabilidad del sistema, permitiendo su implementación en diversos escenarios de telemedicina.

2.1.1.4. Metodología empleada por los autores

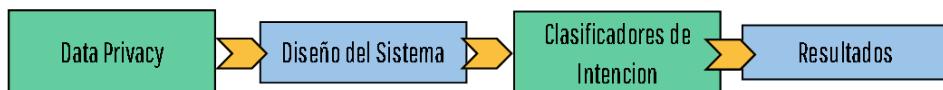


Figura 2.1: Metodología. Fuente: [Bharti et al., 2020](#)

- **Privacidad de Datos** Los datos del paciente son protegidos mediante algoritmos de encriptación asimétrica RSA/ECB/PKCS1PADDING. La clave privada RSA es protegida y solo accesible por la capa interna de la API hospitalaria. El Health Bot utiliza la clave pública para desencriptar las solicitudes, garantizando la seguridad de los datos .

- **Escalabilidad y Disponibilidad** Para asegurar la disponibilidad y escalabilidad de la plataforma, se ha implementado una arquitectura distribuida sin puntos únicos de falla, utilizando servicios de Google Cloud como funciones de Firebase, bases de datos y hosting, BigQuery ML y AI Cloud .

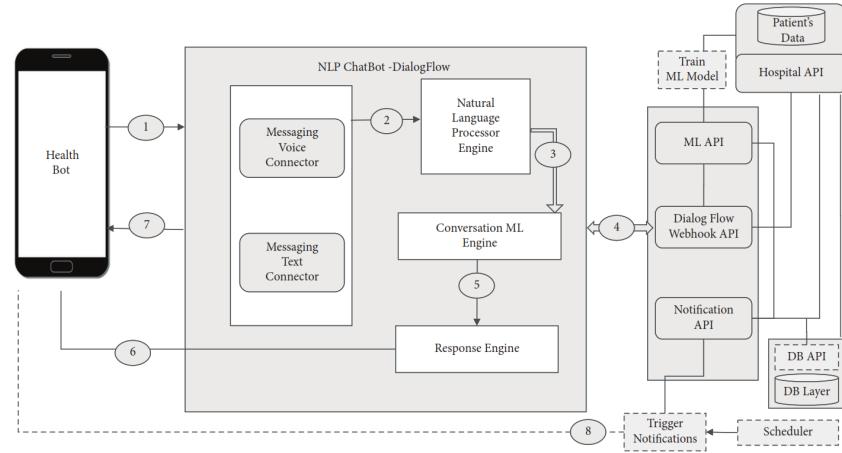


Figura 2.2: Escalabilidad y Disponibilidad. Fuente: [Vasileiou y Maglogiannis, 2022](#)

- **Interfaz de Usuario y Procesamiento NLP** El Health Bot UI soporta interfaces conversacionales basadas en texto y voz, desarrollado como una aplicación web progresiva (PWA) para proporcionar una experiencia de usuario nativa. El procesamiento NLP de DialogFlow clasifica las solicitudes de los pacientes y gestiona las respuestas utilizando un flujo de diálogo estructurado .

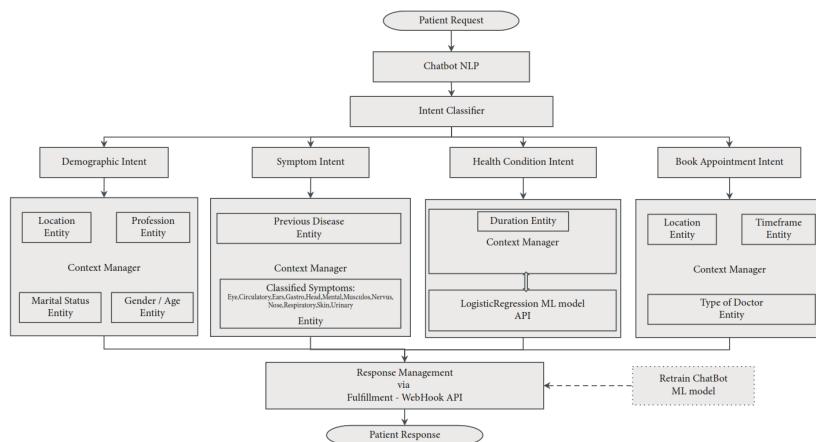


Figura 2.3: Interfaz de Usuario y Procesamiento NLP. Fuente: [Vasileiou y Maglogiannis, 2022](#)

- **Clasificadores de Intención** Los clasificadores de intención son responsables de identificar y manejar las preguntas demográficas del paciente, los síntomas conocidos, el estado actual de salud y la programación de citas. Cada intención se gestiona a través de un flujo de contexto que asegura la recogida precisa de datos y la respuesta adecuada del sistema.

2.1.1.5. Resultados obtenidos

Los resultados del estudio muestran que el Health Bot es capaz de predecir con alta precisión casos de Covid-19 y enfermedades cardíacas. Los modelos de ML entrenados lograron precisiones del 98.3% y 82%, respectivamente. En el caso del modelo de Covid-19, se utilizó un conjunto de datos emulado con 2100 filas, de las cuales el 80% se empleó para entrenamiento y el 20% para pruebas. El modelo de regresión logística utilizado para predecir enfermedades cardíacas fue entrenado con el conjunto de datos de Cleveland de UCI, logrando un rendimiento del 82% en precisión.

La implementación de algoritmos de ML y la integración de tecnologías de NLP permitieron una interacción más fluida y precisa entre los pacientes y el sistema de salud, mejorando así la experiencia del usuario y la eficiencia del diagnóstico

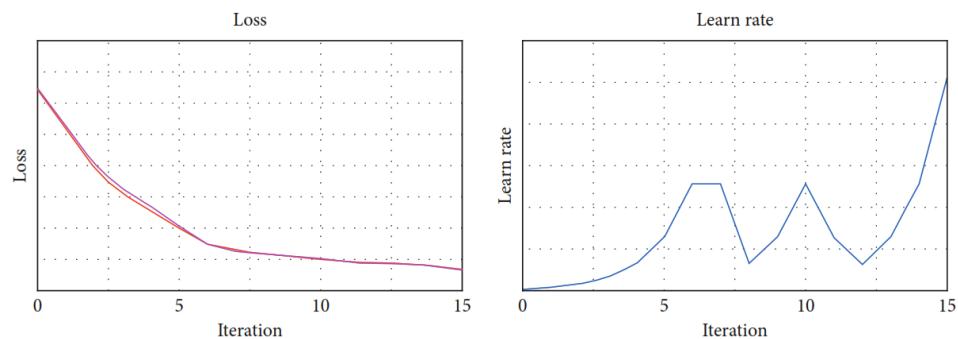


Figura 2.4: Resultado. Fuente: [Vasileiou y Maglogiannis, 2022](#)

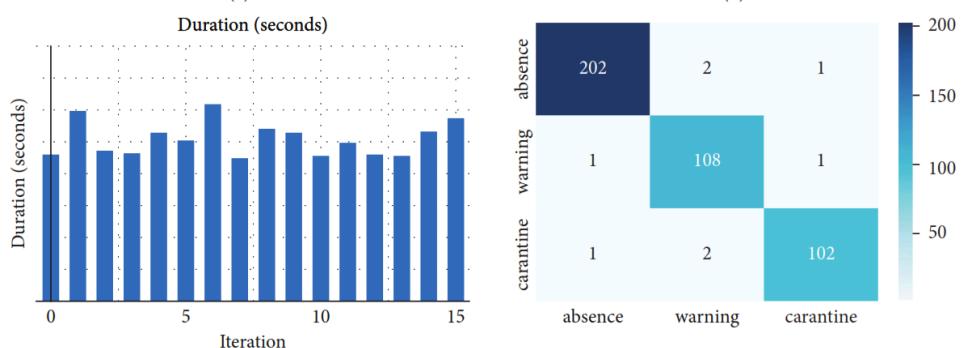


Figura 2.5: Resultado. Fuente: [Vasileiou y Maglogiannis, 2022](#)

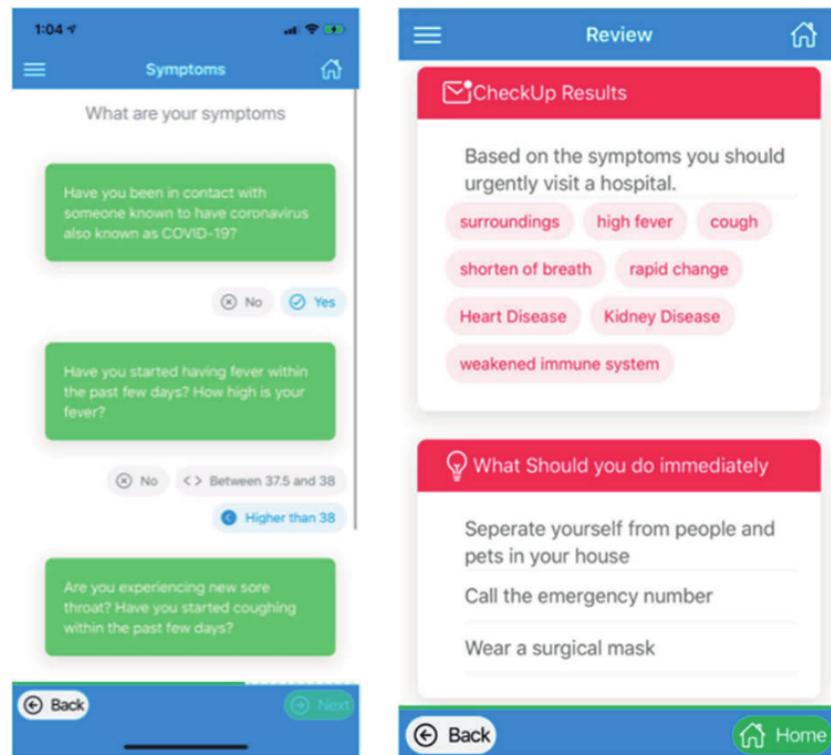


Figura 2.6: Resultado. Fuente: [Vasileiou y Maglogiannis, 2022](#)

2.1.2. PEFT-MedAware: Large Language Model for Medical Awareness (Pandya, 2023)

2.1.2.1. Planteamiento del Problema

El artículo "PEFT-MedAware: Large Language Model for Medical Awareness" de Keivalya Pandya aborda el desarrollo de un modelo de lenguaje especializado en la conciencia médica utilizando un enfoque de ajuste fino eficiente en parámetros (PEFT). El problema principal identificado es la inexactitud y la incertidumbre en las respuestas de los modelos de chat generalistas en el ámbito médico, donde la precisión y la fiabilidad son esenciales. Para abordar este problema, se propone un modelo específico, peft-MedAware, que utiliza PEFT para mejorar el modelo Falcon-1b con datos de MedQuAD, que contiene 16,407 pares de preguntas y respuestas médicas. Este enfoque optimiza el rendimiento del modelo utilizando solo el 0.44 % de sus parámetros entrenables, mejorando así la eficiencia computacional. El modelo resultante supera a otros LLMs en tareas de preguntas y respuestas médicas específicas, utilizando recursos computacionales limitados, es apropiado para ser implementado en entornos con limitaciones de recursos.

2.1.2.2. Objetivos

1. Desarrollar y optimizar el modelo peft-MedAware utilizando técnicas de PEFT para mejorar la precisión en la respuesta a consultas médicas específicas.
2. Aumentar la eficiencia en el entrenamiento de modelos mediante la utilización de configuraciones avanzadas de quantización.
3. Proporcionar respuestas médicas contextualmente relevantes y basadas en evidencia a partir de un amplio conjunto de datos médicos.

2.1.2.3. Fundamento Teórico

El fundamento teórico del artículo se basa en el uso de tecnologías avanzadas de procesamiento del lenguaje natural (NLP) y ajuste fino eficiente en parámetros (PEFT) para mejorar la precisión y eficiencia de los modelos de lenguaje en el ámbito médico.

- **Procesamiento del Lenguaje Natural (NLP)** Se utiliza para analizar y clasificar datos médicos en texto, permitiendo al modelo peft-MedAware proporcionar respuestas precisas y contextualmente relevantes a consultas médicas.
- **Ajuste Fino Eficiente en Parámetros (PEFT)** El PEFT es una técnica de optimización que ajusta solo los parámetros más influyentes de un modelo, lo que reduce significativamente la sobrecarga computacional y el tiempo de entrenamiento. Esta técnica es crucial cuando se trabaja con grandes modelos de lenguaje, ya que permite un uso más eficiente de los recursos computacionales.
- **Modelos de Lenguaje Grande (LLMs)** Los LLMs son modelos de inteligencia artificial que contienen miles de millones de parámetros y están diseñados para comprender y generar texto. Estos modelos tienen el potencial de revolucionar la búsqueda de información en el ámbito médico al proporcionar información precisa y actualizada. Sin embargo, su eficacia depende de su capacidad para ofrecer respuestas detalladas y específicas a consultas médicas.
- **Quantización** La configuración de BitsAndBytes se utiliza para procesar datos y actualizar pesos de manera eficiente durante el entrenamiento de transformadores. La quantización reduce la precisión de los datos procesados, lo que disminuye el consumo de memoria y permite manejar modelos más grandes o múltiples modelos simultáneamente sin sobrecargar los recursos del sistema.
- **Datasets Especializados** MedQuAD es un conjunto de datos de preguntas y respuestas médicas utilizado para entrenar el modelo peft-MedAware. Este dataset incluye pares

de preguntas y respuestas sobre una amplia variedad de enfermedades, medicamentos y otras entidades médicas, proporcionando una base sólida para el entrenamiento y la evaluación del modelo en tareas específicas de QA médico.

2.1.2.4. Metodología empleada por los autores

La metodología utilizada en el desarrollo del modelo peft-MedAware incluye varias etapas críticas, desde la preprocesamiento de datos hasta la implementación de técnicas de ajuste fino y cuantificación para optimizar el rendimiento del modelo.

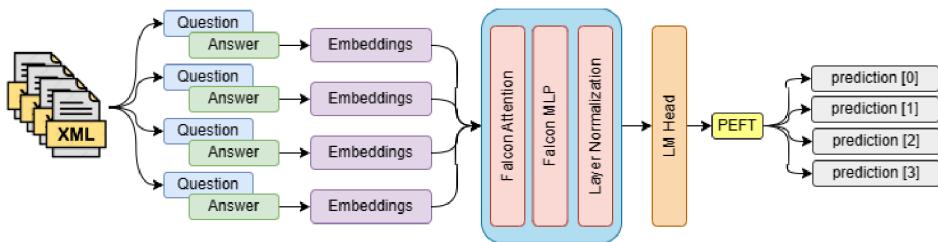


Figura 2.7: Metodología. Fuente: [Pandya, 2023](#)

1. Selección y Preprocesamiento de Datos:

Dataset MedQuAD: Se utilizó el conjunto de datos MedQuAD, que contiene 16,407 pares de preguntas y respuestas médicas, para entrenar el modelo. Este dataset está bien anotado y cubre una amplia variedad de tipos de preguntas relacionadas con enfermedades, tratamientos, diagnósticos y efectos secundarios.

Preprocesamiento: Se llevó a cabo un preprocesamiento exhaustivo de los datos para transformar las preguntas y respuestas en un formato adecuado para el entrenamiento del modelo. Esto incluye la limpieza de datos, normalización y etiquetado de entidades.

2. Entrenamiento del Modelo:

Ajuste Fino Eficiente en Parámetros (PEFT): Se aplicó PEFT para ajustar finamente el modelo Falcon-1b utilizando solo el 0.44 % de sus parámetros entrenables (aproximadamente 3 millones de 700 millones). Con esto se redujo la sobrecarga computacional.

Quantización: Se utilizó la configuración de BitsAndBytes para procesar los datos con precisión de 4 bits, lo que redujo el consumo de memoria y permitió un entrenamiento más eficiente en hardware diverso. Además, se empleó la técnica de doble quantización para capturar características intrincadas de los datos sin comprometer la precisión numérica.

3. Configuración del Modelo:

Carga del Modelo: El modelo se cargó utilizando precisión de 4 bits, lo que permitió manejar grandes volúmenes de datos y entrenar el modelo de manera eficiente en Google Colab T4 Runtime.

Optimización de Recursos: La reducción de la complejidad computacional permitió entrenar el modelo más rápidamente y conservar recursos, facilitando la experimentación con varios hiperparámetros y configuraciones sin sobrecargar el sistema.

4. Evaluación y Comparación:

Comparación con Otros Modelos: Se comparó el rendimiento del modelo peft-MedAware con otros modelos de lenguaje a gran escala, como ChatGPT y Baize-healthcare, en tareas de preguntas y respuestas médicas.

2.1.2.5. Resultados obtenidos

Los resultados del estudio muestran que el modelo peft-MedAware supera a otros modelos de lenguaje en tareas de preguntas y respuestas médicas específicas, utilizando recursos computacionales limitados. El modelo fue capaz de proporcionar respuestas precisas y contextualmente relevantes a una amplia gama de consultas médicas, demostrando una alta eficiencia y especialización. Además, la reducción en los requisitos computacionales permitió tiempos de entrenamiento más rápidos y una mejor eficiencia general del modelo. La implementación de técnicas de PEFT y cuantificación optimizada resultó en un modelo que es tanto preciso como eficiente, adecuado para su despliegue en entornos con restricciones de recursos.

2.1.3. Medbot: Conversational Artificial Intelligence Powered Chatbot for Delivering Tele-Health after COVID-19 ([Bharti, Bajaj, Batra, Lalit, Lalit & Gangwani, 2020](#))

2.1.3.1. Planteamiento del Problema

La pandemia de COVID-19 ha exacerbado los desafíos existentes en la atención médica, particularmente en áreas rurales de India, donde el acceso a servicios de salud es limitado. El artículo aborda la necesidad de una solución innovadora para superar estas barreras mediante el uso de inteligencia artificial (IA) y tecnologías de telemedicina. Específicamente, propone el desarrollo de un chatbot conversacional multilingüe llamado ".^apka Chikitsak", diseñado para proporcionar educación sanitaria primaria, asesoramiento y medidas preventivas a los pacientes

sin necesidad de visitar físicamente un hospital. Este enfoque no solo busca reducir la transmisión del virus, sino también mejorar la accesibilidad y la calidad de la atención médica en un contexto de recursos limitados.

2.1.3.2. Objetivos

1. Aliviar la presión sobre los servicios de salud presenciales mediante la provisión de consultas virtuales.
2. Ofrecer información sanitaria básica, medidas preventivas y remedios caseros para enfermedades prevalentes.
3. Utilizar procesamiento de lenguaje natural y arquitectura sin servidor para crear un sistema eficiente y escalable.

2.1.3.3. Fundamento Teórico

El fundamento teórico del artículo se basa en varios pilares de la inteligencia artificial y la telemedicina:

- **Inteligencia Artificial en Salud:** La IA ha demostrado ser eficaz en la simulación de interacciones humanas para proporcionar atención médica. Ejemplos previos incluyen sistemas como ELIZA y PARRY, que imitan interacciones humanas para fines terapéuticos y de diagnóstico.
- **Procesamiento de Lenguaje Natural (NLP):** El uso de NLP permite que los chatbots comprendan y respondan a las consultas de los usuarios en lenguaje natural, facilitando interacciones más humanas y efectivas. Esto incluye la conversión de voz a texto y viceversa, esencial para la funcionalidad del chatbot en múltiples idiomas.
- **Telemedicina:** La telemedicina permite la distribución de servicios de salud a distancia, reduciendo la necesidad de visitas físicas a los centros de salud.
- **Arquitectura sin Servidor:** El (serverless) permite implementar servicios de backend sin necesidad de infraestructura dedicada, lo que facilita la escalabilidad y la eficiencia del sistema.

2.1.3.4. Metodología empleada por los autores

La metodología empleada en el desarrollo del chatbot "Aapka Chikitsak" incluye varios componentes clave:

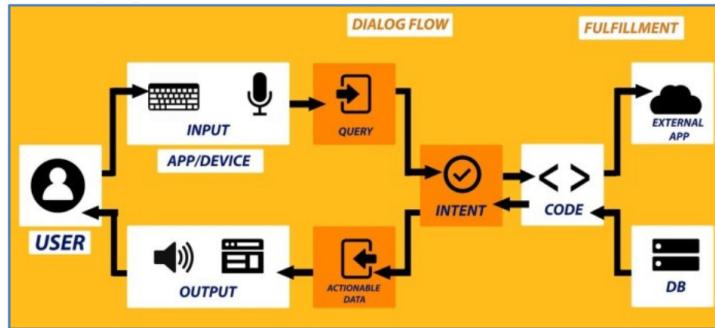


Figura 2.8: Metodología. Fuente: Bharti et al., 2020

- 1. Análisis de Requisitos:** Se identificaron las necesidades de los usuarios, particularmente en áreas rurales, para diseñar un sistema que sea accesible y fácil de usar.
- 2. Diseño de la Arquitectura:** La aplicación se construyó sobre una arquitectura sin servidor utilizando Google Cloud Platform (GCP) y Firebase Cloud Functions.
- 3. Desarrollo del Chatbot:** Se desarrolló un chatbot multilingüe utilizando el API de Dialogflow para la creación de una interfaz conversacional automatizada. El chatbot puede manejar entradas de voz y texto, procesarlas usando NLP y generar respuestas adecuadas.
- 4. Entrenamiento del Modelo:** Se entrenaron modelos de NLP para reconocer y entender diversas consultas de salud. Los modelos se alimentaron con datos relevantes para mejorar su precisión en la identificación de síntomas y la provisión de consejos médicos.
- 5. Pruebas y Despliegue:** La aplicación se integró con diversas bases de datos de salud y se sometió a pruebas exhaustivas para asegurar su funcionalidad y precisión. Se realizaron pruebas de usuario para ajustar la interfaz y mejorar la experiencia del usuario. El sistema se desplegó en la infraestructura de GCP, asegurando su disponibilidad y accesibilidad.

2.1.3.5. Resultados obtenidos

Los resultados del estudio muestran que el chatbot "Aapka Chikitsak" ha logrado reducir significativamente las barreras de acceso a los servicios de salud en las áreas rurales de India. El bot proporciona información sobre las enfermedades más prevalentes, medidas preventivas, remedios caseros y recomendaciones dietéticas basadas en la ubicación del usuario. Además, ofrece sesiones de asesoramiento interactivo para el apoyo emocional y la atención prenatal. La implementación del chatbot ha demostrado ser eficaz en la detección de enfermedades comunes y la provisión de soluciones inmediatas y eficientes a los pacientes.

2.1.4. Intelligent Chatbot for Medical Assistance in Rural Areas ([Arulmangainayaki, Harini, Keerthiga & Priya*, 2020](#))

2.1.4.1. Planteamiento del Problema y objetivo

El artículo [Intelligent Chatbot for Medical Assistance in Rural Areas](#)^aborda la problemática de la falta de acceso a servicios médicos en las áreas rurales de la India, donde la mayoría de los doctores y facilidades hospitalarias están concentrados en zonas urbanas. Esto deja a millones de personas sin acceso adecuado a atención médica. Para abordar esta disparidad, los autores han desarrollado una aplicación de chatbot que actúa como un asistente médico virtual, diseñado para conectar a los pacientes rurales con médicos y proporcionar asistencia médica básica. La aplicación utiliza inteligencia artificial para responder consultas médicas, recomendar prácticas de tratamiento y derivar a los pacientes a médicos en casos de problemas más graves. El objetivo es ofrecer una herramienta accesible que pueda brindar información médica esencial, mejorar la autogestión de la salud y reducir la carga sobre los servicios de salud urbanos.

2.1.4.2. Fundamento Teórico

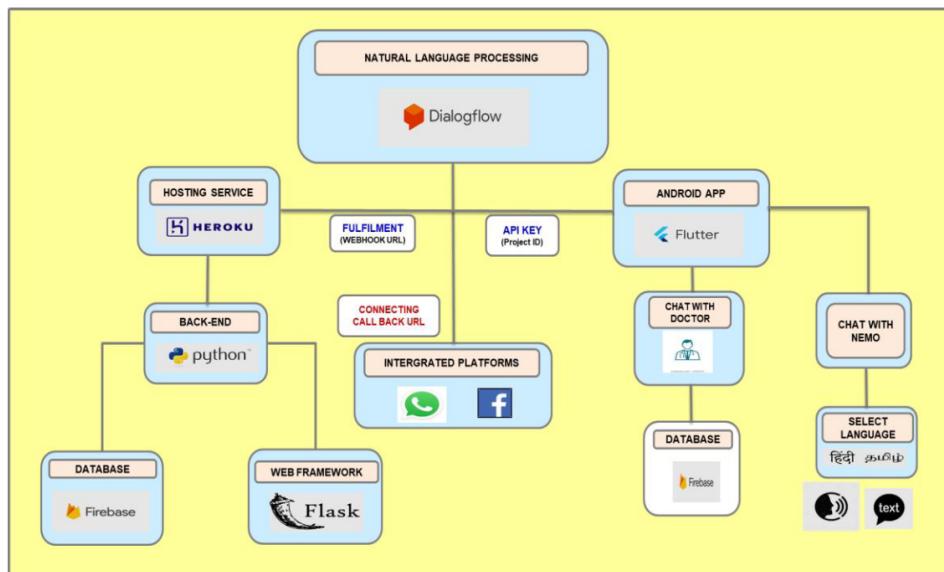


Figura 2.9: Resultado. Fuente: [Arulmangainayaki et al., 2020](#)

- **Procesamiento de Lenguaje Natural (NLP):** El NLP permite que los chatbots entiendan y procesen el lenguaje humano. Utilizando algoritmos de NLP, el chatbot puede interpretar las consultas de los usuarios y proporcionar respuestas adecuadas. Esto incluye la identificación de síntomas y la recomendación de tratamientos básicos.

- **Arquitectura Sin Servidor:** La aplicación se basa en una arquitectura sin servidor utilizando servicios como Heroku y Firebase. Esto permite una fácil escalabilidad y una gestión eficiente de los recursos, reduciendo la necesidad de infraestructura física.
- **Dialogflow:** Esta herramienta se utiliza para desarrollar interfaces conversacionales que soportan la interacción en lenguaje natural. Dialogflow permite la creación de agentes que pueden comprender y responder a las consultas de los usuarios, facilitando una interacción fluida y eficiente.
- **Flask y Flutter:** Flask se utiliza como marco web para el desarrollo del backend, mientras que Flutter se emplea para la creación de la interfaz de usuario de la aplicación móvil. Estas herramientas permiten una integración efectiva y una experiencia de usuario intuitiva.
- **Algoritmos de Aprendizaje Automático:** Se utilizan algoritmos como Naive Bayes y árboles de decisión para clasificar las consultas de los usuarios y proporcionar respuestas precisas. Estos algoritmos permiten al chatbot aprender y mejorar continuamente a medida que interactúa con más usuarios

2.1.4.3. Metodología empleada por los autores

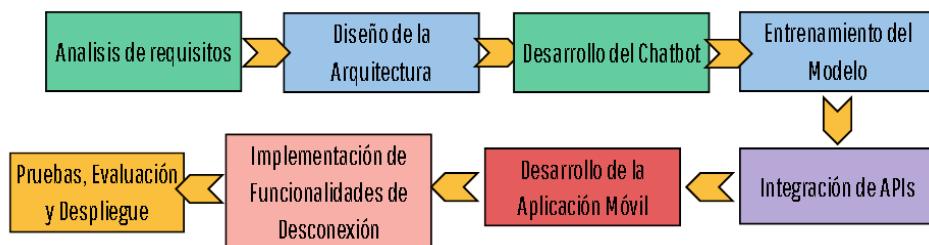


Figura 2.10: Metodología. Fuente: Bharti et al., 2020

1. Análisis de Requisitos:

Se realizó un análisis detallado de las necesidades de los usuarios, especialmente en áreas rurales, para diseñar un sistema que sea accesible y fácil de usar.

2. Diseño de la Arquitectura:

La aplicación se construyó sobre una arquitectura sin servidor utilizando Heroku y Firebase, lo que permite una fácil escalabilidad y reduce la necesidad de infraestructura física.

3. Desarrollo del Chatbot:

Se utilizó Dialogflow para crear un agente conversacional que puede manejar entradas de voz y texto. El chatbot utiliza NLP para interpretar las consultas de los usuarios y proporcionar respuestas adecuadas.

4. Entrenamiento del Modelo:

Se entrenaron modelos de NLP para reconocer y entender diversas consultas de salud. Estos modelos se alimentaron con datos relevantes para mejorar su precisión en la identificación de síntomas y la provisión de consejos médicos.

5. Integración de APIs:

Se integraron varias APIs, como la API de DrugBank para información sobre medicamentos y la API de Practo para datos de médicos. Esto permite al chatbot proporcionar información precisa y relevante sobre tratamientos y profesionales de la salud.

6. Desarrollo de la Aplicación Móvil:

Se utilizó Flutter para desarrollar la aplicación móvil, lo que permite una interfaz de usuario intuitiva y una experiencia de usuario fluida. La aplicación está diseñada para ser utilizada en dispositivos Android.

7. Implementación de Funcionalidades de Desconexión:

Dado que muchas áreas rurales tienen acceso limitado a Internet, se implementaron funcionalidades de comunicación fuera de línea utilizando Twilio. Esto permite a los usuarios interactuar con el chatbot a través de mensajes de texto y llamadas telefónicas, incluso sin una conexión a Internet.

8. Pruebas, Evaluación y Despliegue:

La aplicación se sometió a pruebas exhaustivas para asegurar su funcionalidad y precisión. Se realizaron pruebas de usuario para ajustar la interfaz y mejorar la experiencia del usuario. Además, se evaluó la precisión de las respuestas del chatbot mediante la comparación con respuestas proporcionadas por profesionales de la salud. El sistema se desplegó en la infraestructura de Heroku y Firebase, asegurando su disponibilidad y accesibilidad.

2.1.4.4. Resultados obtenidos

Los resultados presentados en el estudio muestran que el chatbot es capaz de proporcionar información médica precisa y útil a los usuarios rurales, mejorando significativamente el acceso a servicios médicos básicos. La aplicación ha sido bien recibida por los usuarios,

con una alta tasa de interacción y satisfacción. El análisis de las sesiones de usuario indica que el chatbot maneja eficazmente una variedad de consultas médicas, proporcionando respuestas rápidas y relevantes. Los usuarios han utilizado principalmente el chatbot para consultas sobre síntomas comunes, medicación y recomendaciones de primeros auxilios. Además, la capacidad del chatbot para operar sin conexión constante a internet ha sido un factor crucial en su aceptación y uso en áreas rurales con infraestructura limitada de internet.

INTENT	SESSIONS	COUNT	EXIT %
FIND DOCTOR	10	52	1.92
FIND DOCTOR-CUSTOM	8	48	18.75
SMALLTALK.GREETINGS.HELLO	6	22	18.18
WEATHER	5	16	12.50
FEVER	4	12	8.33
FIND HOSPITAL	5	11	2.50
FIND HOSPITAL-CUSTOM	4	9	22.22
WEATHER-CUSTOM	2	9	8.90
DIABETES	3	7	2.10

Tabla 2.1: Resultado. Fuente: [Arulmangainayaki et al., 2020](#)

2.1.5. HHH: An Online Medical Chatbot System based on Knowledge Graph and Hierarchical Bi-Directional Attention ([Bao, Ni & Liu, 2020](#))

2.1.5.1. Planteamiento del Problema y objetivo

El artículo "HHH: An Online Medical Chatbot System based on Knowledge Graph and Hierarchical Bi-Directional Attention.^aborda los problemas que enfrentan los pacientes para acceder a servicios de atención primaria, como la dificultad para ver a un médico, largos tiempos de espera y la inconveniencia de hacer citas. Para abordar estos desafíos, los autores proponen un sistema de chatbot médico que combina un grafo de conocimiento con un modelo de atención bidireccional jerárquico (HBAM). El chatbot, denominado HHH (Healthcare Helper System), está diseñado para responder preguntas médicas complejas utilizando un grafo de conocimiento construido a partir de datos médicos recopilados de Internet y un modelo de similitud de texto basado en aprendizaje profundo. Este enfoque híbrido permite al chatbot comprender y responder preguntas en lenguaje natural, proporcionando respuestas precisas y relevantes a los usuarios con poco conocimiento médico. El objetivo principal es mejorar la eficiencia y calidad del servicio médico, facilitando el acceso a información médica y reduciendo

el desperdicio de recursos.

2.1.5.2. Fundamento Teórico

El fundamento teórico del trabajo se basa en la combinación de dos enfoques: grafo de conocimiento y HBAM para procesar y responder preguntas en el contexto médico.

- **Grafo de Conocimiento:** El grafo de conocimiento almacena información médica, incluyendo enfermedades, síntomas, tratamientos y relaciones entre estos conceptos. Este proporciona respuestas rápidas y precisas a preguntas bien definidas, aprovechando la estructura organizada y fácilmente consultable del grafo.
- **Modelo de Atención Jerárquico Bidireccional (HBAM):** Este modelo es una extensión de los modelos LSTM (Long Short-Term Memory), que son una clase de redes neuronales recurrentes (RNN) diseñadas para procesar secuencias de datos. El HBAM incluye una capa de BiLSTM que captura información de contexto en ambas direcciones (hacia adelante y hacia atrás) y una capa de atención que resalta las palabras clave en una oración.
- **Siamese Framework y Distancia Manhattan:** El modelo utiliza un enfoque de redes siamés, donde dos redes idénticas comparten los mismos pesos para procesar dos entradas diferentes y comparar sus representaciones. La distancia Manhattan se utiliza para medir la similitud semántica entre las representaciones de las oraciones.

2.1.5.3. Metodología empleada por los autores

La metodología adoptada para el desarrollo del sistema HHH incluye varios componentes y pasos clave para garantizar su efectividad y precisión:

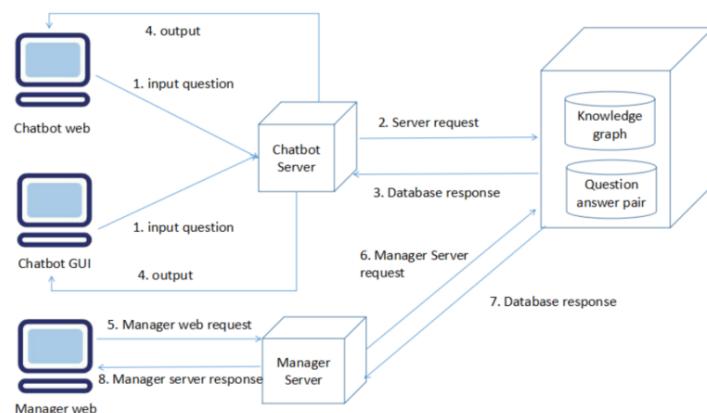


Figura 2.11: Metodología. Fuente: [Bao et al., 2020](#)

1. Diseño de la Arquitectura del Sistema:

Arquitectura del Gráfico de Conocimiento: Se desarrolló utilizando Neo4j, que almacena datos sobre enfermedades, síntomas y tratamientos. El gráfico contiene 3,500 entidades y 4,500 relaciones.

Modelo HBAM: Incluye una capa de LSTM bidireccional y una capa de atención de palabras, diseñada para comparar la similitud semántica entre preguntas y respuestas en el dataset.

2. Implementación del Gráfico de Conocimiento:

Almacenamiento y Recuperación de Datos: El gráfico de conocimiento se construyó a partir de datos médicos recopilados de diversas fuentes en línea. El proceso de selección de respuestas implica la extracción de entidades relevantes y la identificación de la intención del usuario.

Extracción de Entidades y Reconocimiento de Intenciones: Utiliza el algoritmo Aho-Corasick para identificar entidades médicas en las preguntas de los usuarios y un módulo de reconocimiento de intenciones para predecir la intención del usuario basada en bibliotecas de predicados predefinidos.

3. Desarrollo del Modelo HBAM:

Entrenamiento y Pruebas: El modelo se entrenó utilizando un subconjunto del dataset de preguntas duplicadas de Quora, que contiene pares de preguntas y respuestas médicas. Se utilizó una capa de LSTM bidireccional para capturar la información contextual y una capa de atención para resaltar las palabras clave en las preguntas.

Evaluación del Modelo: Se comparó el rendimiento del HBAM con otros modelos de vanguardia como BERT y MaLSTM. Los resultados mostraron que HBAM tiene un mejor rendimiento en términos de precisión en la similitud semántica.

4. Integración de la Interfaz de Usuario:

Interfaz Web y GUI Local: Se desarrollaron para permitir la interacción del usuario con el chatbot. La interfaz web facilita el acceso remoto, mientras que la GUI local proporciona una experiencia de usuario enriquecida.

5. Pruebas y Evaluación del Sistema:

Pruebas de Usuario: Se realizaron pruebas exhaustivas para asegurar la funcionalidad y precisión del sistema. Los usuarios interactuaron con el chatbot para evaluar la calidad de las respuestas y la facilidad de uso de la interfaz.

6. Despliegue y Mantenimiento:

Implementación en Entornos Reales: El sistema se desplegó en entornos de producción para evaluar su rendimiento en situaciones reales. Se implementó un sistema de monitoreo continuo para mantener la calidad del servicio y realizar mejoras basadas en el feedback de los usuarios.

2.1.5.4. Resultados obtenidos

Los resultados obtenidos muestran que el modelo HBAM supera a otros modelos de última generación desde el punto de vista de precisión en la predicción de la similitud de oraciones médicas. En los experimentos realizados, el HBAM logró una precisión promedio del 81.2 %, comparado con el 78.2 % de BERT y el 78.4 % de MaLSTM. Estos resultados indican que el HBAM es más efectivo en la comprensión de consultas médicas y la provisión de respuestas precisas.

Además, el sistema HHH demostró ser capaz de manejar una variedad de preguntas médicas, proporcionando respuestas precisas y relevantes tanto desde el grafo de conocimiento como mediante la comparación de similitud de texto. Los experimentos adicionales realizados con conjuntos de datos médicos adicionales confirmaron la robustez y flexibilidad del modelo HBAM, mostrando un rendimiento consistente en diferentes escenarios de prueba.

Tabla 2.2: Metodos de comparacion. Fuente: [Bao et al., 2020](#)

Methods	Average Evaluation Accuracy	Range of Change by 30 Times Experiments
BERT [7]	78.2 %	(-1.8 %,+1.3 %)
MaLSTM [9]	78.4 %	(-2.9 %,+2.0 %)
HBAM	81.2 %	(-2.4 %,+2.2 %)

Medical website name	Method name	Average predict accuracy	Range of change by 10 times experiments
ehealthforumQAs	BERT	78.5 %	(-1.8 %, +1.1 %)
	HBAM	81.3 %	(-1.2 %, +1.1 %)
	MaLSTM	78.4 %	(-2.9 %, +1.5 %)
questionDoctorQAs	BERT	78.2 %	(-1.4 %, +0.9 %)
	HBAM	80.9 %	(-2.1 %, +2.5 %)
	MaLSTM	78.1 %	(-1.7 %, +1.9 %)
webmdQAs	BERT	78.1 %	(-1.6 %, +0.9 %)
	HBAM	81.2 %	(-1.2 %, +1.3 %)
	MaLSTM	78.5 %	(-1.5 %, +1.9 %)

Tabla 2.3: Resultado de exactitud. Fuente: [Bao et al., 2020](#)

2.1.6. HealFavor: Dataset and A Prototype System for Healthcare Chat-Bot ([Ur Rahman Khilji, Laskar, Pakray, Kadir, Lydia & Bandopadhyay, 2020](#))

2.1.6.1. Planteamiento del Problema

El acceso a servicios médicos puede ser difícil debido a varios factores, como la escasez de médicos, largos tiempos de espera y la inconveniencia de hacer citas. Estas barreras afectan tanto a pacientes como a proveedores de servicios de salud, resultando en un uso ineficiente de los recursos disponibles. En respuesta a estos desafíos, se han desarrollado sistemas innovadores como los chatbots médicos basados en inteligencia artificial. Estos sistemas tienen el potencial de simular conversaciones en tiempo real, proporcionando asistencia médica interactiva y personalizada. El trabajo presentado propone el desarrollo de un chatbot médico llamado HealFavor, que utiliza un conjunto de datos autogenerado y una arquitectura prototípica para mejorar la accesibilidad médica y proporcionar respuestas precisas a consultas médicas comunes.

2.1.6.2. Fundamento Teórico

El fundamento teórico del sistema de chatbot HealFavor se basa en la integración de técnicas avanzadas de inteligencia artificial y procesamiento de lenguaje natural (NLP). Estos enfoques permiten al sistema comprender y responder a consultas médicas en lenguaje natural, proporcionando respuestas precisas y relevantes.

- **Sistemas de Chatbot Históricos y Contemporáneos** El desarrollo de chatbots se remonta a sistemas pioneros como ELIZA, desarrollado en la década de 1960, que utilizaba patrones de scripts codificados para simular conversaciones. ALICE, que utilizaba patrones basados en el lenguaje de marcado de inteligencia artificial (AIML), mejoró esta capacidad al almacenar respuestas en archivos AIML. Sistemas más recientes como Jabberwacky y Cleverbot no solo utilizan respuestas preprogramadas, sino que también aprenden de las interacciones pasadas para mejorar sus respuestas
- **Arquitectura del Sistema:** La aplicación HealFavor se basa en el marco de RASA, utilizando políticas de diálogo embebidas recurrentes para la generación de respuestas. La integración con MongoDB permite el almacenamiento en tiempo real de historiales de chat y análisis de informes médicos, facilitando un sistema escalable y eficiente.

2.1.6.3. Metodología empleada por los autores

La metodología adoptada para el desarrollo del sistema HHH incluye varios componentes y pasos clave para garantizar su efectividad y precisión:

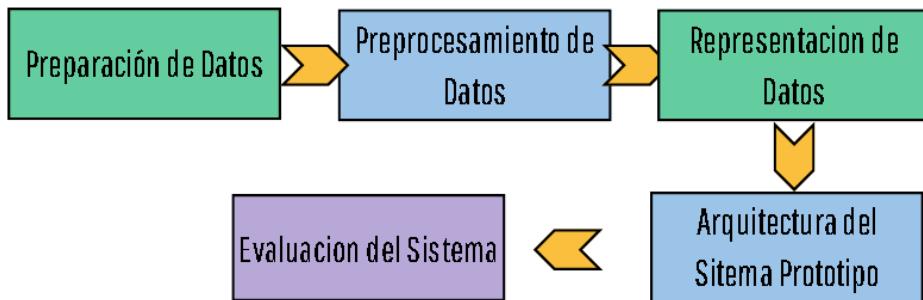


Figura 2.12: Metodología. Fuente: Bharti et al., 2020

1. Preparación de Datos:

Fuentes y Observaciones: Los datos se recopilaron de fuentes confiables como WebMD y Drugs.com, y se consultó con expertos médicos para obtener información sobre síntomas comunes.

Calidad y Filtrado: Los datos preparados se verificaron para asegurar su consistencia y relevancia. Se realizaron grandes clasificaciones iniciales para abarcar un amplio conjunto de enfermedades y luego se refinaron según síntomas específicos.

2. Preprocesamiento de Datos:

Técnicas Utilizadas: Incluyen conversión a minúsculas, eliminación de palabras vacías, tokenización y lematización para mejorar la clasificación y precisión de los datos.

3. Representación de Datos:

Clasificación de Intenciones: Se desarrollaron módulos para clasificar las intenciones de los pacientes como un problema de clasificación múltiple. Las secuencias de intenciones se utilizaron para predecir las respuestas y continuar la conversación.

Predicción de Secuencias: Se prepararon conjuntos exhaustivos de secuencias para diferentes casos de uso de pacientes, incluyendo preguntas relacionadas con la salud y la reserva de citas.

4. Arquitectura del Sistema Prototipo:

Marco RASA: Utiliza políticas de diálogo embebidas recurrentes inspiradas en el algoritmo StarSpace de Facebook AI Research. Se crean vectores de características utilizando la representación de Bag of Words (BoW) y se generan incrustaciones a través de capas densas para la entrada del paciente y las acciones del sistema.

Mecanismo de Atención: El input del usuario y el output previo de la red se alimentan en un modelo recurrente para calcular la atención, utilizando la suma total del output de la capa de incrustación y del mecanismo de atención para generar la respuesta final.

5. Evaluación del Sistema:

Pruebas de Usuario: Se realizaron pruebas exhaustivas con evaluadores que hicieron un total de 162 preguntas al sistema. Las respuestas se calificaron en una escala de 1 a 3, obteniendo una precisión total del 46.50 %.

2.1.6.4. Resultados obtenidos

El sistema de chatbot HealFavor ha demostrado ser efectivo en la provisión de respuestas precisas y relevantes a preguntas médicas comunes. Los resultados de las pruebas de usuario mostraron una alta satisfacción con la precisión de las respuestas y la facilidad de uso de la interfaz. El sistema alcanzó una precisión del 46.50 % en la clasificación de respuestas correctas, lo que indica una mejora significativa en la accesibilidad médica y la eficiencia del sistema de salud. La integración con MongoDB permitió el almacenamiento en tiempo real de historiales de chat y análisis de informes médicos, facilitando un sistema escalable y eficiente.

2.1.7. ChatDoctor: A Medical Chat Model Fine-Tuned on a Large Language Model Meta-AI (LLaMA) Using Medical Domain Knowledge (Li, Li, Zhang, Dan, Jiang & Zhang, 2023)

2.1.7.1. Planteamiento del Problema

El acceso a consultas médicas precisas y oportunas sigue siendo un desafío significativo, especialmente en regiones con recursos médicos limitados. Los modelos de lenguaje grandes (LLMs) como ChatGPT han demostrado capacidades impresionantes en tareas generales de procesamiento del lenguaje natural (NLP), pero su rendimiento en el dominio médico es limitado debido a la falta de entrenamiento específico en conocimientos médicos. Esto puede resultar en respuestas incorrectas que pueden ser perjudiciales en un contexto médico. Para abordar esta limitación, se desarrolló el modelo ChatDoctor, afinado específicamente en el conocimiento del dominio médico utilizando el modelo LLaMA. Este modelo busca mejorar la precisión y relevancia de las respuestas médicas, proporcionando así un apoyo más fiable y accesible para los pacientes y profesionales de la salud.

2.1.7.2. Fundamento Teórico

El desarrollo de ChatDoctor se basa en varios principios teóricos y tecnológicos clave:

- **Modelo de Lenguaje Grande (LLM):** Los LLMs como LLaMA se entrenan inicialmente en grandes cantidades de datos textuales para predecir la siguiente palabra en una secuencia, desarrollando así habilidades generales de lenguaje. Estos modelos luego se afinan utilizando conjuntos de datos específicos del dominio para mejorar su rendimiento en tareas especializadas.
- **Afine del Modelo con Datos Específicos del Dominio:** ChatDoctor se afina utilizando un conjunto de datos de 100,000 conversaciones médico-paciente reales recopiladas de una plataforma de consulta médica en línea. Este enfoque asegura que el modelo desarrolle una comprensión profunda de las consultas y respuestas médicas auténticas.
- **Recuperación Autónoma de Información:** Para mitigar las limitaciones inherentes a los LLMs, como las respuestas erróneas, se incorpora una base de conocimientos externos que el modelo puede consultar en tiempo real. Esta base de conocimientos incluye bases de datos médicas confiables y recursos en línea como Wikipedia. La recuperación de información se realiza a través de prompts configurados que extraen términos clave de las consultas del paciente y buscan la información relevante en la base de conocimientos.
- **Evaluación de Rendimiento:** El rendimiento de ChatDoctor se evalúa utilizando métricas estándar como precisión, recuerdo y puntuación F1, comparándolo con otros modelos como ChatGPT. Estas evaluaciones se realizan utilizando respuestas de médicos humanos como referencia para garantizar la relevancia y exactitud de las respuestas generadas por el modelo.

2.1.7.3. Metodología empleada por los autores

La metodología adoptada para el desarrollo del sistema HHH incluye varios componentes y pasos clave para garantizar su efectividad y precisión:

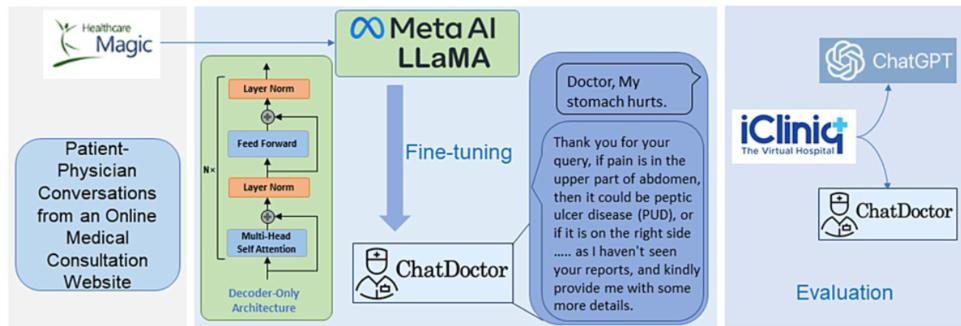


Figura 2.13: Metodología del proceso del modelo del ChatDoctor. Fuente: [Li et al., 2023](#)

1. Recolección y Preparación de Datos:

Dataset de Conversaciones Médico-Paciente: Se recopilaron alrededor de 100,000 interacciones médico-paciente de la plataforma HealthCareMagic. Estas conversaciones se limpiaron y anonimizaron para respetar la privacidad de los participantes.

Filtrado de Conversaciones: Se eliminaron automáticamente las conversaciones demasiado cortas y se filtraron manualmente las respuestas con errores. Se utilizó LanguageTool para corregir errores gramaticales y asegurar la calidad de los datos.

Dataset de Pruebas: Se recopilaron alrededor de 10,000 conversaciones adicionales de iCliniq para probar el rendimiento del modelo.

2. Desarrollo de la Base de Conocimientos Externa:

Curación de la Base de Datos: Se creó una base de datos que incluye enfermedades, síntomas, pruebas médicas y tratamientos utilizando fuentes confiables como Medline-Plus. Esta base de datos es actualizable continuamente sin necesidad de reentrenamiento del modelo.

Recuperación de Información: Se diseñaron prompts específicos para extraer términos clave de las consultas del paciente y buscar información relevante en la base de conocimientos. Este proceso asegura respuestas precisas y respaldadas por fuentes confiables.

3. Entrenamiento del Modelo:

Modelo LLaMA: Se utilizó el modelo LLaMA de Meta, entrenado en 1.0 billón de tokens de fuentes de datos públicas. Este modelo fue afinado primero con datos del proyecto Alpaca de Stanford y luego con el dataset HealthCareMagic-100k utilizando 6 GPUs A100 durante tres horas.

Parámetros de Entrenamiento: Los parámetros incluyeron un tamaño de batch total de 192, una tasa de aprendizaje, 3 épocas, una longitud máxima de secuencia de 512 tokens y una proporción de calentamiento de 0.03, sin decaimiento de peso.

4. Evaluación del Modelo:

Pruebas de Rendimiento: Se utilizaron preguntas del dataset iCliniq como entradas y las respuestas de médicos humanos como referencia. Se empleó BERTScore para evaluar la precisión, el recuerdo y la puntuación F1 de las respuestas generadas por ChatDoctor en comparación con ChatGPT.

Comparaciones Cualitativas: Se realizaron comparaciones detalladas entre las respuestas de ChatDoctor y ChatGPT en términos de precisión y relevancia para diversas consultas médicas contemporáneas.

2.1.7.4. Resultados obtenidos

El modelo ChatDoctor mostró un rendimiento superior en la provisión de respuestas médicas precisas y relevantes en comparación con ChatGPT. En pruebas cualitativas, ChatDoctor fue capaz de responder correctamente a preguntas sobre términos médicos recientes como Monkeypox y medicamentos aprobados recientemente como Daybue, gracias a su capacidad de recuperación autónoma de información. En evaluaciones cuantitativas utilizando BERTScore, ChatDoctor superó a ChatGPT en precisión, recuerdo y puntuación F1, demostrando su efectividad en proporcionar respuestas médicas fiables. Estas mejoras subrayan el potencial de ChatDoctor para asistir en consultas médicas preliminares y mejorar la accesibilidad a la información médica precisa.

	ChatGPT	ChatDoctor	P-value
Precision	0.8374 ± 0.0188	0.8444 ± 0.0185	$6,66 \times 10^{-19}$
Recall	0.8445 ± 0.0164	0.8451 ± 0.0157	$4,71 \times 10^{-4}$
F1 Score	0.8406 ± 0.0143	0.8446 ± 0.0138	$2,14 \times 10^{-111}$

Tabla 2.4: Comparación entre el BERTScore entre ChatDoctor y ChatGPT. Fuente: [Li et al., 2023](#)

2.1.8. Auto Response Generation in Online Medical Chat Services ([Jahanshahi, Kazmi & Cevik, 2022](#))

2.1.8.1. Planteamiento del Problema y objetivo

El acceso a servicios médicos de calidad y la eficiencia en la comunicación entre médicos y pacientes son desafíos significativos en el campo de la telemedicina. Con el aumento de la demanda de consultas médicas en línea debido a la pandemia de COVID-19 y otros factores, los profesionales de la salud enfrentan una carga de trabajo elevada que puede afectar la calidad de la atención médica. En respuesta a este problema, el estudio propone un mecanismo de

generación de respuestas automáticas inteligentes para servicios de chat médico en línea, con el objetivo de mejorar la eficiencia de las interacciones entre médicos y pacientes y reducir los tiempos de espera. Este mecanismo se basa en algoritmos de aprendizaje automático y procesamiento de lenguaje natural para identificar y generar respuestas adecuadas a las consultas de los pacientes, mejorando así la experiencia general del usuario y la efectividad del servicio de telemedicina.

2.1.8.2. Fundamento Teórico

El desarrollo del sistema de generación de respuestas automáticas inteligentes se basa en varias tecnologías y teorías clave:

- **Procesamiento de Lenguaje Natural (NLP):** En este estudio, se utilizan técnicas de NLP para analizar y procesar las consultas de los pacientes, permitiendo la generación de respuestas adecuadas basadas en la comprensión del contexto y la semántica del texto.
- **Modelos de Aprendizaje Automático:** Se emplean varios algoritmos de aprendizaje automático, incluyendo BERT, BiLSTM, y XGBoost, para entrenar el sistema con un gran conjunto de datos de conversaciones médicas. Estos modelos aprenden a identificar patrones y generar respuestas basadas en el historial de interacciones médicas.
- **Clustering y Filtrado de Datos:** Se utilizan algoritmos de clustering para agrupar respuestas médicas similares y etiquetar manualmente los datos, creando un conjunto de respuestas prediseñadas que el sistema puede utilizar. Este enfoque asegura que las respuestas generadas sean coherentes y relevantes para las consultas de los pacientes.
- **Evaluación y Mejora Continua:** El rendimiento del sistema se evalúa mediante métricas estándar como precisión, recuerdo y puntuación F1, comparando las respuestas generadas con las respuestas proporcionadas por médicos humanos. Este proceso de evaluación permite identificar áreas de mejora y ajustar los modelos para mejorar la precisión y relevancia de las respuestas.

2.1.8.3. Metodología empleada por los autores

La metodología empleada para desarrollar el sistema de generación de respuestas automáticas inteligentes incluye varias etapas clave:

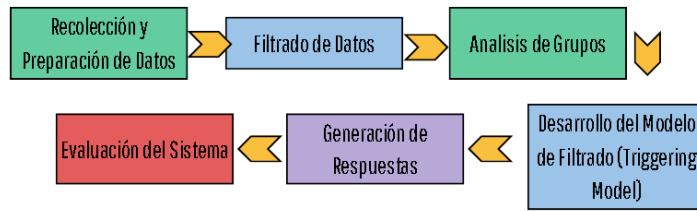


Figura 2.14: Metodología. Fuente: Bharti et al., 2020

1. Recolección y Preparación de Datos:

Dataset de Conversaciones Médico-Paciente: Se recopilaron más de 900,000 mensajes históricos entre médicos y pacientes a lo largo de 9 meses. Estos datos se anonimizaron y se prepararon para el análisis.

Filtrado de Datos: Se aplicaron técnicas de limpieza de datos para corregir errores ortográficos, mal uso de puntuación y errores gramaticales, asegurando la calidad del dataset.

2. Análisis de Grupos:

Clustering de Respuestas Médicas: Se implementaron algoritmos de clustering para identificar las respuestas más frecuentes de los médicos y etiquetar los datos manualmente. Se crearon clusters semánticos para agrupar respuestas similares y se seleccionaron los clusters más densos para su uso en el sistema.

3. Desarrollo del Modelo de Filtrado (Triggering Model):

Modelo de Clasificación Binaria: Se desarrolló un modelo de clasificación binaria para filtrar los mensajes de los pacientes y determinar si requieren una respuesta automática. Este modelo se entrenó utilizando técnicas de embedding ponderado y algoritmos como BERT y BiLSTM.

4. Generación de Respuestas:

Modelo de Generación de Respuestas: Se desarrollaron varios modelos de generación de respuestas, incluyendo BERT y Seq2Seq, para sugerir las respuestas más adecuadas a las consultas de los pacientes que pasaron el filtro de triggering. Estos modelos se entrenaron utilizando el conjunto de datos preprocesado y se ajustaron para maximizar la precisión y relevancia de las respuestas generadas.

5. Evaluación del Sistema:

Pruebas de Rendimiento: Se realizaron pruebas exhaustivas para evaluar la precisión, el recuerdo y la puntuación F1 de las respuestas generadas. Se utilizó un enfoque

de validación cruzada de 5 pliegues para asegurar la robustez del modelo y evitar el sobreajuste.

Comparación con Baselines: Se comparó el rendimiento de los modelos desarrollados con enfoques basados en reglas y otros algoritmos de aprendizaje automático, demostrando la efectividad del enfoque propuesto.

2.1.8.4. Resultados obtenidos

El sistema de generación de respuestas automáticas inteligentes demostró ser altamente efectivo en la provisión de respuestas precisas y relevantes a consultas médicas en línea. Los modelos basados en BERT superaron significativamente a otros algoritmos en términos de precisión y recuerdo, con una precisión@3 de 85.41%. La integración de técnicas de NLP y aprendizaje automático permitió generar respuestas coherentes y útiles en tiempo real, mejorando la eficiencia de las interacciones médico-paciente. Los resultados indican que el sistema puede manejar eficazmente una gran cantidad de consultas simultáneas, reduciendo la carga de trabajo de los médicos y mejorando la satisfacción de los pacientes.

Table 4 Summary performance values for the triggering and response generation model combinations to create an end-to-end pipeline

Triggering Model	Response Generation Model	Precision@3	Triggering Model	Response Generation Model	Precision@3
BERT	BERT	85.42 ± 0.82	LSTM	BERT	85.58 ± 0.42
BERT	LSTM	82.79 ± 0.81	LSTM	LSTM	83.28 ± 0.75
BERT	Seq2seq	60.22 ± 4.80	LSTM	Seq2seq	61.56 ± 4.08
BERT	XGBoost	80.89 ± 1.07	LSTM	XGBoost	81.92 ± 0.57
BERT	SVM	81.11 ± 1.23	LSTM	SVM	82.03 ± 0.66
BERT	Weighted-TFIDF	49.73 ± 4.03	LSTM	Weighted-TFIDF	51.63 ± 3.27
BERT	TFIDF	50.33 ± 3.22	LSTM	TFIDF	52.13 ± 2.90
BERT	Frequency	46.32 ± 1.82	LSTM	Frequency	48.18 ± 1.24
XGBoost	BERT	83.61 ± 0.41	SVM	BERT	83.00 ± 0.39
XGBoost	LSTM	81.37 ± 0.66	SVM	LSTM	80.68 ± 0.62
XGBoost	Seq2seq	59.32 ± 4.27	SVM	Seq2seq	58.59 ± 4.19
XGBoost	XGBoost	79.60 ± 0.52	SVM	XGBoost	78.83 ± 0.48
XGBoost	SVM	79.81 ± 0.57	SVM	SVM	78.98 ± 0.49
XGBoost	Weighted-TFIDF	48.85 ± 3.42	SVM	Weighted-TFIDF	47.79 ± 3.30
XGBoost	TFIDF	49.45 ± 2.48	SVM	TFIDF	48.41 ± 2.41
XGBoost	Frequency	45.61 ± 0.63	SVM	Frequency	44.51 ± 0.46
Weighted-TFIDF	BERT	73.31 ± 0.96	TFIDF	BERT	73.27 ± 0.66
Weighted-TFIDF	LSTM	71.45 ± 0.91	TFIDF	LSTM	71.28 ± 0.72
Weighted-TFIDF	Seq2seq	52.34 ± 3.12	TFIDF	Seq2seq	52.09 ± 3.31
Weighted-TFIDF	XGBoost	69.96 ± 0.87	TFIDF	XGBoost	69.75 ± 0.68
Weighted-TFIDF	SVM	70.14 ± 0.78	TFIDF	SVM	69.90 ± 0.56
Weighted-TFIDF	Weighted-TFIDF	46.46 ± 2.97	TFIDF	Weighted-TFIDF	45.38 ± 2.90
Weighted-TFIDF	TFIDF	44.44 ± 1.20	TFIDF	TFIDF	44.35 ± 1.28
Weighted-TFIDF	Frequency	42.24 ± 0.74	TFIDF	Frequency	40.93 ± 0.70

**Figura 2.15:** Valores de rendimiento para la combinación de modelos de activación y generación de respuesta. Fuente: [Jahanshahi et al., 2022](#)

2.1.9. An Approach to Medical Diagnosis Using Smart Chatbot ([Verma, Singh, Tiwari & Tripathy, 2022](#))

2.1.9.1. Planteamiento del Problema

El acceso a diagnósticos médicos precisos y accesibles es un desafío significativo, especialmente en áreas con recursos médicos limitados. Las visitas hospitalarias para asuntos menores a menudo se evitan, lo que puede llevar a problemas de salud más graves en el futuro. Para abordar esta situación, se propone el desarrollo de un chatbot médico llamado DiagZone, diseñado para proporcionar diagnósticos rápidos y fiables de manera remota y accesible desde cualquier lugar. Utilizando tecnologías como AWS Lex, AWS Lambda y Twilio, DiagZone integra procesamiento de lenguaje natural (NLP) para analizar las consultas de los usuarios, identificar posibles enfermedades y sugerir medidas correctivas o remitir al usuario a un médico si es necesario. Este enfoque pretende mejorar la eficiencia del diagnóstico médico, reducir la carga de trabajo de los especialistas y ofrecer una solución accesible y gratuita para el monitoreo de la salud.

2.1.9.2. Fundamento Teórico

El desarrollo de DiagZone se basa en varios principios teóricos y tecnológicos clave:

- **Procesamiento de Lenguaje Natural (NLP):** Utiliza técnicas de NLP para analizar y comprender las consultas de los usuarios, permitiendo una interacción más humana y precisa. Herramientas como Python NLTK son empleadas para analizar el habla y generar respuestas inteligentes.
- **Modelos de Aprendizaje Automático:** Se entrena modelo como AWS Lex con datos médicos para mejorar su capacidad de diagnóstico. Estos modelos son capaces de reconocer patrones en las consultas de los usuarios y generar respuestas basadas en un conjunto de datos predefinido.
- **Integración de Servicios en la Nube:** AWS Lambda y Twilio se utilizan para integrar el chatbot con plataformas de mensajería como WhatsApp, permitiendo una comunicación segura y eficiente. Estas tecnologías aseguran que el chatbot pueda manejar grandes volúmenes de consultas de manera rápida y segura.
- **Enfoque en la Seguridad de los Datos:** Se implementan estrictas medidas de seguridad para proteger la información sensible de los usuarios. Twilio proporciona un sistema de prevención de pérdida de datos y Amazon Lex implementa controles técnicos y físicos para prevenir el acceso no autorizado a la información.

- **Accesibilidad y Usabilidad:** El chatbot está diseñado para ser accesible desde cualquier dispositivo con conexión a internet, lo que facilita su uso en diversas situaciones y por diferentes tipos de usuarios.

2.1.9.3. Metodología empleada por los autores

La metodología para desarrollar DiagZone incluye varias etapas clave:

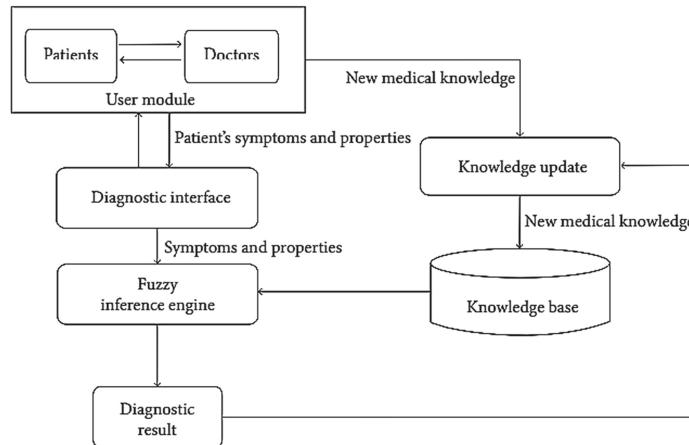


Figura 2.16: Metodología. Fuente: Verma et al., 2022

1. Recolección y Preparación de Datos:

Dataset de Síntomas: Se recopiló un conjunto de datos de síntomas y enfermedades de diversas fuentes médicas confiables. Este dataset se utiliza para entrenar el modelo de aprendizaje automático.

Limpieza y Preprocesamiento de Datos: Se eliminaron errores ortográficos y gramaticales de los datos recopilados para asegurar su calidad. Se utilizaron técnicas de tokenización y extracción de características para preparar los datos para el análisis.

2. Desarrollo del Modelo de Diagnóstico:

Entrenamiento del Modelo: Utilizando AWS Lex, se entrenó un modelo de lenguaje que puede analizar las consultas de los usuarios y generar diagnósticos basados en los síntomas proporcionados.

Integración con Servicios en la Nube: AWS Lambda y Twilio se integraron para permitir la comunicación segura entre el chatbot y los usuarios a través de WhatsApp. Este sistema permite que el chatbot acceda a una base de datos de conocimiento médico y genere respuestas en tiempo real.

3. Implementación de Medidas de Seguridad:

Protección de Datos: Se implementaron sistemas de prevención de pérdida de datos y encriptación para proteger la información sensible de los usuarios. Twilio asegura que los datos solo sean accesibles por dispositivos autorizados y se sigue el principio de menor privilegio para el acceso a la información.

Auditorías y Cumplimiento: AWS certifica que las medidas de seguridad cumplen con los requisitos legislativos, contractuales y regulatorios necesarios para manejar datos médicos sensibles.

4. Evaluación:

Pruebas de Rendimiento: Se realizaron pruebas exhaustivas para evaluar la precisión y relevancia de los diagnósticos generados por el chatbot. Se utilizó un enfoque de validación cruzada para asegurar la robustez del modelo.

2.1.9.4. Resultados obtenidos

DiagZone demostró ser efectivo en la provisión de diagnósticos médicos precisos y relevantes. En pruebas de rendimiento, el chatbot fue capaz de analizar los síntomas proporcionados por los usuarios y sugerir posibles enfermedades junto con medidas correctivas adecuadas. El sistema también pudo referir a los usuarios a médicos en caso de que los síntomas indicaran una condición más grave. La integración con WhatsApp a través de Twilio permitió una comunicación rápida y segura, mientras que el uso de AWS Lex garantizó respuestas precisas basadas en el análisis de datos de síntomas. Los usuarios reportaron una alta satisfacción con la facilidad de uso y la rapidez de las respuestas proporcionadas por el chatbot.

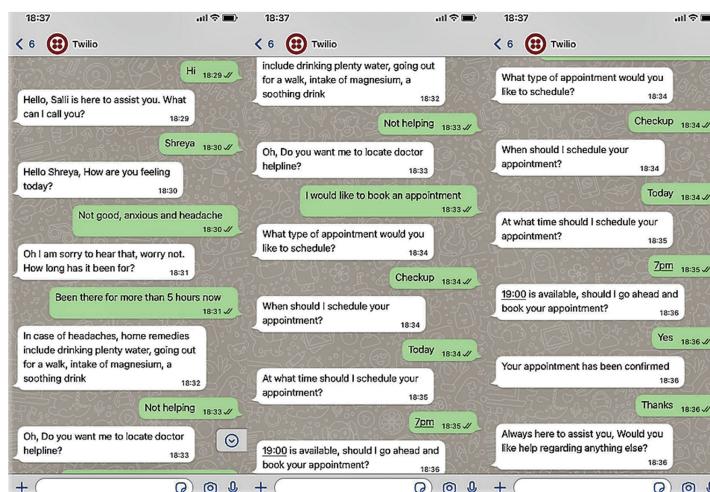


Figura 2.17: Chat Between User and Bot Salli. Fuente: [Verma et al., 2022](#)

2.1.10. A Medical ChatBot (Dharwadkar & Deshpande, 2018)

2.1.10.1. Planteamiento del Problema

El acceso a información médica precisa y oportuna es esencial para el bienestar de las personas, pero muchas veces los usuarios no cuentan con el conocimiento necesario sobre tratamientos o síntomas de enfermedades específicas. Además, las visitas al hospital para problemas menores pueden ser costosas y consumir mucho tiempo, y las consultas telefónicas pueden ser no siempre efectivas. Se presenta un chatbot médico que utiliza procesamiento de lenguaje natural (NLP) para proporcionar orientación sobre temas de salud de manera inmediata y accesible, sin la necesidad de visitas físicas al hospital. Este sistema no solo pretende ahorrar tiempo y reducir la carga sobre los servicios médicos, sino también ofrecer un recurso educativo para aquellos interesados en mejorar su conocimiento sobre salud y bienestar.

2.1.10.2. Fundamento Teórico

El desarrollo del chatbot médico se fundamenta en varias teorías y tecnologías clave:

- **Procesamiento de Lenguaje Natural (NLP):** El NLP permite a las máquinas comprender e interpretar el lenguaje humano, facilitando la interacción entre el usuario y el chatbot. Técnicas como el etiquetado de partes del discurso y el análisis semántico se utilizan para interpretar correctamente las consultas de los usuarios y generar respuestas adecuadas.
- **Algoritmo de Máquina de Vectores de Soporte (SVM):** El SVM permitirá diferenciar entre diferentes clases basándose en los datos de entrenamiento. En el contexto del chatbot médico, se utiliza para predecir enfermedades.

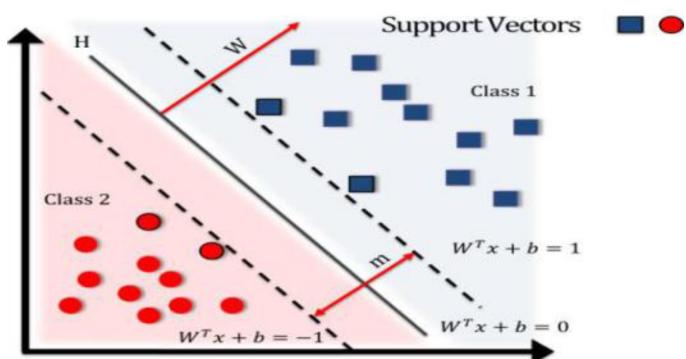


Figura 2.18: Separando hiperplano por ecuación. Fuente: [Dharwadkar y Deshpande, 2018](#)

- **Similitud de Orden de Palabras:** La similitud de orden de palabras es importante para asegurar que el significado de las oraciones se mantenga coherente. Diferentes órdenes de palabras pueden alterar significativamente el significado de una oración.
- **Algoritmo de Stemming de Porter:** Este algoritmo se utiliza para reducir las palabras a su raíz o forma base, eliminando sufijos comunes. Esto ayuda a normalizar los datos textuales y mejora la precisión del análisis de NLP.
- **Interfaz de Usuario Gráfica (GUI):** Una GUI eficiente es crucial para facilitar la interacción entre el usuario y el chatbot, simulando una conversación humana.
- **APIs de Google:** Las APIs de Google para la conversión de voz a texto y reversa se utilizan para facilitar la comunicación verbal con el chatbot. Permite a usuarios interactuar con el sistema utilizando comandos de voz, mejorando la accesibilidad para personas con discapacidades visuales o dificultades para escribir.

2.1.10.3. Metodología empleada por los autores

La metodología empleada incluye varias etapas clave:

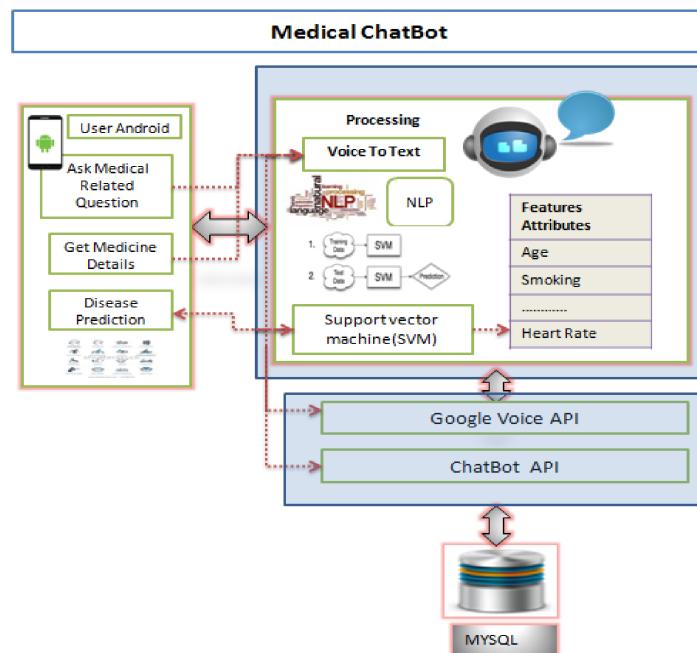


Figura 2.19: Metodología del Medical Chatbot. Fuente: [Dharwadkar y Deshpande, 2018](#)

1. Recolección y Preparación de Datos:

Dataset de Síntomas y Enfermedades: Se recopiló un conjunto de datos de síntomas y enfermedades de diversas fuentes médicas confiables. Estos datos fueron limpiados y preprocesados para asegurar su calidad y relevancia.

Filtrado de Datos: Se aplicaron técnicas de limpieza de datos para corregir errores ortográficos y gramaticales, así como para eliminar cualquier ruido o datos irrelevantes.

2. Desarrollo del Modelo de Diagnóstico:

Entrenamiento del Modelo SVM: Se entrenó un modelo de SVM para clasificar y predecir enfermedades basándose en los síntomas proporcionados por los usuarios. Este modelo fue ajustado para maximizar la precisión y minimizar los errores de clasificación.

Implementación de NLP: Se integraron técnicas de NLP para analizar y comprender las consultas de los usuarios. Esto incluye el uso de algoritmos de stemming, etiquetado de partes del discurso y análisis semántico para interpretar correctamente las entradas de texto.

3. Desarrollo de la Interfaz de Usuario:

Diseño de la GUI: Se diseñó una interfaz intuitiva y fácil de usar para facilitar la interacción entre los usuarios y el chatbot. La GUI incluye funciones para la entrada de texto y voz, así como para la visualización de respuestas.

Integración con APIs de Google: Las APIs de Google para la conversión de voz a texto y viceversa se integraron en el sistema para permitir la comunicación verbal con el chatbot.

4. Implementación de la Similitud de Orden de Palabras:

Cálculo de la Similitud: Se implementaron técnicas para calcular la similitud de orden de palabras entre las consultas de los usuarios y las respuestas almacenadas en la base de datos.

Optimización del Umbral: Se ajustó el umbral de similitud para equilibrar la precisión y la relevancia de las respuestas generadas, asegurando que el chatbot proporcione respuestas útiles y coherentes.

5. Evaluación:

Pruebas de Rendimiento: Se realizaron pruebas exhaustivas para evaluar la precisión y relevancia de los diagnósticos generados por el chatbot. Se utilizó un enfoque de validación cruzada para asegurar la robustez del modelo y evitar el sobreajuste.

2.1.10.4. Resultados obtenidos

El chatbot médico demostró ser efectivo en la provisión de diagnósticos médicos precisos y relevantes. En las pruebas de rendimiento, el modelo de SVM logró una precisión del

94 %, superando significativamente a los métodos K-nearest neighbors y Naive Bayes. El uso de técnicas de NLP permitió al chatbot interpretar correctamente las consultas de los usuarios y generar respuestas útiles basadas en los datos de síntomas y enfermedades. La integración con APIs de Google facilitó la comunicación verbal con el chatbot, mejorando la accesibilidad para una mayor variedad de usuarios. Los usuarios expresaron una gran satisfacción con la facilidad y precisión del diagnóstico proporcionado por el chatbot.

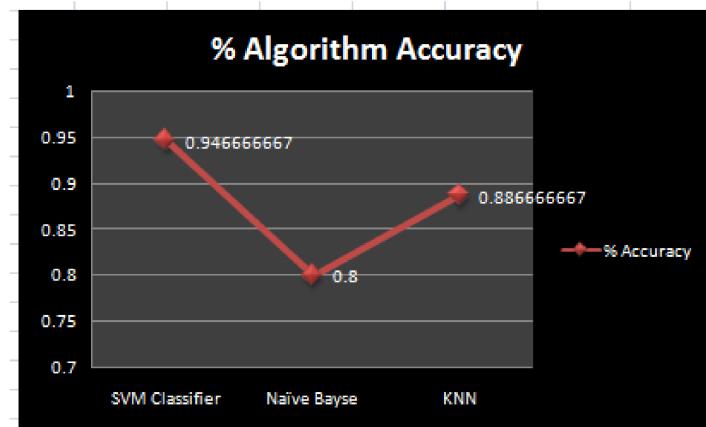


Figura 2.20: Algoritmo de Exactitud después de la comparación de diferentes métodos. Fuente: [Dharwadkar y Deshpande, 2018](#)

2.2. Bases Teóricas

2.2.1. Inteligencia Artificial y Procesamiento de Lenguaje Natural

Inteligencia Artificial (IA): La IA hace referencia a la imitación de los procesos de inteligencia humana por parte de sistemas de computación. En el contexto de un chatbot médico, la IA se utiliza para analizar las consultas de los usuarios y proporcionar respuestas precisas.

Procesamiento de Lenguaje Natural (NLP): El NLP es una rama de la IA que se centra en la interacción entre computadoras y humanos mediante el lenguaje natural. Los modelos de NLP permiten a los chatbots entender y responder a las consultas en lenguaje humano, facilitando la comunicación natural y efectiva.

BERT (Bidirectional Encoder Representations from Transformers): Un modelo pre-entrenado que ha demostrado un rendimiento superior en diversas tareas de NLP.

LSTM (Long Short-Term Memory): Tipo de red neuronal recurrente para secuencias de datos largos y complejos.

2.2.2. Modelos de Machine Learning

Machine Learning (ML): Se trata de una rama de la Inteligencia Artificial que capacita a los sistemas para aprender y mejorar a partir de la experiencia, sin necesidad de ser programados explícitamente para cada tarea. Los algoritmos de ML son fundamentales para el funcionamiento de los chatbots, ya que permiten mejorar la precisión y relevancia de las respuestas basadas en datos históricos.

Redes Neuronales y Deep Learning: Las redes neuronales, especialmente las redes neuronales profundas (deep learning), han revolucionado el campo del NLP. Modelos como Transformers y BERT (Bidirectional Encoder Representations from Transformers) son capaces de comprender el contexto y matices del lenguaje humano con gran precisión.

2.2.3. Telemedicina y Salud Digital

Telemedicina: La telemedicina se refiere al uso de tecnologías de la información para proporcionar servicios médicos a distancia. Los chatbots médicos son una extensión de la telemedicina, proporcionando asesoramiento y orientación médica sin la necesidad de una interacción cara a cara.

Salud Digital: La salud digital engloba todas las aplicaciones de las tecnologías digitales en el ámbito sanitario. Esto incluye desde aplicaciones móviles hasta sistemas complejos de gestión de datos de pacientes. Los chatbots médicos se sitúan en la intersección de la salud digital y la telemedicina, facilitando el acceso a información médica de calidad.

2.3. Marco Conceptual

2.3.1. Concepto de Chatbot Médico Pediátrico

Un **chatbot médico pediátrico** es una aplicación de software diseñada para interactuar con los usuarios mediante una interfaz de chat, ofreciendo asesoramiento y orientación médica específica para pediatría. Este chatbot puede responder preguntas sobre síntomas comunes, proporcionar consejos de salud preventiva y orientar sobre cuándo buscar atención médica.

2.3.2. Componentes del Chatbot Médico Pediátrico

- **Interfaz de Usuario:** La interfaz debe ser intuitiva y fácil de usar, especialmente diseñada para personas con acceso limitado a la tecnología.

- **Motor de IA y NLP:** El corazón del chatbot, responsable de entender las consultas y generar respuestas adecuadas.
- **Base de Conocimientos Médicos:** Una base de datos extensa y actualizada con información validada por expertos en pediatría.
- **Módulo de Seguridad y Privacidad:** Implementaciones para garantizar la seguridad de los datos de los usuarios y el cumplimiento de las regulaciones de privacidad.

2.3.3. Funcionalidades del Chatbot

- **Consulta de Síntomas:** Permite a los usuarios ingresar síntomas y recibir orientación sobre posibles condiciones y recomendaciones.
- **Información Preventiva:** Proporciona consejos sobre vacunaciones, nutrición y desarrollo infantil.
- **Orientación en Emergencias:** Informa a los usuarios sobre cuándo es crucial buscar atención médica inmediata.
- **Soporte Multilingüe:** Para ser accesible a comunidades rurales diversas, el chatbot debe soportar múltiples idiomas y dialectos.

2.3.4. Beneficios de Implementar un Chatbot Médico Pediátrico

- **Accesibilidad:** Proporciona acceso a información médica en áreas rurales con pocos recursos médicos.
- **Eficiencia:** Reduce la carga en los centros de salud al manejar consultas básicas de forma automatizada.
- **Costos Reducidos:** Minimiza los costos asociados con desplazamientos y consultas médicas innecesarias.
- **Educación Sanitaria:** Aumenta el conocimiento y la concienciación sobre temas de salud entre las comunidades rurales.

2.3.5. Desafíos

- **Precisión de las Respuestas:** Garantizar que la información proporcionada sea precisa y actualizada.

- **Privacidad de los Datos:** Proteger la confidencialidad de la información de los usuarios.
- **Accesibilidad Tecnológica:** Asegurar que el chatbot sea accesible en áreas con conectividad limitada.
- **Aprobación Reguladora:** Cumplir con las regulaciones locales e internacionales sobre salud y tecnología.

2.4. Implementación Técnica

2.4.1. Selección de la Plataforma de Desarrollo

Plataformas recomendadas para el desarrollo de chatbots médicos incluyen:

- **Dialogflow:** Ofrecido por Google, soporta NLP avanzado y es fácil de integrar con otras aplicaciones.
- **Microsoft Bot Framework:** Una plataforma robusta para desarrollar y desplegar chatbots en múltiples canales.
- **Rasa:** Una opción open-source que proporciona flexibilidad y control total sobre el diseño del chatbot.

2.4.2. Diseño de la Arquitectura del Chatbot

- **Frontend:** La interfaz de usuario, que puede ser una aplicación web, móvil o incluso integrarse en plataformas de mensajería existentes como WhatsApp.
- **Backend:** El servidor que alberga el motor de IA y la base de conocimientos, procesando las consultas y generando respuestas.
- **Integraciones:** Con sistemas de información médica, bases de datos de salud y plataformas de telemedicina.

2.4.3. Desarrollo del Chatbot

- **Entrenamiento del Modelo de NLP:** Utilizar datos médicos pediátricos para entrenar el modelo, asegurando que pueda comprender y responder a consultas específicas.

- **Desarrollo de la Base de Conocimientos:** Compilar y estructurar la información médica relevante en una base de datos accesible por el chatbot.
- **Pruebas y Validación:** Realizar pruebas exhaustivas para asegurar la precisión y fiabilidad del chatbot, incluyendo pruebas de usabilidad con usuarios de áreas rurales.

Anexos

Anexos A

Anexo I: Matriz de Consistencia

PROBLEMAS	OBJETIVOS	HIPÓTESIS
Problema General	Objetivo General	Hipótesis General
Problemas Específicos	Objetivos Específicos	Hipótesis Específicas
¿De qué manera la implementación de un chatbot médico Pediatrico puede mejorar el acceso a servicios de salud en las zonas rurales de Perú?	Implementar un chatbot médico Pediatrico efectivo y sostenible para brindar servicios de salud de calidad a las poblaciones rurales en Perú	La implementación de un chatbot médico Pediatrico mejorará significativamente el acceso a servicios médicos de calidad para las poblaciones rurales.
¿Que datos disponibles se necesitaran para la implementacion de chatbot médico Pediatrico?	Identificar los datos disponibles y necesarios para la implementación del chatbot médico Pediatrico en áreas rurales de Perú.	La disponibilidad de datos y la integración de APIs adecuadas serán fundamentales para el desarrollo exitoso del chatbot médico Pediatrico.
¿Que arquitectura podrían ser utilizadas para desarrollar un chatbot médico Pediatrico?	Explorar las diferentes arquitecturas disponibles para el desarrollo del chatbot médico Pediatrico.	La arquitectura permitirá la creación de un chatbot médico Pediatrico eficiente y preciso.
¿Qué métodos de entrenamiento y validación se pueden utilizar para un chatbot médico Pediatrico?	Investigar métodos de entrenamiento y validación adecuados para un chatbot médico Pediatrico.	La aplicación de métodos de entrenamiento y validación apropiados garantizarán la funcionalidad y confiabilidad del chatbot médico Pediatrico.
¿Qué métricas se pueden utilizar para evaluar la efectividad del chatbot médico Pediatrico?	Definir métricas de evaluación para medir la efectividad y el impacto del chatbot médico Pediatrico en la prestación de servicios de la salud.	La evaluación de métricas específicas revelará el impacto positivo del chatbot médico Pediatrico en la prestación de servicios de salud en áreas rurales de Perú.

Tabla A.1: Matriz de consistencia. Fuente: Elaboración propia

Hipótesis Específica	Indicadores	Fórmulas
La disponibilidad de datos y la integración de APIs adecuadas serán fundamentales para el desarrollo exitoso del chatbot médico Pediatrico.	*Calidad de datos *Tiempo de respuesta de la API *Porcentaje de consultas resueltas	$\frac{\text{Cantidad de datos precisos y actualizados}}{\text{Total de datos utilizados}} \times 100$ $\frac{\text{Tiempo total de respuesta de la API}}{\text{Número total de consultas}}$ $\frac{\text{Consultas resueltas}}{\text{Total de consultas realizadas}} \times 100$
La arquitectura permitirá la creación de un chatbot médico Pediatrico eficiente y preciso.	*Precisión del modelo de lenguaje natural *Eficiencia del chatbot *Precisión de Diagnóstico (PD) *Tasa de Error del Sistema (TES)	$\frac{\text{Número de respuestas correctas}}{\text{Total de respuestas generadas}} \times 100$ $\frac{\text{Número de consultas manejadas}}{\text{Tiempo total de prueba}}$ $\frac{\text{Número de diagnósticos correctos}}{\text{Número Total de diagnósticos}} \times 100$ $\frac{\text{Número de errores del sistema}}{\text{Número total de interacciones}} \times 100$
La aplicación de métodos de entrenamiento y validación apropiados garantizarán la funcionalidad y confiabilidad del chatbot médico Pediatrico.	*Exactitud del conjunto de datos de entrenamiento *Precisión de la validación cruzada *Tasa de Mejoría en Entrenamiento (TME)	$\frac{\text{Número de pares de consulta-respuesta correctos}}{\text{Total de pares de consulta-respuesta}} \times 100$ $\frac{\text{Número de consultas validadas correctamente}}{\text{Total de consultas validadas}} \times 100$ $\frac{\text{Error inicial} - \text{Error final}}{\text{Error inicial}} \times 100$
La evaluación de métricas específicas revelará el impacto positivo del chatbot médico Pediatrico en la prestación de servicios de salud en áreas rurales de Perú.	*Reducción en tiempos de espera *Aumento en la accesibilidad de servicios médicos *Cobertura de Usuarios en Áreas Rurales (CUAR) *Satisfacción del usuario	Antes= Tiempo promedio de espera antes del chatbot Después= Tiempo promedio de espera después del chatbot $\frac{\text{Antes} - \text{Después}}{\text{Antes}} \times 100$ $\frac{\text{Número de consultas médicas atendidas por el chatbot}}{\text{Total de consultas médicas realizadas}} \times 100$ $\frac{\text{Número de usuarios en áreas rurales}}{\text{Número total de usuarios}} \times 100$ $\frac{\text{Número de usuarios satisfechos}}{\text{Total de usuarios encuestados}} \times 100$

Tabla A.2: Tabla de Hipótesis Específicas, Indicadores y Fórmulas

Anexos B

Anexo II: Arbol del Problema

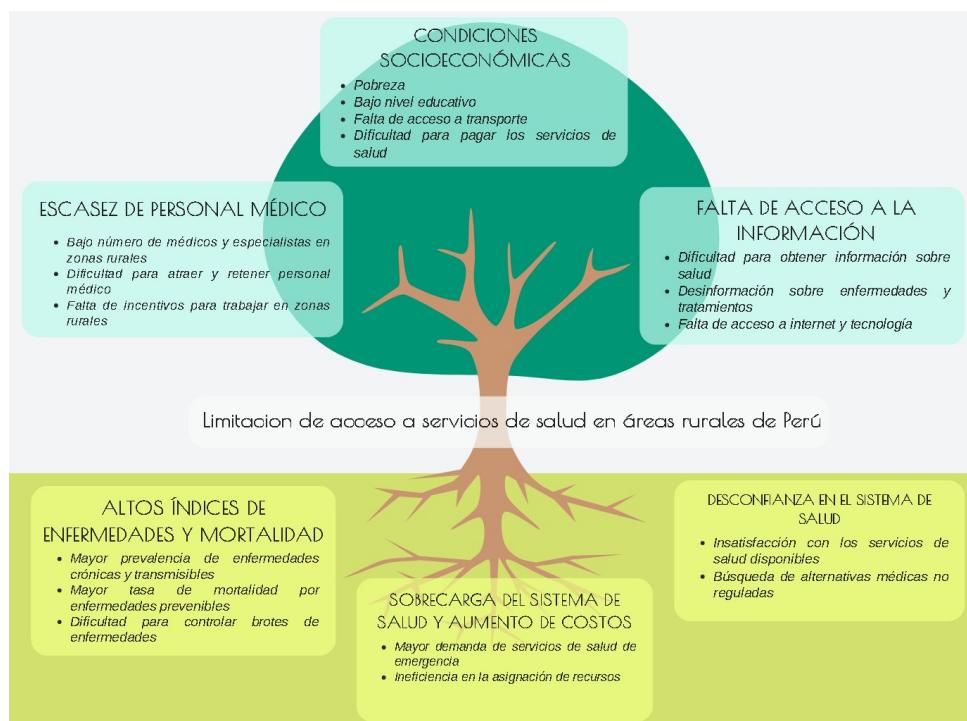


Figura B.1: Árbol del problema. Fuente: Elaboración propia

Anexos C

Anexo IV: Resumen de Papers investigados

Tipo	Nº	Título	Autor	Año	País	Fuente
Problema	1	«The Health ChatBots in Telemedicine: Intelligent Dialog System for Remote Support»	Vasileiou y Maglogiannis	2022	Ver el pais despues	https://doi.org/10.1155/2022/4876512
	2	«PEFT-MedAware: Large Language Model for Medical Awareness»	Pandya	2023	Ver el pais despues	https://doi.org/10.48550/arXiv.2311.10697
Propuesta	3	«Medbot: Conversational Artificial Intelligence Powered Chatbot for Delivering Tele-Health after COVID-19»	Bharti et al.	2020	Ver el pais	10 . 1109 / ICCES48766 . 2020.9137944
	4	«Intelligent Chatbot for Medical Assistance in Rural Areas»	Arulmangainayaki et al.	2020	Ver el	http://dx.doi.org/10.35940/ijitee.F3083.049620
Técnica	5	«HHH: An Online Medical Chatbot System based on Knowledge Graph and Hierarchical Bi-Directional Attention»	Bao et al.	2020	Ver	http://dx.doi.org/10.1145/3373017.3373049
	6	«HealFavor: Dataset and A Prototype System for Healthcare ChatBot»	Ur Rahman Khilji et al.	2020	despues	10 . 1109 / DATABIA50434 . 2020.9190281
	7	«ChatDoctor: A Medical Chat Model Fine-Tuned on a Large Language Model Meta-AI (LLaMA) Using Medical Domain Knowledge»	Li et al.	2023	Ver el pais despues	10 . 7759 / cureus . 40895

Tipo	Nº	Título	Autor	Año	País	Fuente
Técnica	8	«Auto Response Generation in Online Medical Chat Services»	Jahanshahi et al.	2022	Ver el país después	https://pubmed.ncbi.nlm.nih.gov/35854816/
	9	«An Approach to Medical Diagnosis Using Smart Chatbot»	Verma et al.		Ver el país después	https://doi.org/10.1007/978-981-19-3089-8_5
	10	«A Medical ChatBot»	Dharwadkar y Deshpande	2018	Ver el país después	10.14445/22312803/IJCTT-V60P106

BIBLIOGRAFÍA

- Abd-Alrazaq, A., Safi, Z., Alajlani, M., Warren, J., Househ, M., & Denecke, K. (2020). Technical metrics used to evaluate health care chatbots: Scoping review. *J. Med. Internet Res.*, 22(6), e18301.
- Arulmagainayaki, V., Harini, M., Keerthiga, M., & Priya*, M. D. (2020). Intelligent Chatbot for Medical Assistance in Rural Areas. *International Journal of Innovative Technology and Exploring Engineering*, 9(6), 24-31. <https://doi.org/10.35940/ijitee.f3083.049620>
- Bao, Q., Ni, L., & Liu, J. (2020). HHH: An Online Medical Chatbot System based on Knowledge Graph and Hierarchical Bi-Directional Attention. <https://doi.org/10.1145/3373017.3373049>
- Bharti, U., Bajaj, D., Batra, H., Lalit, S., Lalit, S., & Gangwani, A. (2020). Medbot: Conversational Artificial Intelligence Powered Chatbot for Delivering Tele-Health after COVID-19, 870-875. [10.1109/ICCES48766.2020.9137944](https://doi.org/10.1109/ICCES48766.2020.9137944)
- Braveman, P., & Gruskin, S. (2003). Defining equity in health. *Journal of Epidemiology & Community Health*, 57(4), 254-258. <https://doi.org/10.1136/jech.57.4.254>
- Dharwadkar, R., & Deshpande, N. (2018). A Medical ChatBot. *International Journal of Computer Trends and Technology*, 60, 41-45. [10.14445/22312803/IJCTT-V60P106](https://doi.org/10.14445/22312803/IJCTT-V60P106)
- Diez-Canseco, F., Zavala-Loayza, J. A., Beratarrechea, A., Kanter, R., Ramirez-Zea, M., Rubinstein, A., Martinez, H., & Miranda, J. J. (2015). Design and multi-country validation of text messages for an mHealth intervention for primary prevention of progression to hypertension in Latin America. *JMIR MHealth UHealth*, 3(1), e19.
- Epstein, R. M., & Street, R. L. (2011). The Values and Value of Patient-Centered Care. *The Annals of Family Medicine*, 9(2), 100-103. <https://doi.org/10.1370/afm.1239>
- INEI. (2022). POBLACIÓN AFILIADA A SEGURO SOCIAL DE SALUD - EsSalud, SEGÚN ÁMBITO GEOGRÁFICO, 2012-2022. <https://www.inei.gob.pe/estadisticas/indice-tematico/health/>
- Jahanshahi, H., Kazmi, S., & Cevik, M. (2022). Auto Response Generation in Online Medical Chat Services. *Journal of healthcare informatics research*, 6(3), 344-374. <https://doi.org/10.1007/s41666-022-00118-x>

- Laranjo, L., Dunn, A. G., Tong, H. L., Kocaballi, A. B., Chen, J., Bashir, R., Surian, D., Gallego, B., Magrabi, F., Lau, A. Y. S., & Coiera, E. (2018). Conversational agents in healthcare: a systematic review. *J. Am. Med. Inform. Assoc.*, 25(9), 1248-1258.
- Li, Y., Li, Z., Zhang, K., Dan, R., Jiang, S., & Zhang, Y. (2023). ChatDoctor: A Medical Chat Model Fine-Tuned on a Large Language Model Meta-AI (LLaMA) Using Medical Domain Knowledge. [10.7759/cureus.40895](https://doi.org/10.7759/cureus.40895)
- OECD & Bank, T. W. (2020). *Panorama de la Salud: Latinoamérica y el Caribe 2020*. <https://doi.org/10.1787/740f9640-es>
- Pandya, K. (2023). PEFT-MedAware: Large Language Model for Medical Awareness. <https://doi.org/10.48550/arXiv.2311.10697>
- (PwC), P. (2017, mayo). Bot.Me: A revolutionary partnership—How AI is pushing man and machine closer together—ContentEngine. <https://contentenginellc.com/2017/05/15/bot-me-a-revolutionary-partnership-how-ai-is-pushing-man-and-machine-closer-together/>
- Rogers, E. M. (2003). *Diffusion of Innovations*. Free Press.
- Tudor Car, L., Dhinagaran, D. A., Kyaw, B. M., Kowatsch, T., Joty, S., Theng, Y.-L., & Atun, R. (2020). Conversational agents in health care: Scoping review and conceptual analysis. *J. Med. Internet Res.*, 22(8), e17158.
- UNICEF. (2022). La mortalidad infantil alcanzó un mínimo mundial histórico en 2022, según un informe de las Naciones Unidas. <https://www.unicef.org/es/comunicados-prensa/mortalidad-infantil-alcanzo-minimo-mundial-historico-2022>
- Ur Rahman Khilji, A. F., Laskar, S. R., Pakray, P., Kadir, R. A., Lydia, M. S., & Bandyopadhyay, S. (2020). HealFavor: Dataset and A Prototype System for Healthcare ChatBot, 1-4. [10.1109/DATABIA50434.2020.9190281](https://doi.org/10.1109/DATABIA50434.2020.9190281)
- Vasileiou, M. V., & Maglogiannis, I. G. (2022). The Health ChatBots in Telemedicine: Intelligent Dialog System for Remote Support. *Journal of healthcare engineering*, 2022, 1-12. <https://doi.org/10.1155/2022/4876512>
- Verma, S., Singh, M., Tiwari, I., & Tripathy, B. K. (2022). An Approach to Medical Diagnosis Using Smart Chatbot (A. K. Das, J. Nayak, B. Naik, S. Vimal & D. Pelusi, Eds.), 43-56. https://doi.org/10.1007/978-981-19-3089-8_5